

单位代码： 10293 密 级： \_\_\_\_\_

南京邮电大学

# 专业学位硕士学位论文



论文题目： 城市道路智能车辆行为  
识别与安全轨迹研究

学 号 1221077105

姓 名 陆金辉

导 师 鲍楠

专业学位类别 电子信息硕士

类 型 全日制

专业（领域） 电子信息

论文提交日期 2024.05

# **Research on Behavior Recognition and Safe Trajectory of Intelligent Vehicles on Urban Roads**

Thesis Submitted to Nanjing University of Posts and  
Telecommunications for the Degree of  
Master of Electronic Information



By

Jinhui Lu

Supervisor: Nan Bao

May 2024

# 摘要

在智能交通系统快速发展的背景下，城市道路交通安全问题日益成为社会广泛关注的议题。作为智能交通系统的重要组成部分，智能车辆的行为识别和安全轨迹规划准确性直接关系到道路行驶的安全性和效率。因此，本文围绕智能车辆在城市道路环境中的行驶特点，提出目标车辆行为识别和轨迹预测算法，并进一步规划本车安全行驶轨迹，以提高安全与效率。

首先，针对传统车辆行为识别方法特征选择繁琐、时序数据和多维数据处理表现不佳的问题，提出了一种基于混合高斯隐马尔可夫模型的城市道路智能车辆行为识别方法。通过 Prescan 平台仿真获取数据并选取合适的特征参数。根据 Baum-Welch 算法优化模型参数，并结合前后向算法实现对目标前车车辆行为的识别。仿真实验结果表明，该方法能够有效捕捉车辆行为的多样性和随时间的动态变化，从而更准确地识别车辆行为。

然后，在对前车行为进行预测识别的基础上，收集预测前车轨迹以便为主车规划最优安全轨迹做铺垫。根据仿真平台数据集筛选出前车的经典换道轨迹，采用横向加速度和航向角作为特征，用高斯混合模型聚类出不同换道风格的原型轨迹，并通过高斯过程回归模型得到预测的轨迹。实验证明，随着历史数据长度的增加，预测的精确性显著提高，模型生成的置信区间有效覆盖了实际轨迹。

最后，在前两点研究基础上，建立基于主车的圆形安全距离模型，考虑周围车道车辆的状态和前车行为轨迹，设计合适的换道策略。通过五次多项式生成主车备选路径簇，根据综合评价函数规划主车最优轨迹。仿真实验结果表明，引入圆形安全距离模型后，该方法能够兼顾场景的实时动态性，并成功规划出了安全高效的主车最优轨迹。

**关键词:**车辆行为识别，混合高斯隐马尔可夫模型，高斯过程回归，轨迹预测，安全距离模型，五次多项式，轨迹规划

# Abstract

Against the background of rapid development of intelligent transportation systems (ITS), urban road traffic safety has increasingly become a topic of wide social concern. As an important part of ITS, the behavior recognition and safety trajectory planning accuracy of intelligent vehicles are directly related to the safety and efficiency of road travel. Therefore, this thesis focuses on the driving characteristics of intelligent vehicles in urban road environment, proposes target vehicle behavior recognition and trajectory prediction algorithms, and further plans the safe driving trajectory of this vehicle to improve safety and efficiency.

Firstly, for the problems of cumbersome feature selection and poor performance of temporal data and multi-dimensional data processing in traditional vehicle behavior recognition methods, an intelligent vehicle behavior recognition method based on Mixed Gaussian Hidden Markov Model for urban roads is proposed. The data are obtained and appropriate feature parameters are selected through simulation on the Prescan platform. The model parameters are optimized according to the Baum-Welch algorithm and combined with the forward and backward algorithms to achieve the recognition of the vehicle behavior of the target front vehicle. The results of simulation experiments show that the method can effectively capture the diversity of vehicle behaviors and dynamic changes over time, and thus identify vehicle behaviors more accurately.

Then, based on the predictive identification of the front vehicle behavior, the predicted front vehicle trajectories are collected in order to pave the way for the main vehicle to plan the optimal safe trajectory. Based on the simulation platform dataset, the classical lane-changing trajectories of the front vehicle are screened, the lateral acceleration and heading angle are used as features, and the prototype trajectories with different lane-changing styles are clustered by Gaussian mixture model, and the predicted trajectories are obtained by Gaussian process regression model. It is proved that the accuracy of prediction is significantly improved with the increase of the length of historical data, and the confidence intervals generated by the model effectively cover the actual trajectories.

Finally, on the basis of the previous two studies, a circular safe distance model based on the main vehicle is established to design an appropriate lane changing strategy by considering the state of vehicles in the surrounding lanes and the behavioral trajectory of the front vehicle. The alternative path clusters of the main vehicle are generated by quintic polynomial, and the optimal

trajectory of the main vehicle is planned according to the comprehensive evaluation function. The simulation experimental results show that after the introduction of the circular safety distance model, the method can take into account the real-time dynamics of the scene and successfully plan the safe and efficient optimal trajectory of the main vehicle.

**Key words:** Vehicle Behavior Recognition, Mixed Gaussian Hidden Markov Model, Gaussian Process Regression, Trajectory Prediction, Safe Distance Model, Quintic Polynomial, Trajectory Planning

# 目录

第一章 绪论 .....	1
1.1 研究背景与意义 .....	1
1.2 国内外研究现状 .....	3
1.2.1 车辆行为识别研究现状 .....	4
1.2.2 车辆轨迹预测研究现状 .....	6
1.2.3 车辆轨迹规划研究现状 .....	7
1.3 主要研究内容 .....	8
1.4 论文组织结构 .....	9
第二章 相关背景知识介绍 .....	10
2.1 隐马尔可夫模型 .....	10
2.1.1 HMM 简介 .....	10
2.1.2 HMM 基本问题 .....	12
2.1.3 HMM 解决算法 .....	12
2.2 仿真平台简介 .....	19
2.2.1 Prescan 的仿真流程 .....	20
2.2.2 主要特性及应用场景 .....	21
2.2.3 仿真平台小结 .....	22
2.3 车辆轨迹预测方法 .....	22
2.3.1 基于物理模型的轨迹预测 .....	22
2.3.2 基于行为模型的轨迹预测 .....	22
2.3.3 基于交互模型的轨迹预测 .....	23
2.3.4 车辆轨迹预测小结 .....	23
2.4 车辆轨迹规划方法 .....	24
2.4.1 基于优化的轨迹规划 .....	24
2.4.2 基于搜索的轨迹规划 .....	25
2.4.3 基于机器学习的轨迹规划 .....	25
2.4.4 基于曲线拟合的轨迹规划 .....	26
2.4.5 车辆轨迹规划小结 .....	26
2.5 本章小结 .....	26
第三章 基于 GM-HMM 的城市道路前车行为识别 .....	27
3.1 场景和数据分析 .....	27
3.1.1 行驶场景 .....	27
3.1.2 特征参数选择 .....	29
3.2 GM-HMM 模型构建 .....	30
3.3 参数训练 .....	31
3.4 城市道路车辆行为识别 .....	34
3.5 实验结果分析 .....	35
3.6 本章小结 .....	36
第四章 基于 GPR 的不同换道风格前车轨迹预测 .....	37
4.1 车辆行驶轨迹数据采集 .....	37
4.2 换道轨迹风格聚类特征选择 .....	38
4.3 不同换道风格下的车辆轨迹聚类 .....	39
4.4 基于高斯过程回归的轨迹预测 .....	43
4.4.1 模型设计 .....	44

4.4.2 轨迹预测 .....	46
4.5 实验结果分析 .....	47
4.6 本章小结 .....	50
第五章 车辆安全换道模型及其最优轨迹规划.....	52
5.1 车辆换道安全特性分析 .....	52
5.1.1 M 车与 L1/R1 车之间的最小纵向安全距离.....	54
5.1.2 M 车与 L2/R2 车之间的最小纵向安全距离.....	54
5.2 圆形安全距离模型的建立 .....	55
5.3 基于安全距离模型和前车行为轨迹的主车路径簇生成.....	58
5.4 最优轨迹规划 .....	61
5.5 实验结果分析 .....	63
5.6 本章小结 .....	68
第六章 总结与展望 .....	69
6.1 全文工作总结 .....	69
6.2 未来展望 .....	70
参考文献 .....	71
附录 1 攻读硕士学位期间撰写的论文 .....	75
附录 2 攻读硕士学位期间申请的专利 .....	76
附录 3 攻读硕士学位期间参加的科研项目 .....	77
致谢 .....	78

# 第一章 绪论

## 1.1 研究背景与意义

在智能交通系统快速发展的背景下，城市道路交通安全问题日益成为社会广泛关注的议题。智能车辆技术的发展为提高交通安全和效率提供了新的可能性，智能车辆通过集成高级感知系统、自动化决策和控制机制，具备了在复杂环境下识别多变行为模式并采取相应安全措施的能力。然而，智能车辆在城市环境中的有效和安全运行，不仅要求其精确识别预测其他车辆的行为和轨迹，还需要在复杂的交通环境中规划出安全且高效的行驶轨迹。

在城市道路的复杂交通环境中，车流量大，交通参与者的行为也极具多样化和不确定性，给智能车辆技术的发展带来了前所未有的考验。根据国家统计局发布的 2018-2022 年交通事故（含汽车交通事故）发生数及死亡人数数据，如图 1.1 和图 1.2 所示，我国道路交通事故频发，仅 2022 年达到 256409 起，其中涉及汽车交通事故共 157407 起，占比 61.3%，死亡 42012 人<sup>[1]</sup>，致死率高达 26.7%，而车辆变道事故占比高达 2.7%，驾驶员的误操作、视野盲区及车辆间不足的安全距离等因素，都可能触发交通事故。为了避免这些问题，当前技术解决方案包括车辆自动控制技术和高级驾驶辅助系统（Advanced Driving Assistance System, ADAS）等<sup>[2]</sup>，它们利用传感器等设备实时监控车辆周围环境，结合机器学习并通过分析数据来预防潜在风险。智能车辆利用这些技术，不仅能够检测到其他车辆的存在，还能预测识别它们的行为和轨迹，从而规划出安全的行驶轨迹。因此，目前为改善城市道路交通主要聚焦于以下关键技术：第一，智能车辆的准确判断能力，尤其是对前车等行为意图的预测识别，成为防止重大事故发生的关键。第二，前车轨迹预测是智能车辆安全行驶的关键。考虑到前车对主车的影响，需要智能车辆能够基于识别前车行为和当前的交通环境预测其未来轨迹，以便更好地进行安全轨迹规划。第三，主车的车辆轨迹规划则要求智能车辆在保证安全和效率的前提下，计算规划出最优行驶路径。这不仅要求智能车辆能够处理来自不同方向的信息，识别周围车辆的意图行为并预测其未来轨迹，还要求其在复杂的城市道路交通环境中做出快速而准确的决策。






图 1.1 2018-2022 交通事故发生数和汽车交通事故发生数




图 1.2 2018-2022 交通事故死亡人数和汽车交通事故死亡人数

这三大关键技术对提高智能车辆的安全性和行驶效率具有重要意义<sup>[3]</sup>。近年来，谷歌的 Waymo 自动驾驶项目使用复杂的机器学习模型来识别其他车辆的行为意图，这在城市交通中特别有效，帮助减少由预测错误引起的碰撞。特斯拉的 Autopilot 系统能够通过持续监控周围车辆动态，预测它们的未来位置，从而提前调整车速和方向，避免潜在碰撞。奥迪与斯坦福大学合作开发的 AI 驾驶助手，利用实时数据分析技术来优化车辆行驶路径，实现更安全高效的行驶体验。麻省理工在自动驾驶领域的研究中，开发了一种能够实时处理复杂交通场景的算法，提高了智能车辆在不可预测环境中的适应性和安全性。我国的百度 Apollo 项目在智能车辆的行为识别和轨迹预测方面也取得了突破，其开发的系统已在北京和上海的测试中显示出优越的交通适应能力。通过集成高精度的传感器、先进的人工智能技术和复杂的决策算法，

智能车辆有望实现对周围环境的实时感知、对未来事件的准确预测，以及最优轨迹规划。智能车辆的行为识别与轨迹预测规划能力直接关系到其是否能够有效避免交通事故，显著提高城市道路的安全性和交通流的效率。因此，本文聚焦于城市道路智能车辆的行为识别与安全轨迹研究，旨在通过提出一系列创新性的方法和策略，对车辆行为识别技术、车辆轨迹预测方法及车辆轨迹规划的进行深入剖析，系统性地解决智能车辆在复杂城市道路交通环境中的行为识别和安全轨迹问题。

综上所述，城市道路智能车辆的行为识别与安全轨迹研究对于实现智能车辆的安全高效行驶具有至关重要的意义，有助于为城市交通管理和规划提供新的思路和解决方案，显著提升智能车辆的行为轨迹预测精度和轨迹规划效率，促进城市道路交通系统的可持续发展，同时对提高城市交通的安全流畅性和缓解交通拥堵问题具有实际应用价值。

## 1.2 国内外研究现状

车辆行为识别、车辆轨迹预测以及车辆轨迹规划之间存在密切的联系和相互依赖的关系，广泛应用于智能车辆对动态交通场景的感知研究。

首先，车辆行为识别是自动驾驶系统预测的主要任务之一，它依赖于对周围环境的理解，其任务是选取关键目标车辆外部参数输入，结合算法识别并预测反映驾驶员的操作行为。这一步骤的准确性直接影响到后续的轨迹预测和规划的可靠性。

接着，车辆轨迹预测基于行为识别的结果，进一步预测目标车辆的未来位置状态，从而提前识别潜在危险，如避免碰撞和应对突发情况，同时帮助系统规划路线以增强行驶的效率 and 舒适性，为轨迹规划提供必要的前提条件。作为智能驾驶的核心模块，车辆轨迹预测的质量对于后面的规划至关重要。

最后，车辆轨迹规划则是在轨迹预测的基础上，结合车辆的动力学特性和环境约束，制定一条从起点到目标点的最优或可行路径<sup>[4]</sup>。这一过程需要综合考虑安全性、效率性和舒适性，同时满足驾驶规则和道路条件的限制。

在自动驾驶系统中，这三个环节形成了一个闭环反馈系统：车辆行为识别提供了轨迹预测的基础；轨迹预测为轨迹规划定下可行路线；而轨迹规划的结果又会通过控制系统反馈给车辆执行，进而影响到车辆的实际行为和状态，这些行为和状态的变化又会被系统捕捉和分析，用于下一轮的行为和轨迹预测。因此，这三者之间的紧密联系和相互作用是自动驾驶系统安全高效运行的关键。针对车辆行为识别、车辆轨迹预测、车辆轨迹规划，国内外已有大量研究，下面将进行阐述。

### 1.2.1 车辆行为识别研究现状

车辆行为识别依赖于对驾驶员操作及车辆动态数据的分析，以此来推断驾驶员的驾驶意图或行为模式。车辆行为识别作为自动驾驶和智能交通系统中的一个关键领域，它涉及到对车辆在道路上的各种行为进行准确、实时的监测和分析。这一领域的研究旨在提高交通系统的安全性、效率和智能化水平。

通过精确的车辆行为识别或预测，可以显著增强道路交通的安全性，学者们为此做了大量研究。初始的研究侧重于利用传感器如摄像头、激光雷达等收集车辆的速度、加速度和航向角等信息。如王润民等人<sup>[5]</sup>采用扩展卡尔曼滤波进行多传感器信息融合，并结合旋转矢量法和高斯牛顿法来预测并校正车辆姿态，以满足智能车辆行为识别需求。尽管该方法通过多传感器信息融合提高了解算精度，但其复杂度高，计算成本也相应增加。Li Y 等人<sup>[6]</sup>利用智能手机内置加速度传感器监测驾驶行为，通过重定向校准算法和 ISO 2631 标准进行效率评分，提供了一种成本低廉的解决方案。然而，这种方法的准确性受到手机位置的影响，需要进一步优化。由此可见，初始研究方法对这些数据的分析依赖于滤波、特征提取和模式识别技术，往往面临手动特征选择、耗时、适应性差等问题。

随着人工智能的兴起，基于机器学习的车辆行为识别方法得到了广泛关注，并取得了显著的成果。车辆行为的识别技术逐渐从初步的数据收集与分析，发展到应用机器学习算法实现行为预测和识别。在这一进程中，研究者们首先通过使用传感器收集车辆信息数据，再通过滤波、特征提取和模式识别技术进行处理，以便为后续的机器学习模型提供输入。机器学习模型能够从大量数据中学习复杂的特征表示，可以提取时空信息，更好地捕捉车辆行为的动态特征，提高车辆行为识别的准确性。

机器学习技术的应用标志着车辆行为识别方法的一大进步。袁伟等人<sup>[7]</sup>采用支持向量机（Support Vector Machine, SVM）建立了换道行为分类识别模型，并通过遗传算法对模型中的核函数参数进行了优化，提高了车辆行为识别准确度和效率，但该方法需要手动提取和选择特征，且对非线性问题处理能力有限，难以处理时间序列数据。王相海等人<sup>[8]</sup>提出了一种基于隐马尔可夫模型（Hidden Markov model, HMM）的车辆行为实时判别方法，能够有效应对时间序列的建模，通过分析方向角的变化区间来辨别各类车辆行为的独特属性，运用 Baum-Welch 算法在多个观测序列条件下对 HMM 模型参数进行优化训练，以获得最佳模型参数，并实时捕获车辆的行驶轨迹数据与模型进行比对，实现了对车辆行为的即时判定，但该方法在多维数据处理上表现不佳。Xing Z.Y.等人<sup>[9]</sup>通过利用多维高斯和离散隐马尔可夫模型分析驾驶行为数据建立双层隐马尔可夫模型，实现了车辆行为的在线识别模型，弥补了 HMM

难以处理多维数据的不足。熊晓夏等人<sup>[10]</sup>研提出了基于 HMM 和 SVM 算法的预测模型, 根据 HMM 的时间特性和 SVM 的分类特性, 通过对观测事件的概率建模和判别函数的建立, 能够有效预测危险车辆行为, 及时地进行驾驶预警和干预。SUN Q 等人<sup>[11]</sup>比较分析了不同变道策略下的变道时间、转角、相对距离和速度, 并使用随机森林 (Random Forest, RF) 分类器构建了车辆行为识别模型。Lee 等人<sup>[12]</sup>提出了一种进化 RF 算法, 通过有效地学习车辆中大量的传感器数据来识别驾驶员意图倾向, 但倘若数据集噪声较大, RF 很可能陷入过拟合。

最新的研究转向深度学习框架, Gao 等人<sup>[13]</sup>提出了一种新型的多尺度时空 Transformer 车辆行为检测框架, 该框架采用前视视频帧和车辆信号的多模态数据, 设计多补丁架构来捕获不同尺度的驾驶场景特征, 并通过多补丁时空注意模块来同时模拟多尺度特征并捕捉空间-时间关联, 从而准确的识别车辆行为。Guo 等人<sup>[14]</sup>开发了基于的 Transformer 的变道预测模型, 该模型通过注意力机制集中计算力于关键信息, 成功预测了未来两秒内的车道变换。尽管 Transformer 模型在车辆行为识别中表现出了高效的学习能力, 但其资源消耗大、训练时间长、泛化能力有限、对大量标记数据的依赖性强。Zhang 等人<sup>[15]</sup>提出了一种结合卷积神经网络 (Convolutional Neural Network, CNN) 和门控循环单元 (Gated Recurrent Unit, GRU) 的新型数据驱动异常驾驶行为识别方法, 其中 CNN 用于捕捉序列长期趋势中的非线性关系, 而 GRU 用于从驾驶参数中提取时间序列特征。Zhang 等人<sup>[16]</sup>提出了一种基于时间卷积神经网络 (Temporal Convolution Network, TCN) 的驾驶员行为识别方法, 该方法通过多层卷积和全连通层对车辆行为进行分类。CNN 和 TCN 虽能有效处理空间和时间数据, 但它们可能难以捕捉更复杂的时序依赖关系, 而且训练数据需求较大, 易受到过拟合的影响。Liu Z.Q.等人<sup>[17]</sup>引入了先验知识和后验知识, 提出了一种用于车辆行为识别的知识驱动长短期记忆神经网络 (Long Short-Term Memory, LSTM), 通过对 LSTM 网络在各时间点输出的自动学习得到的权重进行加权累加, 有效地挖掘了编码信息, 从而显著提升了对车辆变道意图的识别精度, 但该方法计算需要大量数据, 复杂度较高。Komol 等人<sup>[18]</sup>利用 LSTM 和 GRU, 结合来自合作感知消息的车辆动力学数据, 预测驾驶员在交叉口的意图动作。GRU 和 LSTM 提供了改进的时间序列数据处理能力, 但计算成本较高, 对实时处理的响应速度可能不足。由此可见, 尽管深度学习具备强大的自动特征提取能力, 但其对大量标记数据的依赖、模型解释性不足, 数据收集和标记过程耗时, 以及高计算资源需求和泛化能力问题限制了其的实际应用。

综上所述, 机器学习算法成为传统车辆行为识别领域的主流。尽管这些算法在某些方面表现出色, 但它们普遍存在特征选择繁琐费时的问题, 而且对新情境的适应性不足, 缺乏灵活性。此外, 这些方法在处理时间序列数据时表现不佳, 难以处理多维数据。因此在上述研究基础上, 本文将针对存在的问题和不足进一步研究车辆行为识别。

## 1.2.2 车辆轨迹预测研究现状

车辆轨迹预测作为自动驾驶和智能交通系统的关键技术之一,近年来获得了极大地发展,从最初基于物理模型的方法慢慢向基于行为模型、基于交互模型的方法转变,是一个技术栈丰富、方案多、难度大的智能驾驶核心任务。

技术发展初期主要基于物理模型的方法,如王艳阳等人<sup>[19]</sup>通过建立车辆运动学模型,结合预瞄控制与滑模控制方法,对不同车速和转向曲率下的预测误差进行分析,提高了在车辆行为不确定性影响下轨迹预测的精度。

而随着传感器技术、数据处理能力和人工智能算法的快速发展,研究逐渐转向更为基于行为模型的方法。例如,张一鸣等人<sup>[20]</sup>融合前车驾驶意图与车辆运动模型,有效提高了轨迹预测的准确性。Tomar 等人<sup>[21]</sup>通过 SVM 的全局唯一解决方案优势来识别横纵向预测误差,避免了多个局部最小值的问题,从而预测变道车辆的轨迹,提高了预测准确性。宋秀兰等人<sup>[22]</sup>则引入了时空融合多头注意力机制,通过门控机制结合 LSTM 编解码器来优化轨迹预测精度。此外,王雪阳等人<sup>[23]</sup>的研究表明,结合生成对抗网络和神经网络能够显著提高轨迹预测的效率和准确度。Altche Fd 等人<sup>[24]</sup>利用 LSTM 在 NGSIM US-101 数据集上进行训练,能够在未来几秒钟内准确预测横向和纵向车辆轨迹,提高了自动驾驶系统的安全性和效率。Ye N 等人<sup>[25]</sup>通过建立双层 HMM 来挖掘车辆历史轨迹的隐含状态序列,并预测了接下来阶段的轨迹。Sheng Z 等人<sup>[26]</sup>提出了一种基于图的时空卷积网络用于预测邻近车辆的未来轨迹分布。该网络通过图卷积网络处理空间交互,利用 CNN 捕捉时间特征,并通过 GRU 网络对时空特征进行编码和解码,生成未来轨迹分布。Chen 等人<sup>[27]</sup>提出了一种新型的空间-时间动态注意力网络,能够捕捉每个时间戳下的动态交互变化,并通过不同的序列模型来获取个体运动状态及其社交互动的时空相关性,用于车辆轨迹预测。Shi K 等人<sup>[28]</sup>提出了一种整合的深度学习基础的双维度车辆轨迹预测模型,设计了一种基于注意力机制、双向 LSTM 和 TCN 的切换神经网络结构,以模拟并预测轨迹。

这些方法虽然提高了预测的准确性和效率,但应对多变环境表现不足。为解决该问题,交互模型的研究逐渐成为热点,特别是在复杂交通场景下的轨迹预测。进一步的研究如 Li H 等人<sup>[29]</sup>提出的社会力模型约束的门控循环单元模型,通过融合物理模型与行为模型,有效捕捉车辆间的交互行为及其与周边环境的互动,从而精准预测车辆轨迹。但上述方法难以应对不同驾驶风格等不确定因素影响,存在预测精度和可靠性不足问题。

总之,车辆轨迹预测是一个多学科交叉、充满挑战的领域。在复杂的交通环境中,车辆轨迹预测能够帮助车辆做出更加安全和高效的决策,如换道、避障和路径规划等。这一技术

对于提高道路安全、优化交通流量、减少拥堵以及实现智能车辆的高效运行具有重要意义。在上述研究的基础上, 本文将针对车辆轨迹预测进行进一步探索, 旨在考虑驾驶风格不确定因素的影响, 提高预测精度和可靠性。

### 1.2.3 车辆轨迹规划研究现状

轨迹规划是自动驾驶技术的关键组成部分, 它在路径规划的基础上添加了时间维度, 允许对车辆的速度和加速度等进行控制, 其目的是确保目标车辆在指定区域内从起点到终点的行驶路线是安全且无碰撞的。依据对环境信息的掌握程度, 可将其分成全局和局部。全局轨迹规划在整个环境中确定车辆的最优路径, 而当环境发生变化时, 重新规划路径的成本相对较高。相反, 局部轨迹规划关注车辆当前周围的具体交通环境, 要求车辆具备即时的避障能力, 这通常需要车辆对局部环境信息进行实时更新, 对处理和计算能力的要求较高。初期轨迹规划侧重于全局路径的确定, 即在全面了解环境的情况下预设车辆的行进路线。但在动态变化的环境中, 这种方法的响应速度慢, 适应性较差。因此, 研究逐渐转向局部路径规划, 即在车辆行进中不断调整轨迹, 以应对即时的道路情况和周围环境的变化。在城市道路情况下, 换道轨迹规划更多地涉及到局部路径规划。

随着技术的发展, 轨迹规划不仅要考虑路径的安全性, 还需兼顾行驶效率等其他条件, 在这一背景下, 出现了多种技术方案来解决特定的问题和满足不同的限制条件。传统的基于优化的方法核心优势在于简单直观, 计算效率高, 适合处理动态变化的环境, 但其实时性和复杂环境适应性方面还有待提高。为解决这些问题, 研究者通常会结合其他路径规划技术, 或对势场模型和优化目标进行改进, 以提高规划的可靠性和效率。如陈浩等人<sup>[30]</sup>提出了一种改进的基于势场搜索的无人车动态避障轨迹规划算法, 通过调整斥力场的方向和引入距离衰减因素, 有效地克服了传统人工势场法面临的局部最小值陷阱和目标不可达的挑战。此外, 算法还融合了随机搜索的策略, 使得无人车能够在不断变化的环境中安全地规划出行驶轨迹。为了解决换道过程中的侧翻与碰撞风险, 黄子超等人<sup>[31]</sup>利用车辆通信技术结合人工势场和模型预测控制, 生成避障换道轨迹。机器学习在轨迹规划方面也有应用, Li A 等人<sup>[32]</sup>针对自动驾驶车辆与人驾驶车辆共享道路的背景, 通过 LSTM 建立了数据驱动的轨迹模型, 以生成类人驾驶轨迹, 能够准确模拟复杂交通环境中人类的驾驶行为, 但其依赖大量的高精度数据和较高的计算资源。此外, 基于曲线拟合的方法也广泛应用于轨迹规划, Yang D 等人<sup>[33]</sup>同时考虑舒适度与换道效率, 提出了一种基于三次多项式的优化轨迹规划算法, 但该方法难以应对场景的动态变化。也有人结合优化方法和曲线拟合方法来进行轨迹规划, 张一鸣等人<sup>[20]</sup>通过

利用贝塞尔曲线设计了一种高速公路场景下主车避撞轨迹规划方案,在构建目标函数时,综合考虑了与前车的碰撞风险概率、车速变化以及舒适性等关键因素,为了确保轨迹规划的可行性,采用序列二次规划技术对贝塞尔曲线的控制点及主车目标点的位置进行了精细优化,成功求解出了最佳避撞路径。Xiao J 等人<sup>[34]</sup>通过将轨迹规划问题解耦为路径规划和纵向速度规划两个子问题以简化难度,首先结合圆弧和直线生成无碰撞路径满足车辆运动学约束,并把路径设置成连续曲率,然后基于驾驶和制动系统性能约束,使用 B 样条曲线生成纵向速度,采用基于稳定性理论的非时间参考路径策略进行最优轨迹生成。

综上所述,目前车辆轨迹规划方法在提高安全性、效率和舒适性方面均有其优势,大部分研究集中在高速公路场景下,缺乏对城市道路或其他类型道路的适用性,且难以兼顾环境的实时动态性。因此,基于以上研究,本文将探索在城市道路的适用性,进一步优化提升车辆轨迹规划的实时动态响应能力。

### 1.3 主要研究内容

本文基于 1.2 节中对智能车辆行为识别、轨迹预测和轨迹规划领域研究现状进行深入剖析,针对目前智能车辆行为识别和安全轨迹研究中面临的问题展开具体地工作,概括如下:

(1) 针对传统车辆行为识别方法特征选择繁琐、时序数据和多维数据处理不佳的问题,提出一种混合高斯隐马尔可夫模型 (Mixed Gaussian Hidden Markov model, GM-HMM) 来识别城市道路上目标车辆的行为。该模型结合 HMM 的时间序列分析和高斯混合模型 (Gaussian mixture model, GMM) 的连续数据处理优势,通过利用 GMM 描述在特定隐状态下的观察数据分布以及 HMM 处理状态转换的能力,以提升识别精度与可靠性。最后仿真实验验证 GM-HMM 能够捕捉车辆行为的多样性和随时间的动态变化,有效准确地识别车辆行为。

(2) 针对车辆轨迹预测中难以应对不同驾驶风格等不确定因素影响,导致预测精度和可靠性不足问题。为了解决这一问题,使用 GMM 对轨迹进行聚类进行平均化处理得到不同换道风格的原型轨迹,利用高斯过程回归 (Gaussian Process Regression, GPR) 来预测未来的轨迹。与传统线性预测模型相比, GPR 通过考虑数据点之间的相关性来生成预测,能够更好地处理数据的不确定性问题。最后仿真实验验证该方法能够适应不同驾驶风格的影响,可以精确有效地预测出目标车辆轨迹,提高了预测精度和可靠性。

(3) 现有车辆轨迹规划研究集中在高速公路上,缺乏对城市道路或其他类型道路的适用性,且难以兼顾环境的实时动态性。为了解决以上问题,提出一种动态环境下基于圆形安全距离模型的城市道路主车最优轨迹规划方法,首先建立圆形安全距离模型,再结合前车的行

为轨迹，设计出合适的路线策略，利用五次多项式生成备选路径簇，最后通过构造综合评价指标函数来筛选智能车辆的最优轨迹，旨在避免与周围车辆碰撞以提高行驶过程中的安全性，规划出智能车辆安全高效的最优轨迹。最后仿真实验验证引入圆形安全距离模型后，该方法能够兼顾场景的实时动态性，并成功规划出了主车最优轨迹。

## 1.4 论文组织结构

本文一共分为 6 章，详细安排如下：

第一章：绪论。首先全面阐述了本文研究的背景与意义；其次，对车辆行为识别、车辆轨迹预测以及车辆轨迹规划的国内外研究现状进行了详尽的讨论，为后续研究提供了参考和帮助；最后，介绍了本文的研究内容和章节安排。

第二章：相关背景知识介绍。详细阐述了 HMM 和 Prescan 的基础知识、以及当前车辆轨迹预测和规划方法，为后续的模型建立和仿真实验打下坚实的理论基础。

第三章：基于 GM-HMM 的城市道路车辆行为识别。针对传统车辆行为识别方法在特征选择、时序数据和多维数据处理方面存在的问题，提出采用 GM-HMM 来识别城市道路上智能车辆的行为，对前车车辆行为进行识别研究。首先，通过从 Prescan 平台仿真获得的城市三车道道路场景数据中提取前车关键特征参数，并运用 Baum-Welch 算法对模型参数进行优化；其次，结合前后向算法识别前车行为；最后，通过仿真实验对该模型进行验证。

第四章：基于 GPR 的不同换道风格前车轨迹预测。在已知前车行为的情况下，考虑到驾驶风格这一不确定因素影响，进一步研究前车不同换道风格下的轨迹预测精度和可靠性，为规划主车最优安全轨迹奠定基础。从仿真数据集中筛选前车的经典换道轨迹，以横向加速度、航向角为聚类特征，使用高斯混合模型聚类出不同换道风格的原型轨迹，并根据 GPR 来获得预测轨迹，以指导主车进行安全换道。最后，通过实验分析对预测轨迹进行验证。

第五章：车辆安全换道模型及其最优轨迹规划。首先，在成功预测前车行为与轨迹的基础上，鉴于主车在行驶过程中受到周围车辆影响，需判断能否安全换道的问题，构建基于主车的圆形安全距离模型以提高实时动态性，考虑周围车道车辆的状态和前车的行为轨迹来设计换道策略。通过五次多项式生成换道备选路径簇，并充分考虑安全性、舒适性、效率，通过多目标综合评价指标函数选出最优轨迹。最后，通过分析车辆在不同工况下的仿真实验，对轨迹规划的结果进行检验。

第六章：总结与展望。对全文所做工作进行总结；并在此基础上，提出未来研究方向。



## 第二章 相关背景知识介绍

本章通过相关背景知识介绍，旨在为城市道路智能车辆行为识别与安全轨迹的研究提供坚实的理论与技术基础。首先，本章简介了隐马尔可夫模型（HMM），该统计模型能有效处理时序数据并自动学习数据特征，特别适用于解析车辆行为的动态特性和不可观测状态，这对于车辆行为识别尤为重要。接着，本章介绍了 Prescan 仿真平台，该平台为研究提供了一个高度精确的城市三车道道路交通环境模拟，能够生成和分析复杂的交通场景数据，为城市道路车辆行为识别和安全轨迹研究提供实验基础，使得从理论到实际应用的过渡更为可靠和有效。由于车辆行为识别方法大多采用机器学习，在上一章节研究现状中已有描述，故本章不再赘述。进一步地，本章讨论了车辆轨迹预测的多种方法，这些方法对提升智能车辆对未来环境适应性及安全性方面具有重要作用。此外，最后本章探讨了车辆轨迹规划的方法，这些技术关乎智能车辆如何在复杂环境中安全有效地导航。

### 2.1 隐马尔可夫模型

#### 2.1.1 HMM 简介

HMM 是一种重要的统计模型，用于描述一个系统在不可观测的隐含状态序列中的转换过程。与传统马尔可夫模型不同的是，HMM 中的状态是不直接可见的，称之为“隐状态”，但可以通过分析与这些状态相关的观测数据来间接地推断出它们。系统的观测数据，则是由这些隐状态根据一定的概率分布生成的。观测序列便是能够直接获取的数据序列，如通过传感器采集到的车辆位移和速度信息，而这些信息背后的驾驶行为状态（如左换道、右换道或直行）则构成了隐状态序列。HMM 在时间序列数据分析中发挥着关键作用，因其独特的建模方法，使其在多个领域内得到了广泛的应用，如语音识别、生物信息学、金融市场分析以及自动驾驶技术中的车辆行为识别等。

HMM 基于两个假设来对观测事件的概率建模：

(1) 齐次马尔可夫假设：当前时刻隐状态仅受上一时刻的状态影响，确保了模型的状态转移的简洁性和可计算性。

(2) 观测独立性假设：任何时刻的观测仅依赖于当前时刻的状态，保证了模型对当前状态信息的准确捕捉，而不受历史状态的直接影响<sup>[35]</sup>。

在智能交通系统中，准确地识别和预测车辆行为对于提高行车安全性和效率至关重要。HMM 通过对车辆观测数据的分析，使得能够理解和预测车辆可能的行为模式。具体来说，HMM 利用状态转移概率矩阵来描述不同隐状态之间的转移规律，以及观测概率矩阵来描述每个隐状态下观测数据出现的概率。通过这两个概率矩阵，结合初始状态分布，HMM 提供了一种系统性的方法来推断出最可能的隐状态序列，进而对车辆行为进行识别和预测。

HMM 结构为  $\lambda = \{E, F, A, B, \pi\}$ ，各参数意义见表 2.1。由于  $B$  决定观测序列， $A$  和  $\pi$  决定状态序列，一般简写成  $\lambda = \{A, B, \pi\}$ 。

表 2.1 HMM 参数表

参数	含义	表达式	相关阐述
$E$	隐含状态数量	$Q = \{q_1, q_2, \dots, q_E\}, q_i \in Q$	隐含状态集合 $Q = \{q_1, q_2, \dots, q_E\}$ ， $t$ 时刻所处状态为 $S_t = q_i$ ，其中 $q_i$ 是隐状态的取值之一
$F$	观测状态数量	$V = \{v_1, v_2, \dots, v_F\}, v_k \in V$	观测集合 $V = \{v_1, v_2, \dots, v_F\}$ ， $t$ 时刻观测状态为 $O_t = v_k$ ，其中 $v_k$ 是观测的取值之一
$A$	状态转移概率矩阵	$A = \{a_{ij}\}_{E \times E}, 1 \leq i, j \leq E$ $a_{ij} = P(S_{t+1} = q_j   S_t = q_i)$	$a_{ij}$ 表示在 $t$ 时刻处于状态 $q_i$ 的条件下，在 $t+1$ 时刻转移至状态 $q_j$ 的概率
$B$	观测值概率矩阵	$B = \{b_j(k)\}_{E \times F}, 1 \leq j \leq E, 1 \leq k \leq F$ $b_j(k) = P(O_t = v_k   S_t = q_j)$	$b_j(k)$ 表示在 $t$ 时刻处于 $q_j$ 状态的条件下生成观测 $v_k$ 的概率
$\pi$	初始状态概率向量	$\pi = \{\pi_1, \pi_2, \dots, \pi_E\}$ , $\pi_i = P(S_1 = q_i), 1 \leq i \leq E$	$\pi_i$ 表示在 $t=1$ 时刻处于状态 $q_i$ 的概率

HMM 每个时间步都有两组对应的变量，如图 2.1 所示，左侧为隐状态， $S_t = q_i$  是系统在  $t$  时刻的隐状态，取值集合记为  $S$ ；右侧为观测状态， $O_t = v_k$  是系统在  $t$  时刻的观测，取值集合记为  $O$ 。




图 2.1 HMM 结构示意图

给定  $\lambda$  和长度为  $T$  的状态序列  $S=\{S_1, S_2, \dots, S_T\}$ ，则其对应观测序列  $O=\{O_1, O_2, \dots, O_T\}$  的生成步骤如下：

- (1) 初始状态设置：由初始状态分布  $\pi$  产生状态  $S_1=q_i$ ；
- (2) 时间步  $t$  的设置：令  $t=1$ ；
- (3) 观测生成：根据状态  $S_t=q_i$  的观测概率分布  $b_i(k)$  生成  $O_t=v_k$ ；
- (4) 状态转移：根据状态  $S_t$  的状态转移概率分布  $a_{ij}$  产生下一个状态  $S_{t+1}=q_j$ ；
- (5) 更新时间步：令  $t=t+1$ ，若  $t < T$ ，转到 (3)；否则终止生成并输出  $O$ 。

通过这一过程，HMM 能够生成与实际观测数据相吻合的状态序列，进而用于诸如车辆行为的分析识别与预测。

### 2.1.2 HMM 基本问题

在 HMM 的实际应用中，定义隐马尔可夫模型  $\lambda$ ，隐状态序列  $S$ ，观测序列  $O$ ，观测序列概率  $P(O|\lambda)$ ，则一般聚焦于以下三个基本问题：

- (1) 概率计算：已知  $\lambda$  和  $O$ ，计算  $P(O|\lambda)$ ，即如何评估模型和观测序列的匹配程度<sup>[36]</sup>。

解决算法：前后向算法。

- (2) 解码：已知  $\lambda$  和  $O$ ，求让  $P(S|O)$  最大的  $S$ ，即如何找到和此观测序列最匹配的隐状态序列<sup>[37]</sup>。

解决算法：Viterbi 算法。

- (3) 参数学习：已知  $O$ ，调整估计  $\lambda$ ，使得  $P(O|\lambda)$  最大，即如何训练模型使其能最好的匹配描述观测数据。

解决算法：Baum-Welch 算法。

### 2.1.3 HMM 解决算法

#### 一、前后向算法

虽然可以通过遍历所有可能的隐状态序列来计算  $P(O|\lambda)$ ，但这种方法在序列长度增加时会遇到计算量指数增长的问题。为了解决这一问题，前向算法和后向算法采用了递归计算的策略，有效降低了运算复杂性。

##### a). 前向算法

定义前向概率：

$$\alpha_t(i) = P(O_1 O_2 \cdots O_t, S_t = q_i | \lambda) \quad (2.1)$$

式中,  $P(O_1 O_2 \cdots O_t, S_t = q_i | \lambda)$  表示已知  $\lambda$ , 到  $t$  时刻前观测序列为  $O_1, O_2, \dots, O_t$  且状态为  $q_i$  的概率。

前向算法过程如下:

(1) 利用初始概率矩阵初始化前向概率。

$$\alpha_1(i) = \pi_i b_i(O_1), \quad 1 \leq i \leq E \quad (2.2)$$

其中,  $\pi_i$  表示初始时刻状态为  $q_i$  的概率;  $E$  为隐含状态的数量;  $b_i(O_1)$  是在状态  $q_i$  下产生观测  $O_1$  的概率;  $\alpha_1(i)$  是初始时刻观测为  $O_1$  且状态为  $S_t = q_i$  的联合概率。

(2) 递推求前向概率。

前向概率是联合概率, 根据累加原理可知:

$$\alpha_{t+1}(j) = \left[ \sum_{i=1}^E \alpha_t(i) a_{ij} \right] b_j(O_{t+1}), \quad 1 \leq t \leq T-1, 1 \leq j \leq E \quad (2.3)$$

式中,  $\alpha_{t+1}(j)$  为到  $t+1$  时观测到  $O_1, O_2, \dots, O_t, O_{t+1}$  且状态为  $q_j$  的前向概率;  $b_j(O_{t+1})$  是在状态  $q_j$  下产生观测  $O_{t+1}$  的概率;  $\alpha_t(i) a_{ij}$  是到  $t$  时观测到  $O_1, O_2, \dots, O_t$  且状态为  $q_i$  而在  $t+1$  时为  $q_j$  的联合概率<sup>[38]</sup>。

(3) 终止, 计算观测序列概率。

如果观察结果的长度为  $T$ , 很容易得到  $P(O|\lambda)$ :

$$\alpha_T(i) = P(O_1 O_2 \cdots O_T, S_T = q_i | \lambda) \quad (2.4)$$

$$P(O | \lambda) = \sum_{i=1}^E \alpha_T(i) \quad (2.5)$$

综上所述, 前向算法之所以高效, 是因为它采取了逐步计算的策略来推导出  $P(O|\lambda)$ 。该算法利用了状态序列的路径依赖性, 通过在每个时间步对  $E$  个可能状态进行局部计算, 并将每个状态在  $t$  时刻的计算结果作为下一时间步计算的基础, 从而避免了重复的计算工作。这样, 计算复杂度从直接计算的  $O(TE^T)$  降低到了  $O(E^2T)$ , 显著减少了所需的计算资源。

#### b). 后向算法

与前向算法相反, 定义后向概率:

$$\beta_t(i) = P(O_{t+1} O_{t+2} \cdots O_T | S_t = q_i, \lambda) \quad (2.6)$$

式中,  $P(O_{t+1} O_{t+2} \cdots O_T | S_t = q_i, \lambda)$  表示已知  $\lambda$ , 在  $t$  时刻状态为  $q_i$  的条件下, 从  $t+1$  到  $T$  的观测序列为  $O_{t+1}, O_{t+2}, \dots, O_T$  的概率<sup>[39]</sup>。

后向算法过程如下：

(1)初始化。

$$\beta_T(i) = 1, \quad 1 \leq i \leq E \quad (2.7)$$

式中， $\beta_T(i)$  表示后向概率的初值，对最终时刻的所有状态  $q_i$  设置  $\beta_T(i) = 1$ 。

(2)递推求后向概率。

后向概率的计算从观测序列的末端开始逆向进行，已知  $t+1$  至  $T$  时刻的观测结果，但在  $t$  时刻观测结果  $O_t$  是未知的，由公式(2.6)形式推导可得：

$$\beta_{t-1}(i) = P(O_t O_{t+1} \cdots O_T | S_{t-1} = q_i, \lambda) \quad (2.8)$$

通过这种方式，在这种逆向计算过程中逐步构建从序列末端到当前时刻的状态概率，即使在缺乏某些时刻具体观察信息的情况下，也能有效地进行计算。这不仅提升了计算效率，还便于对整个序列进行综合性的理解和分析。

假设  $t-1$  时刻隐状态为  $q_i$ 、 $t$  时刻隐状态为  $q_j$ ，则  $\beta_{t-1}(i)$  能分成两部分，第一部分是观测结果为  $O_t$  的概率  $a_{ij}b_j(O_t)$ ，第二部分是  $t$  时刻隐状态为  $q_j$  且观测结果  $O_{t+1}, O_{t+2}, \dots, O_T$  的概率  $\beta_t(j)$ ，利用乘法定理可知，此时的概率为  $a_{ij}b_j(O_t)\beta_t(j)$ 。

而  $t$  时刻隐含状态可能性有  $E$  个，根据加法原理可得：

$$\beta_t(i) = \sum_{j=1}^E a_{ij}b_j(O_{t+1})\beta_{t+1}(j), 1 \leq t \leq T-1, 1 \leq j \leq E \quad (2.9)$$

式中， $\beta_{t+1}(j)$  为到  $t+1$  时观测到  $O_1, O_2, \dots, O_t, O_{t+1}$  且状态为  $q_j$  的后向概率。

(3)终止，计算观测序列概率。

由上面推导可递归得到  $\beta_1(i)$ ：

$$\beta_1(i) = P(O_2 O_3 \cdots O_T | S_1 = q_i, \lambda) \quad (2.10)$$

在  $t=1$  时刻，从隐状态  $q_i$  得到  $O_1$  的概率为：

$$P(O_1)P(O_2, O_3, O_4, \dots, O_T | S_1 = q_i, \lambda) = \pi_i b_i(O_1) \beta_1(i) \quad (2.11)$$

由加法原理可知后向算法  $P(O|\lambda)$  为：

$$P(O | \lambda) = \sum_{i=1}^E \pi_i b_i(O_1) \beta_1(i) \quad (2.12)$$

后向概率的初始概率为  $\beta_T(i)$ ，可以表示为：

$$\beta_T(i) = P(O_{T+1} | S_T = q_i) \quad (2.13)$$

c).前后向算法

根据前向概率与后向概率的定义得：

$$P(O | \lambda) = \sum_{i=1}^E \sum_{j=1}^E \alpha_i(i) a_{ij} b_j(O_{t+1}) \beta_{t+1}(j), t = 1, 2, \dots, T-1 \quad (2.14)$$

d).概率和期望的计算

(1)已知  $\lambda$  和  $O$ ，求在时刻  $t$  处于状态  $q_i$  的概率。

记  $\gamma_t(i) = P(S_t = q_i | O, \lambda)$ ，则有：

$$\gamma_t(i) = P(S_t = q_i | O, \lambda) = \frac{P(S_t = q_i, O_t | \lambda)}{P(O_t)} \quad (2.15)$$

$P(S_t = q_i, O_t | \lambda)$  为在  $t$  时刻，隐状态为  $q_i$  且观察结果为  $O_t$  的概率。观测序列  $O$  可分为  $O_1, O_2, \dots, O_t$  和  $O_{t+1}, O_{t+2}, O_{t+3}, \dots, O_T$  两部分。前半段可用前向概率  $\alpha_t(i)$  表示，后半段可用后向概率  $\beta_t(i)$  表示，根据前向和后向概率的定义，利用乘法原理可知联合概率分布为：

$$P(S_t = q_i, O | \lambda) = \alpha_t(i) \beta_t(i) \quad (2.16)$$

所以：

$$\gamma_t(i) = \frac{\alpha_t(i) \beta_t(i)}{P(O | \lambda)} = \frac{\alpha_t(i) \beta_t(i)}{\sum_{j=1}^E \alpha_t(j) \beta_t(j)} \quad (2.17)$$

(2)已知  $\lambda$  和  $O$ ，求在  $t$  时状态为  $q_i$  且在  $t+1$  时为  $q_j$  的概率<sup>[40]</sup>。

记  $\xi_t(i, j) = P(S_t = q_i, S_{t+1} = q_j, O | \lambda)$ ，利用前向后向概率计算：

$$\xi_t(i, j) = \frac{P(S_t = q_i, S_{t+1} = q_j, O | \lambda)}{P(O | \lambda)} = \frac{P(S_t = q_i, S_{t+1} = q_j, O | \lambda)}{\sum_{i=1}^E \sum_{j=1}^E P(S_t = q_i, S_{t+1} = q_j, O | \lambda)} \quad (2.18)$$

$$P(S_t = q_i, S_{t+1} = q_j, O | \lambda) = \alpha_t(i) a_{ij} b_j(O_{t+1}) \beta_{t+1}(j) \quad (2.19)$$

$$\xi_t(i, j) = \frac{\alpha_t(i) a_{ij} b_j(O_{t+1}) \beta_{t+1}(j)}{\sum_{i=1}^E \sum_{j=1}^E \alpha_t(i) a_{ij} b_j(O_{t+1}) \beta_{t+1}(j)} \quad (2.20)$$

(3)给定  $O$ ，将  $\gamma_t(i)$ 、 $\xi_t(i, j)$  对各个时刻  $t$  求和，可得状态  $i$  出现的期望值  $\sum_{t=1}^T \gamma_t(i)$ ，状态

$i$  转移的期望值  $\sum_{t=1}^{T-1} \gamma_t(i)$ ，状态  $i$  转移到  $j$  的期望值  $\sum_{t=1}^{T-1} \xi_t(i, j)$ 。

## 二、Baum-Welch 算法

HMM 的参数学习问题可通过监督学习或非监督学习解决，具体取决于是否同时提供隐状态序列  $S$  与观测序列  $O$  的数据。若训练数据包括  $O$  和对应的  $S$ ，则采用监督学习方法，即用极大似然估计参数；若只有  $O$  无对应的  $S$ ，则适用非监督学习 Baum-Welch 算法（即 Expectation-Maximization algorithm, EM 算法）<sup>[41]</sup>，本文将简介该方法。

若已知  $S$  和  $O$ ，那么 HMM 实际上是包括隐变量的概率模型：

$$P(O | \lambda) = \sum_S P(O | S, \lambda) P(S | \lambda) \quad (2.21)$$

(1) 确定完整序列的对数似然函数。

完整序列由观测序列和隐状态序列组成  $(O, S) = (O_1, O_2, \dots, O_T, S_1, S_2, \dots, S_T)$

其对数似然函数：

$$Q(\lambda, \bar{\lambda}) = \sum_S \log P(O, S | \lambda) P(O, S | \bar{\lambda}) \quad (2.22)$$

(2) EM 算法的 E 步：求 Q 函数  $Q(\lambda, \bar{\lambda})$ 。

$$P(O, S | \lambda) = \pi_{s_1} b_{s_1}(O_1) a_{s_1 s_2} b_{s_2}(O_2) \cdots a_{s_{T-1} s_T} b_{s_T}(O_T) \quad (2.23)$$

$$Q(\lambda, \bar{\lambda}) = \sum_S \log \pi_{s_1} P(O, S | \bar{\lambda}) + \sum_S \left( \sum_{t=1}^{T-1} \log a_{s_t s_{t+1}} \right) P(O, S | \bar{\lambda}) + \sum_S \left( \sum_{t=1}^T \log b_{s_t}(O_t) \right) P(O, S | \bar{\lambda}) \quad (2.24)$$

(3) EM 算法的 M 步：极大化  $Q(\lambda, \bar{\lambda})$  求模型参数  $A, B, \pi$ 。

第一项可写成：

$$\sum_S \log \pi_{s_1} P(O, S | \bar{\lambda}) = \sum_{i=1}^E \log \pi_i P(O, S_1 = i | \bar{\lambda}) \quad (2.25)$$

由约束条件  $\sum_{i=1}^E \pi_i = 1$ ，利用拉格朗日乘子：

$$\sum_{i=1}^E \log \pi_i P(O, S_1 = i | \bar{\lambda}) + \gamma \left( \sum_{i=1}^E \pi_i - 1 \right) \quad (2.26)$$

令偏导为 0：

$$\frac{\partial}{\partial \pi_i} \left[ \sum_{i=1}^E \log \pi_i P(O, S_1 = i | \bar{\lambda}) + \gamma \left( \sum_{i=1}^E \pi_i - 1 \right) \right] = 0 \quad (2.27)$$

$$P(O, S_1 = i | \bar{\lambda}) + \gamma \pi_i = 0 \quad (2.28)$$

$$\gamma = -P(O | \bar{\lambda}) \quad (2.29)$$

$$\pi_i = \frac{P(O, S_1 = i | \bar{\lambda})}{P(O | \bar{\lambda})} \quad (2.30)$$

第二项可写成：

$$\sum_S \left( \sum_{t=1}^{T-1} \log a_{S_t S_{t+1}} \right) P(O, S | \bar{\lambda}) = \sum_{i=1}^E \sum_{j=1}^E \sum_{t=1}^{T-1} \log a_{ij} P(O, S_t = i, S_{t+1} = j | \bar{\lambda}) \quad (2.31)$$

由约束条件  $\sum_{j=1}^E a_{ij} = 1$ ，利用拉格朗日乘子得：

$$a_{ij} = \frac{\sum_{t=1}^{T-1} P(O, S_t = i, S_{t+1} = j | \bar{\lambda})}{\sum_{t=1}^{T-1} P(O, S_t = i | \bar{\lambda})} \quad (2.32)$$

第三项可写成：

$$\sum_S \left( \sum_{t=1}^T \log b_{S_t}(O_t) \right) P(O, S | \bar{\lambda}) = \sum_{j=1}^E \sum_{t=1}^T \log b_j(O_t) P(O, S_t = j | \bar{\lambda}) \quad (2.33)$$

由约束条件  $\sum_{k=1}^F b_j(k) = 1$ ，利用拉格朗日乘子得：

$$b_j(k) = \frac{\sum_{t=1}^T P(O, S_t = j | \bar{\lambda}) S(O_t = v_k)}{\sum_{t=1}^T P(O, S_t = j | \bar{\lambda})} \quad (2.34)$$

将得到的概率分别用  $\gamma_t(i)$ 、 $\xi_t(i, j)$  表示：

$$a_{ij} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \quad (2.35)$$

$$b_j(k) = \frac{\sum_{t=1, O_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)} \quad (2.36)$$

$$\pi_i = \gamma_1(i) \quad (2.37)$$



Baum-Welch 算法流程如下:

(1)初始化。对  $n=0$ , 选取  $a_{ij}^{(0)}, b_j(k)^{(0)}, \pi_i^{(0)}$ , 得到模型  $\lambda^{(0)} = \{A^{(0)}, B^{(0)}, \pi^{(0)}\}$ 。

(2)递推。对  $n=1, 2, \dots$ ,

$$a_{ij}^{(n+1)} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)} \quad (2.38)$$

$$b_j(k)^{(n+1)} = \frac{\sum_{t=1, O_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)} \quad (2.39)$$

$$\pi_i^{(n+1)} = \gamma_1(i) \quad (2.40)$$

(3)终止。得到模型  $\lambda^{(n+1)} = \{A^{(n+1)}, B^{(n+1)}, \pi^{(n+1)}\}$ 。

### 三、预测算法 Viterbi

在 HMM 中, Viterbi 算法是一种动态规划算法, 其目的为找到最可能的状态序列<sup>[42]</sup>, 这个序列称为最优路径, 它解释了观测数据序列的产生。算法通过构建一个路径概率图, 每一步计算到达每个状态的最高概率, 并记录每个状态的前一个最优状态。最终, 它通过回溯这些记录, 从终态向初态追踪, 确定最可能的隐含状态序列, 其中一条路径对应着一个状态序列。

Viterbi 算法流程:

(1)初始化。

$$\delta_1(i) = \pi_i b_i(O_1), \quad i = 1, 2, \dots, E \quad (2.41)$$

$$\psi_1(i) = 0, \quad i = 1, 2, \dots, E \quad (2.42)$$

(2)递推。对  $t=2, 3, \dots, T$

$$\delta_t(i) = \max_{1 \leq j \leq E} [\delta_{t-1}(j) a_{ji}] b_i(O_t), \quad i = 1, 2, \dots, E \quad (2.43)$$

$$\psi_t(i) = \arg \max_{1 \leq j \leq E} [\delta_{t-1}(j) a_{ji}], \quad i = 1, 2, \dots, E \quad (2.44)$$

(3)终止。

$$P^* = \max_{1 \leq i \leq E} \delta_T(i) \quad (2.45)$$

$$i_T^* = \arg \max_{1 \leq i \leq E} [\delta_T(i)] \quad (2.46)$$

(4)最优路径回溯。对  $t=T-1, T-2, \dots, 1$

$$i_t^* = \psi_{t+1}(i_{t+1}^*) \quad (2.47)$$

求得最优路径  $I^* = (i_1^*, i_2^*, \dots, i_T^*)$ 。

综上所述，三个算法的关系如图 2.2 所示。Baum-Welch 算法首先用于训练模型参数，使其能够更好地拟合实际观测数据。一旦模型参数被学习，前向后向算法可以计算给定这些参数时，任何观察序列出现的概率。而 Viterbi 算法则使用这些参数来推断最可能的隐含状态序列，从而实现对车辆行为的最准确判断。利用这些算法能够构造车辆行为识别系统，通过不断学习和调整，提高系统对复杂交通环境的适应能力和预测精确性。

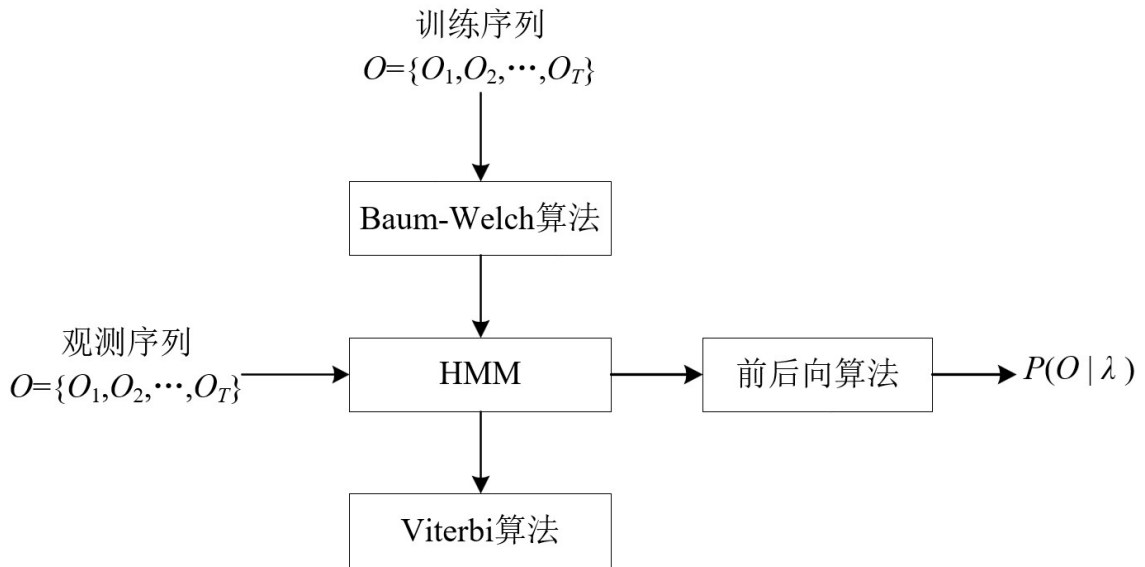


图 2.2 HMM 基本问题的解决算法关系

## 2.2 仿真平台简介

随着自动驾驶技术的飞速发展，对仿真测试环境的需求日益增长。Prescan 是西门子公司汽车驾驶仿真软件，为 ADAS 和智能车辆系统开发提供了一个基于物理模型的仿真平台。这个平台特别设计来支持包括摄像头、雷达、激光雷达、GPS，以及 V2V 和 V2I 车辆通信等多种技术的开发和应用。依托于 MATLAB 仿真环境，Prescan 成为了研究和开发 ADAS 及自动驾驶系统不可或缺的工具，其强大的功能覆盖了从雷达到车路通讯等各种智能驾驶技术应用的仿真需求。Prescan 作为一款先进的仿真平台，专为自动驾驶和车辆动态研究而设计。Prescan 平台能够提供高精度的物理模型和丰富的场景库，帮助工程师和研究人员在虚拟环境中测试和验证自动驾驶算法和车辆控制策略，从而确保技术在应用到实际车辆之前的安全性和有效性。

### 2.2.1 Prescan 的仿真流程

Prescan 的使用过程被划分为四个主要步骤：场景搭建、传感器添加、控制系统集成以及仿真运行，如图 2.3 所示。

首先，在场景搭建阶段，Prescan 提供了丰富的图形编辑工具和元素库，使用户能够创建包含各种交通标识、建筑物、交通参与者以及不同天气条件和光源设置的详细仿真环境。此外，最新版本的 Prescan 支持导入 OpenDrive 格式的高精度地图，进一步提高仿真的真实度。

传感器添加阶段，则允许用户配置和添加多种类型的传感器，包括但不限于激光雷达、毫米波雷达、超声波雷达及各种摄像头。这些传感器模型能够精确模拟真实设备的物理属性，为自动驾驶系统的测试提供了高度的准确性。

在控制系统集成方面，Prescan 允许通过 MATLAB/Simulink 建立复杂的控制模型，并可与 CarSim、VI-Grade、dSpace ASM 等第三方动力学模型进行集成，支持模型在环、软硬件在环等多种仿真模式。

最后，通过 3D 可视化查看器，用户不仅可以从多角度审视和分析仿真结果，还能生成图片和动画。此外，Prescan 还提供了与 ControlDesk 和 LabView 等工具的接口，以便于批量运行仿真场景和执行硬件在环仿真。

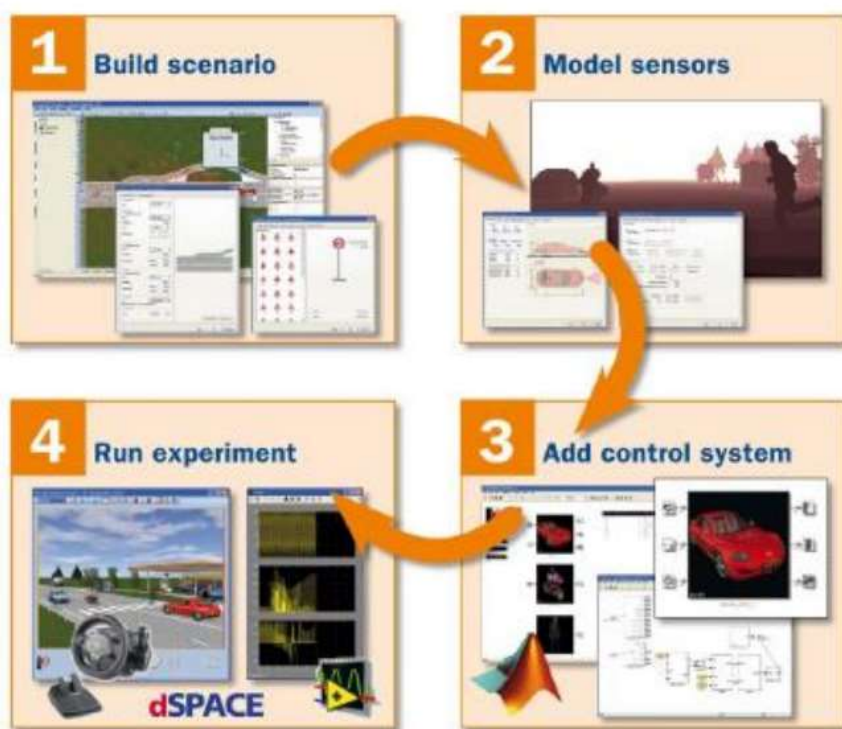


图 2.3 PreScan 搭建仿真模型的步骤

### 2.2.2 主要特性和应用场景

**Prescan** 的环境建模功能非常强大，允许用户创建包含复杂道路、交通标识和动态元素的真实仿真场景。其传感器模型精度高，能够准确模拟各种传感器的工作原理和性能限制。车辆动力学模型也极为详细，为仿真提供了坚实的物理基础。

#### (1) 主要特性

**高度可配置的环境建模：****Prescan** 允许用户创建复杂的道路几何形状、交通标志和信号灯配置。这包括城市道路、高速公路以及各种交叉口。此外，它还支持动态环境元素，如其他车辆、行人和自行车，这对于模拟复杂的交通情况至关重要。

**物理精确的传感器模型：**为了测试自动驾驶系统，**Prescan** 提供了一系列高度真实的传感器模型，包括雷达、激光雷达、摄像头和超声波传感器。这些模型能够模拟真实传感器的物理属性和限制，包括噪声、分辨率和检测范围，从而使仿真结果更加准确可靠。

**先进的车辆动力学模型：****Prescan** 内置了高度详细的车辆动力学模型，能够精确模拟车辆在各种条件下的行为。这包括复杂的轮胎模型、悬挂系统、刹车和动力总成。用户可以根据需要调整这些模型的参数，以适应特定车辆的特性。

**集成开发环境：****Prescan** 提供了一个完整的开发环境，包括用于模型构建、脚本编写、仿真执行和结果分析的工具。它支持与 Matlab/Simulink 等其他工程软件的集成，使得开发自动驾驶算法更加灵活和高效。

#### (2) 应用场景

这些特性使 **Prescan** 在多个应用场景中发挥了重要作用。无论是开发和验证自动驾驶算法、设计车辆控制系统，还是进行交通流和安全性研究，**Prescan** 都能提供高效、安全的仿真环境，加速从理论到实际应用的转化过程。

**自动驾驶算法开发和验证：**通过在仿真环境中测试，研究人员可以在没有实际风险的情况下，验证自动驾驶算法的性能，包括路径规划、障碍物检测和避让、车道保持等功能。

**车辆控制系统设计：****Prescan** 可以用来开发和测试各种车辆控制系统，如自适应巡航控制、紧急制动系统和车辆稳定性控制。这有助于优化系统参数，提高车辆的安全性和舒适性。

**交通流和安全研究：**通过模拟大规模的交通场景，**Prescan** 可以用于研究不同的交通管理策略对流量和安全的影响。这对于城市规划和道路设计有重要意义。

### 2.2.3 仿真平台小结

作为自动驾驶和车辆动态研究的高级仿真平台，Prescan 不仅提供了精确的环境建模和传感器模拟能力，还支持复杂的车辆动力学和控制系统开发。通过使用 Prescan，研究人员和工程师可以在安全的虚拟环境中测试和验证他们的技术，加速自动驾驶系统从理论到实际应用的转化过程。随着自动驾驶技术的持续进步，Prescan 及其类似平台的重要性将进一步提升，为自动驾驶系统的发展提供强有力的技术支持。

## 2.3 车辆轨迹预测方法

智能车辆的轨迹预测技术是确保交通安全和提升行驶效率的关键环节。车辆轨迹预测方法主要可以分为基于物理模型、行为模型和交互模型三大类。

### 2.3.1 基于物理模型的轨迹预测

物理模型主要依据车辆运动学和动力学特性来预测车辆的运动轨迹。基于车辆运动学的轨迹预测侧重于车辆在理想条件下的运动，通常不考虑车辆的动力学特性和外部环境因素对车辆的影响，考虑因素包括速度、加速度和转向率等，目标是找到一条可行且安全的路径来实现预定的目标点或轨迹。基于车辆动力学的轨迹预测则更加复杂，不仅要考虑车辆自身的运动特性，如发动机输出、轮胎抓地力和摩擦等因素，还要考虑外部环境因素，如道路状况、交通情况和障碍物等，以确保车辆在执行轨迹时能够安全稳定地运行。

物理模型的优点在于结构简单，计算效率高，适用于短期预测。然而，由于忽略了驾驶员行为的不确定性和复杂交通环境的影响，物理模型在长期预测中的准确性有限。近年来，物理模型的研究主要集中在提高模型的适应性和预测精度。例如，面对车载传感器误差引发的轨迹预测不确定性，高斯模型通过假设车辆运动状态服从正态分布，并利用这些概率分布的参数进行轨迹建模，是一种典型的物理模型。此外，在轨迹预测中，卡尔曼滤波算法和蒙特卡洛方法常与物理模型相结合，应用于处理模型不确定性和噪声干扰问题。

### 2.3.2 基于行为模型的轨迹预测

行为模型专注于理解驾驶员的行为特征与决策过程，旨在通过分析驾驶意图与行为模式，预测车辆未来轨迹，相较于物理模型，在进行长期预测时，它能提供更相关和可靠的轨迹信

息。主要有基于原型轨迹、结合机器学习、基于驾驶意图和数据驱动的三种轨迹预测方法。

原型轨迹是平均化处理后最具代表性的轨迹模式。通过识别车辆最可能遵循的运动模式，并利用相应的原型轨迹来预测未来的移动情况，能够对车辆的局部轨迹进行在线有效预测。

近年来，行为模型的研究获得了显著进展，特别是将机器学习技术包括 SVM、HMM 和各种神经网络等深度学习框架广泛应用于解析驾驶行为并预测轨迹，这些模型能够自动从大数据中学习到复杂的特征，从而提升预测的准确率和系统的鲁棒性。

为实现更为精准的长期轨迹预测，越来越多的研究将焦点转向基于驾驶意图和数据驱动的预测方法。该方法首先挖掘车辆历史数据中的行为特征识别驾驶意图，再通过数据驱动的方式分析包括车辆状态及其他环境因素来进行轨迹预测。虽然该方法在处理长期预测问题方面表现优异，但它们对于大量、高质量的历史数据依赖性较强，另外驾驶者之间行为的个体差异性以及驾驶风格等不确定性因素增加了轨迹预测的难度。

### 2.3.3 基于交互模型的轨迹预测

交互模型考虑车辆与环境以及其他车辆之间的相互作用，通常采用多智能体系统理论，结合社会力模型、博弈论等方法来模拟复杂的交通交互行为，通过分析场景中的交互关系来预测各车辆的未来轨迹<sup>[29]</sup>。这类模型在处理复杂交通场景时表现出较好的适应性，但模型构建和参数调整的难度较大。

### 2.3.4 车辆轨迹预测小结

尽管车辆轨迹预测技术取得了一定的进展，但仍面临诸多挑战。例如，如何提高模型在复杂多变交通环境下的泛化能力和预测精度，如何处理大规模实时数据，以及在如驾驶风格等不确定因素下如何确保预测模型的可靠性等。未来的研究方向可能包括：（1）利用更先进的深度学习算法和大数据分析技术，提高模型的学习泛化能力和预测精度。（2）结合物理模型、行为模型和交互模型的优势，发展混合型轨迹预测模型，以期更好地捕捉车辆间的相互作用和交通流的整体特性，获得更准确的预测结果。（3）探索跨模态数据融合技术，考虑交通环境因素，设计新的数据融合方法和模型结构，如结合车辆传感器数据和交通监控视频数据，提高预测的准确性和鲁棒性。（4）开发实时高效的计算平台和算法，满足实时轨迹预测的需求。（5）结合路径规划算法，设计智能化系统，使车辆在复杂交通环境下更高效地行驶。随着研究的深入和技术的进步，相信未来能够实现更加智能、安全和高效的交通系统。

## 2.4 车辆轨迹规划方法

考虑周围交通环境的影响，车辆轨迹规划通常是换道轨迹规划，其目的是确定一条从换道起点行驶至终点无碰撞的最优轨迹<sup>[43]</sup>。目前常见方法主要包括基于优化的方法、基于搜索的方法、基于机器学习的方法、基于曲线拟合的方法。

### 2.4.1 基于优化的轨迹规划

基于优化的方法核心是视轨迹规划为求解最佳行驶路径的优化问题，以确保车辆达到预期状态。此过程一般涵盖多个目标，如减少碰撞风险、保障行驶安全、提升舒适度、提高行驶效率、确保行驶稳定性及实施的可行性等。通过调整车辆的移动方向和速度，将轨迹规划任务形式化为一个优化的数学问题。在此基础上，以安全和舒适为准则构建目标函数，并通过评估周围障碍物的动态来设置避免碰撞的限制，从而实现轨迹规划。一般有人工势场法、模型预测法等。

人工势场是将车辆的运动环境抽象为由引力和斥力构成的势场，引力由目标位置产生，指引车辆向目标移动；斥力则由障碍物生成，用以驱使车辆避开障碍。车辆的运动轨迹由这些势力的矢量和决定，即车辆在每一位置点上的运动方向和速度是由其所处位置的总势力矢量决定。该方法的核心优势在于简单直观，计算效率高，适合处理动态变化的环境。然而，它也存在一些局限性，如在高复杂环境中可能出现局部最小点问题，导致车辆陷入无法达到目标的状态。为解决这些问题，研究者通常会结合其他路径规划技术，或对势场模型进行改进，以提高规划的可靠性和效率。例如吴晓建等人<sup>[44]</sup>通过整合前车运动轨迹的预测信息到人工势场算法中，实现了动态和一致的车辆避撞轨迹规划，优化了传统方法在动态环境下的性能限制。

模型预测轨迹规划方法通过定义与障碍物的位置和运动状态相关的约束，将轨迹规划问题视为一个受约束的优化问题。通过设定最优化指标，求解约束方程，从而实现避障轨迹规划。这种方法不仅准确地规划出避障路径，还能优化车辆的行驶路线，保证安全和效率。Wang J 等人<sup>[45]</sup>提出了一种基于线性时变模型预测的车辆轨迹规划框架，用于处理车辆在相邻车道上的换道场景，通过集成换道轨迹生成模型到驾驶员-车辆系统中，采用线性时变模型预测方法，在满足驾驶意图和降低碰撞风险的优化目标下进行轨迹重规划，得到最优轨迹。

优化方法在解决多目标优化问题时有效地考虑了车辆的运动学与动力学约束，通过引入优化函数，能够有效应对障碍物和交通车辆的影响，提升换道和避障过程中的轨迹性能。然

而，该方法常将周围环境视为固定，难以适应复杂多变的交通环境，当模型的精确度要求较高时，计算效率较低。

### 2.4.2 基于搜索的轨迹规划

基于搜索的轨迹规划方法致力于遍历驾驶环境以确定从初始位置至目标位置的最优路径。这类方法往往将道路的遍历与速度规划相结合，以形成完整的行驶轨迹。虽然该方法在避免碰撞方面表现出色，但其在处理计算任务时需承担较高的计算量，一般适用于障碍物密集的非结构化道路环境。根据节点采样方式的不同，分为随机采样（如快速随机树 RRT 算法）和确定性采样（如 Dijkstra 或 A\*算法）。

随机采样使用随机性来探索环境，通常用于处理复杂或未完全定义的空间。这种方法不依赖于特定的路径描述，而是通过在环境中随机生成节点并连结这些节点来逐渐探索空间。随机采样优点在于其灵活性高，能够有效处理高维空间和复杂约束，但缺点是生成的路径可能不是最优的，且路径的平滑性和质量依赖于采样密度。

确定性采样则依赖于预定义的路径和规则，通过系统地评估所有可能的路径来找到从起点到终点的最优路径。这种方法在已知和静态的环境中非常有效，可以确保找到最佳解决方案，但其计算成本随问题规模和复杂性显著增加，对于动态或不确定环境的适应性较弱。

### 2.4.3 基于机器学习的轨迹规划

基于机器学习的轨迹规划方法主要依靠机器学习算法从历史数据中学习车辆行为和环境互动，以实现更高效和安全的导航决策。机器学习轨迹规划通常包括几个关键步骤：数据收集、特征工程、模型训练、以及路径生成。首先，从车辆传感器和历史轨迹记录中收集大量数据，如车辆的位置、速度、加速度和周围物体的位置信息等。其次，特征工程的任务是从这些原始数据中提取或构造关键特征信息，例如与最近障碍物的距离、历史行驶速度等。接下来，在模型训练环节选择合适的机器学习算法来处理数据，目标是训练出能够准确预测基于当前状态下最优或最可能轨迹的模型。最后，生成的模型被用来实时规划车辆在未来一段时间内的最佳行驶路径。

该方法能够处理复杂的交通情境，并通过学习提高轨迹规划的准确性和效率，特别适用于动态和不断变化的环境，如交通繁忙的城市道路和高速公路等。然而，这种方法的挑战在于对高性能计算资源和海量训练数据的需求，另外，模型的泛化能力和解释性也是需要考虑的问题<sup>[46]</sup>。



#### 2.4.4 基于曲线拟合的轨迹规划

基于曲线拟合的轨迹规划方法把换道轨迹设定成特定类型的曲线<sup>[43]</sup>，结合约束条件来规划出平滑并且连续的轨迹，常应用于换道轨迹规划中。该方法在结构化道路上的计算效率较高，但由于基于几何曲线的轨迹在路径和速度上存在耦合，往往难以确保所规划路径的最优性和适应性。常见的拟合曲线有三角函数、多项式、圆弧、Bezier 等，其中属多项式换道轨迹规划方法应用最具普适性<sup>[47]</sup>。多项式曲线通过分析起始与终止时刻的位置、方向、最低转弯半径及障碍物限制等几何条件来设定曲线参数。该方法依据不同的几何条件数量，采用三到六阶甚至更高阶的多项式进行计算。随着算法阶数的提升，处理难度和计算时间随之增加，导致算法收敛的速率下降。

#### 2.4.5 车辆轨迹规划小结

在车辆轨迹规划研究中，尽管现有主要方法在高速公路等特定场景下表现出较好的效果，但缺乏对城市道路或其他类型道路的适用性。基于优化的方法虽能有效处理多目标优化问题，确保轨迹的安全性和效率，但往往假设环境稳定，难以适应动态变化。基于搜索的方法在结构化环境中能够找到最优路径，但在动态或未知环境中的计算成本过高。基于机器学习的方法虽能通过历史数据训练适应复杂环境，但需要大量数据和计算资源，且泛化能力受限。基于曲线拟合的方法则在保证路径平滑性和连续性上有优势，但其在路径与速度的耦合处理上存在局限，难以保证路径的最优性和实时适应性。因此，未来的轨迹规划算法研究需集中于综合这些方法优点或弥补它们缺点，提高计算效率和实时动态性，扩展对城市道路或其他类型道路的应用，以应对智能车辆在多样化道路环境下的实际应用需求。

### 2.5 本章小结

本章详细介绍了 HMM 的定义、基本问题及对应解决算法，Prescan 仿真平台的流程、主要特性和应用场景，车辆轨迹预测方法，车辆轨迹规划方法，为接下来前车行为识别建模，以及预测前车行驶轨迹和主车的安全轨迹规划奠定了基础。

## 第三章 基于 GM-HMM 的城市道路前车行为识别

随着城市交通的日益增长，车辆行为识别在提高道路安全性、减少交通拥堵以及提升驾驶舒适性方面愈发关键。行为识别是轨迹预测的先决条件，它能识别其他车辆未来可能采取的行动，如左右换道等，而这些行动可能无法从现有数据中直接观察到，故在预测道路上车辆轨迹方面有重要意义。传统的车辆行为识别方法依赖于手工特征提取和选择，难以处理复杂时序数据和多维数据。为了解决这些问题，本文提出一种基于混合高斯隐马尔可夫模型（GM-HMM）的城市道路车辆行为识别方法。通过 Prescan 平台仿真获取数据并选取合适的特征参数，使用 Baum-Welch 算法迭代训练参数，根据前后向算法实现行为识别。

### 3.1 场景和数据分析

#### 3.1.1 行驶场景

换道是驾驶员基于当前交通状况进行的一系列变换车道操作，旨在优化行驶路径或缩短行程时间，通常有以下四个阶段：

- (1)观察阶段：此时驾驶员在维持正常行驶速度的同时，评估合适的换道时机和车辆间隙。
- (2)加速阶段：确定换道决策后，车辆加速以顺利进入目标车道。此阶段需要逐步提速，并持续监控与周边车辆的安全间隔。
- (3)稳定行驶阶段：车辆进入目标车道后，速度调整到一个稳定状态，确保与邻近车辆保持安全的行驶距离。
- (4)调速阶段：在完成换道动作后，车辆将根据行驶环境的需要逐渐减速，以回到正常的行驶速度，并注意观察后方车辆的行为和反应。

本文利用 Prescan 构建城市三车道道路交通场景，包含车辆、道路布局等，以模拟实际驾驶环境。同时结合 Simulink 仿真交通控制模块处理和模拟车辆的动态响应及其与周围环境的交互，联合仿真获取了车辆运动状态数据，以实现车辆行为的识别。研究对象为典型的城市三车道道路车辆行为：直行、左换道及右换道，行驶场景如图 3.1 所示，中间车道两侧分布有周围车辆（车辆 1~4），目标车辆和主车行驶在同一车道上。为确保主车的行驶安全性和舒适性，故需要对目标前车行为进行识别预测。




图 3.1 城市三车道道路车辆行驶场景

模拟场景设定符合交通规则，在 PreScan/MATLAB 仿真平台中基于实际城市道路典型场景进行建模进行车辆行驶数据采集。采集到的数据主要信息见表 3.1，并且全部车辆的导航均根据既定的路径规划指导，部分车辆位置和速度等参数设置如图 3.2 所示。

表 3.1 数据集车辆主要信息

名称	释义	单位
Time	时间	s
id	车辆的识别号	-
x	车辆的纵坐标	m
y	车辆的横坐标	m
xVelocity	车辆的纵向速度	m/s
yVelcoity	车辆的横向速度	m/s
xAcceleration	车辆的纵向加速度	m/s <sup>2</sup>
yAcceleration	车辆的横向加速度	m/s <sup>2</sup>
Class	车辆类型	-
$\theta$	车辆的航向角	deg

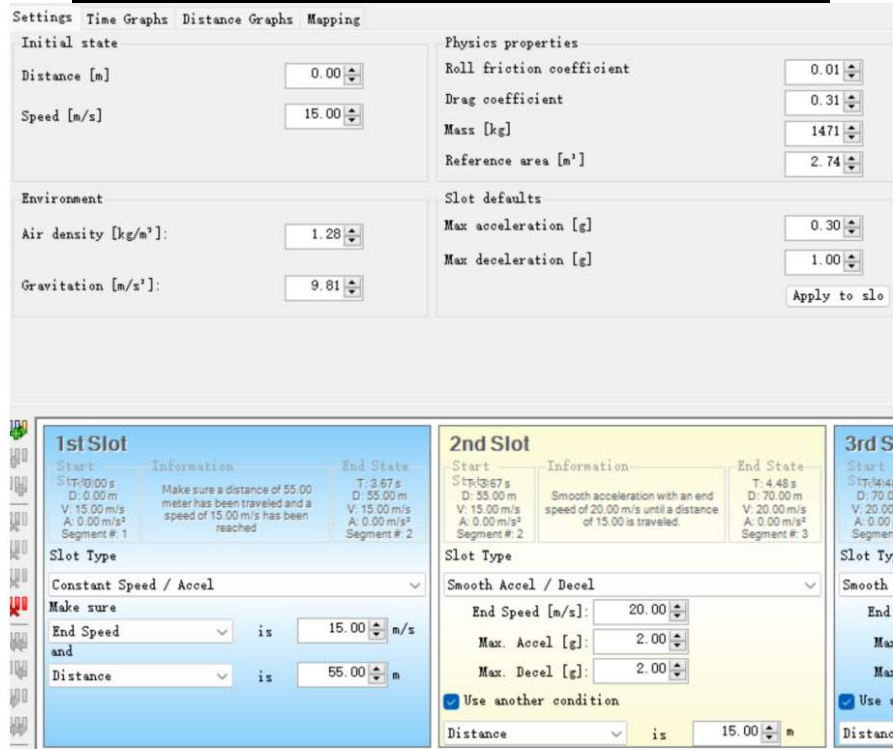


图 3.2 部分车辆参数设置

本文模拟场景具有如下属性：

- (1)除目标车辆外其余车辆均以 15m/s 匀速行驶，并且各车辆间保持必要的安全间隔。
- (2)每个车道的宽度设为 4m，每段场景道路长度为 200m，车辆尺寸按照选取的仿真车辆模块规格设置。
- (3)目标车辆行驶符合正常换道的四个阶段过程。
- (4)当目标车辆完成换道后，所有车辆均继续直行到路段终点，场景结束。
- (5)完成之前的场景后，所有车辆行驶到新的路段，新场景立刻重新启动，以确保场景间的连续性。
- (6)每次换道过程至少持续 4s，以确保完全改变车道或保持车道。

### 3.1.2 特征参数选择

选择较多的特征参数会导致计算量过大，从而影响算法的运行效率。因此应当精选较少且具有代表性的特征参数以降低计算量<sup>[48]</sup>。在分析目标车辆换道时，可以观察到其到右侧车道线的距离  $d_r$ 、纵向速度  $V_x$  以及横向速度  $V_y$  这三个参数会与直行时相比表现出显著的变化。所以，选取它们作为识别目标车辆行为的特征参数，每个样本由这三个参数组成，用来表征车辆的行为模式，并被记录用于模型训练和测试，左换道部分观测变量数据如表 3.2 所示。

表 3.2 左换道部分观测变量数据

时间(s)	$d_r(m)$	$V_x(m)$	$V_y(m)$
0.1	0.62	-0.35	14.19
0.2	0.58	-0.37	14.33
0.3	0.54	-0.37	14.71
0.4	0.49	-0.46	14.9
0.5	0.41	-0.83	14.81
0.6	0.31	-1.06	14.83
0.7	0.17	-1.32	14.84
0.8	0.02	-1.53	14.83
0.9	0.12	-1.44	14.83
1.0	0.27	-1.44	14.82
1.1	0.41	-1.44	14.83
1.2	0.55	-1.44	14.83
1.3	0.7	-1.44	14.82
1.4	0.84	-1.44	14.83
1.5	0.99	-1.53	14.87
1.6	1.13	-1.34	14.86
1.7	1.22	-0.89	14.82
1.8	1.27	-0.55	14.78
1.9	1.31	-0.37	14.78
2.0	1.34	-0.34	14.81

通常需要大量的数据支撑来训练模型的参数，鉴于车辆行为的连续性特征，设定目标车辆的行驶状态数据采样频率为 10Hz 以确保特征参数的连续记录，从而形成完整的观测序列，有助于对车辆动态进行精确追踪和分析。本文共记录了 780 组数据，把它们分成训练集和测试集，以支持模型的训练和效果验证。所有数据首先根据车辆行为类型进行分类，然后按照 7:3 的比例随机划分，以确保每类行为在训练和测试集中均有代表性。训练集用于深入分析不同车辆行为所呈现的特征参数变化，并据此训练车辆行为识别模型，而测试集则用来验证模型的准确性，评估其在处理未见样本时的泛化能力。

### 3.2 GM-HMM 模型构建

在智能交通系统中，精确识别城市三车道道路上的车辆行为对于提高交通安全性和效率至关重要。城市三车道道路是一个动态复杂的环境，车辆行为如直行、左换道和右换道，受到驾驶员意图、交通流密度和周围车辆行为等多种因素的影响。这些复杂的交互作用使得车辆行为识别成为一个涉及多变量和多状态的挑战，故急需寻找一个能够高效捕捉这些复杂性和动态变化的模型。

高斯混合模型（GMM）是一种概率模型，具有灵活性和适应性，它假设所有数据点都源自有限数量的高斯分布，每个高斯分布具有自己的均值和协方差，这些参数决定了分布的位置和形状。这一假设特别适合于模拟城市交通中各种车辆行为背后的连续概率分布，如直行、左换道和右换道。每种行为都对应于特定的高斯分布，这些分布未知，但其参数能够从实际驾驶数据中通过 EM 算法学习得到。通过将数据视为多个高斯分布的混合，GMM 不仅揭示了车辆行为的多样性，还能反映出行为的条件依赖性，从而准确描述车辆在不同行为状态下的动态变化<sup>[49]</sup>。

根据 HMM 的先前描述，HMM 是处理时间序列数据的强大工具，能够对不同行为状态之间的转换进行建模。在复杂的道路交通场景中，车辆的行为表现出明显的前后依赖性，例如，车辆可能从直行变为向左变道。HMM 的状态转移矩阵提供了这种依赖性的数学描述，从而为车辆行为的时间连贯性提供了坚实的理论基础。

因此结合 GMM 的连续数据处理优势和 HMM 的时间序列分析能力，本文提出应用 GM-HMM 来分析和识别城市三车道道路上车辆的行为。可用五元组  $\lambda = \{\pi, A, c, \mu, G\}$  表示 GM-HMM 模型参数，其中  $\pi$  是初始状态概率向量； $A$  是状态转移矩阵； $c$  是高斯分量权重系数； $\mu$  是高斯均值矩阵； $G$  是高斯协方差矩阵。

在 GM-HMM 中，观测概率分布  $B$  的定义是通过多个高斯分布的线性组合来表示，从而

大幅提升模型对数据的拟合能力，特别是有效处理具有复杂多峰特性的观测数据。具体地，与 HMM 不同的是，每个隐状态在 GM-HMM 中不是通过单一的概率分布来描述，而是依赖于多个多维高斯函数，这使得每个状态生成的观测值能够精确地反映出数据的连续概率密度函数。假设模型有  $E$  个隐状态，每个状态包含  $U$  个高斯分量，那么在给定状态下观测到特定数据的概率  $b_j(O)$  为：

$$b_j(O) = \sum_{u=1}^U c_{ju} N(O | \mu_{ju}, G_{ju}) \quad (3.1)$$

式中， $C_{ju}$  表示隐状态  $j$  下第  $u$  个高斯分量的混合权重， $C_{ju} \geq 0$ ，权重之和为 1； $\mu_{ju}$  和  $G_{ju}$  分别是对应高斯分量的均值和协方差矩阵。

$N(O | \mu_{ju}, G_{ju})$  是多维高斯概率密度函数，其表达式为：

$$N(O | \mu_{ju}, G_{ju}) = \frac{1}{(2\pi |G_{ju}|)^{1/2}} \exp \left[ \frac{-1}{2|G_{ju}|} (O - \mu_{ju})(O - \mu_{ju})^T \right] \quad (3.2)$$

### 3.3 参数训练

GM-HMM 的参数训练即已知观测序列  $O = \{O_1, O_2, \dots, O_T\}$ ，模型参数  $\lambda = \{\pi, A, c, \mu, G\}$ ，需要训练参数使  $P(O|\lambda)$  最大。

具体步骤：首先，给每个车辆行为子模型（直行 GM-HMM $\lambda_1$ 、左换道 GM-HMM $\lambda_2$ 、右换道 GM-HMM $\lambda_3$ ）设置初始参数，再从用于计算初始均值矩阵  $\mu_0$  和协方差矩阵  $G_0$  的训练数据中选取一组样本输入。接着，利用前后向算法计算状态序列的前向和后向概率，以此为基础，通过计算观测值的中间辅助变量，结合 Baum-Welch 算法逐步迭代更新各参数，包括状态转移概率和高斯分量的参数，从而最大化训练数据的似然函数。在每次迭代中，根据当前参数估计值重新计算前向概率、后向概率和中间辅助变量，并据此调整模型参数。此过程持续进行，直至参数收敛，最终确定并保存每个子模型的参数。

$\pi$  和  $A$  主要影响模型在时间序列中状态的转变逻辑。由于 Baum-Welch 算法的迭代更新特性，即使这些参数的初始设置不是最佳，但它们会根据数据的状态转移特性逐步调整，足够的迭代和数据量能引导模型参数收敛到接近稳定解，能够大幅有效减少它们初始设置的直接影响，使得  $\pi$  和  $A$  的初始值可以较为灵活地设置，故采用公式 (3.3) 和 (3.4) 设定  $\pi$  和  $A$ 。相比之下， $c$ ， $\mu$  和  $G$  直接决定了模型在每个状态下的观测数据分布，即高斯分布的形状和位置，对数据的拟合精度有直接和显著的影响。不当的初始值设定可能导致模型陷入局部最优

或收敛过程缓慢，特别是在数据具有复杂分布时。为了提高这些参数的初始化质量，采用 K-means 聚类算法来优化初始设置，自动确定初始的聚类中心和分布，以便模型能更有效地探索参数空间并快速收敛。

$$\pi_0 = \left[ \frac{1}{3} \frac{1}{3} \frac{1}{3} \right]^T \quad (3.3)$$

$$A_0 = \begin{bmatrix} \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \\ \frac{1}{3} & \frac{1}{3} & \frac{1}{3} \end{bmatrix} \quad (3.4)$$

本文利用 Python 中的 hmmlearn 工具箱编写程序来训练相应模型，以建立独立的 GM-HMM 来描述目标车辆的三种车辆行为。

直行 GM-HMM $\lambda_1$  的参数训练结果如下：

$$\pi_1 = [0.912 \quad 0.043 \quad 0.045]^T \quad (3.5)$$

$$A_1 = \begin{bmatrix} 0.992 & 0.003 & 0.005 \\ 0.003 & 0.993 & 0.004 \\ 0.005 & 0.004 & 0.991 \end{bmatrix} \quad (3.6)$$

$$c_1 = [1 \quad 1 \quad 1]^T \quad (3.7)$$

$$\mu_1 = \begin{bmatrix} 4.277 & 4.988 & 1.365 \\ -0.035 & -1.007 & -0.993 \\ 19.976 & 20.024 & 18.647 \end{bmatrix} \quad (3.8)$$

$$G_1(:, :, 1) = \begin{bmatrix} 1.046 & 0.009 & 0.598 \\ 0.023 & 0.137 & -0.020 \\ -0.112 & 0.785 & 1.973 \end{bmatrix} \quad (3.9)$$

$$G_1(:, :, 2) = \begin{bmatrix} 0.952 & 0.994 & 0.387 \\ 0.869 & -0.140 & -0.012 \\ 0.536 & 1.321 & 3.891 \end{bmatrix} \quad (3.10)$$

$$G_1(:, :, 3) = \begin{bmatrix} 0.307 & -0.421 & 1.198 \\ 0.070 & 1.425 & 0.599 \\ 0.964 & 0.874 & 2.601 \end{bmatrix} \quad (3.11)$$

左换道 GM-HMM $\lambda_2$  的参数训练结果如下：

$$\pi_2 = [0.852 \quad 0.077 \quad 0.071]^T \quad (3.12)$$

$$A_2 = \begin{bmatrix} 0.953 & 0.026 & 0.021 \\ 0.020 & 0.976 & 0.004 \\ 0.149 & 0.006 & 0.845 \end{bmatrix} \quad (3.13)$$

$$c_2 = [1 \quad 1 \quad 1]^T \quad (3.14)$$

$$\mu_2 = \begin{bmatrix} 4.173 & 2.005 & 2.238 \\ -1.069 & -0.521 & -2.206 \\ 29.857 & 25.662 & 28.405 \end{bmatrix} \quad (3.15)$$

$$G_2(:, :, 1) = \begin{bmatrix} 0.799 & 0.015 & 0.003 \\ -0.014 & 0.025 & -1.411 \\ 0.658 & 1.278 & 2.986 \end{bmatrix} \quad (3.16)$$

$$G_2(:, :, 2) = \begin{bmatrix} -0.182 & 0.501 & 1.134 \\ 0.698 & 0.151 & -0.127 \\ 1.079 & 0.446 & 2.103 \end{bmatrix} \quad (3.17)$$

$$G_2(:, :, 3) = \begin{bmatrix} 0.150 & 0.045 & 0.003 \\ 0.007 & 1.225 & 0.698 \\ -1.053 & -4.24 & 3.204 \end{bmatrix} \quad (3.18)$$

右换道 GM-HMM $\lambda_3$  的参数训练结果如下：

$$\pi_3 = [0.885 \quad 0.102 \quad 0.013]^T \quad (3.19)$$

$$A_3 = \begin{bmatrix} 0.806 & 0.093 & 0.101 \\ 0.005 & 0.902 & 0.093 \\ 0.027 & 0.025 & 0.948 \end{bmatrix} \quad (3.20)$$

$$c_3 = [1 \quad 1 \quad 1]^T \quad (3.21)$$

$$\mu_3 = \begin{bmatrix} 1.295 & 6.219 & 2.102 \\ -0.741 & -2.286 & -0.063 \\ 23.588 & 30.497 & 30.064 \end{bmatrix} \quad (3.22)$$

$$G_3(:, :, 1) = \begin{bmatrix} 0.314 & 0.356 & 0.004 \\ 0.052 & 0.535 & 0.001 \\ 0.327 & -0.004 & -0.849 \end{bmatrix} \quad (3.23)$$

$$G_3(:, :, 2) = \begin{bmatrix} 0.917 & 1.420 & 1.358 \\ 0.258 & 0.673 & 0.006 \\ -0.355 & -0.431 & 0.312 \end{bmatrix} \quad (3.24)$$



$$G_3(:, :, 3) = \begin{bmatrix} -0.258 & 1.034 & 0.011 \\ 1.136 & 2.401 & 0.597 \\ 0.524 & -0.181 & 2.205 \end{bmatrix} \quad (3.25)$$

### 3.4 城市道路车辆行为识别

如图 3.3 所示, 将测试序列样本依次输入到三个子模型里, 根据前后向算法分别计算它们产生该观测序列的概率  $P(O|\lambda)$  并进行比较<sup>[50]</sup>。若某个模型的输出概率值最大, 则反映该子模型和给定观测序列的匹配度最高, 其对应车辆行为即为待识别结果。

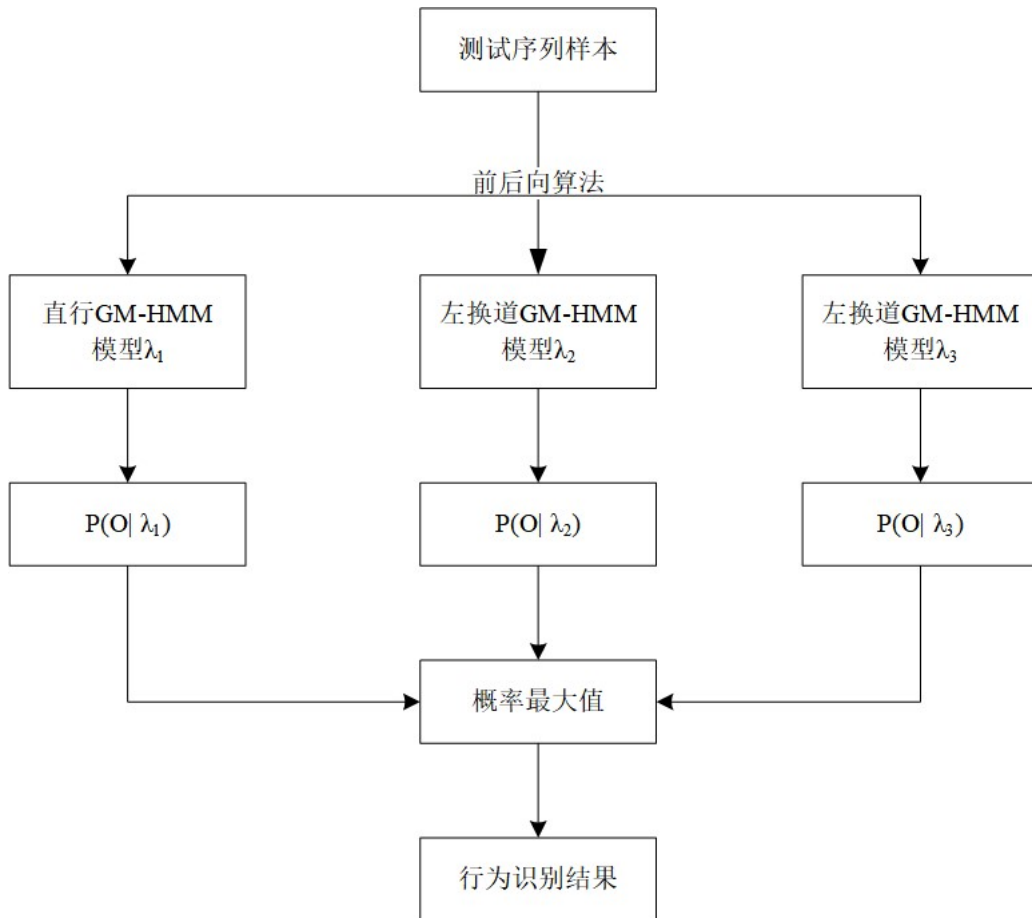


图 3.3 城市道路车辆行为识别过程

本文使用对数概率而不是直接概率计算识别结果, 主要是为了解决由于多个小概率连乘导致的数值下溢和精度问题<sup>[51]</sup>。采用对数转换后, 概率的乘法变为对数值的加法, 这不仅防止了下溢, 还提高了计算的数值稳定性和效率, 同时由于对数是单调函数, 这种转换不会影响决策结果的正确性<sup>[52]</sup>。基于最大似然估计原理, 选取  $P(O|\lambda)$  最大的对应模型作为最佳匹配模型, 因此将每行最大数值对应的车辆行为当成识别结果, 同时对预测的正确性进行了标注, 部分样本识别结果见表 3.3。

表 3.3 部分车辆行为样本识别结果

样本	直行 $\lambda_1$	左换道 $\lambda_2$	右换道 $\lambda_3$	识别结果	识别正误
直行样本 1	-68.26	-278.69	-163.31	直行	正确
直行样本 2	-91.05	-331.42	-227.68	直行	正确
左换道样本 1	-235.30	-48.72	-337.05	左换道	正确
左换道样本 2	-317.80	-381.42	-442.54	直行	错误
右换道样本 1	-273.88	-687.23	-82.91	右换道	正确
右换道样本 2	-396.90	-423.67	-67.83	右换道	正确

### 3.5 实验结果分析

不同时间窗口大小对车辆行为识别准确率的影响有重要意义。时间窗口的大小决定了数据采集的粒度，直接影响行为特征的捕捉能力。较小的时间窗口可能引入更多的噪声和导致过拟合，从而忽略关键的行为变化，特别是在数据样本较少的情况下。相反，较大的时间窗口容易造成信息冗余，降低计算效率<sup>[53]</sup>。因此，需要选择合适的时间窗口在保持数据敏感性和避免模型过拟合之间寻找平衡。如图 3.4 所示，本文研究了不同时间窗口大小（0.5s、1.0s、1.5s、2.0s、2.5s 和 3.0s）下的车辆行为识别准确率，通过分析可得，在 2.0s 时间窗口下为最优选择，模型可以充分获取目标车辆行为特征信息，识别准确率最高。故采用 2.0s 的时间窗口进行连续识别，由此产生的每个观测序列长度为 20，设置每次移动间隔为 0.5s，其中每个时间点都记录了目标车辆的特征参数值数据。




图 3.4 不同时间窗口下的车辆行为识别准确率

为了有效评估所构建的车辆行为识别模型的性能，本文采用识别精度作为关键指标来衡量模型正确识别的样本数量与总样本数量的比例。如表 3.4 所示，在 2.0s 时间窗口下的样本

检验中，直行、左换道、右换道识别精度分别为 92.7%，90.0%和 90.8%，展现出 GM-HMM 的良好识别性能。

表 3.4 车辆行为识别精度

车辆行为	直行	左换道	右换道
样本总数	300	240	240
正确样本数	278	216	218
精度	92.7%	90.0%	90.8%

此外，如表 3.5 所示，本文对不同算法在车辆行为识别中的表现进行了比较，包括 BP、K-NN、RF、SVM、HMM 和 GM-HMM，旨在评估它们在直行、左换道、右换道三种行为的混合样本集下的准确率。在车辆行为识别中，BP 神经网络因容易受初始设置的影响且容易陷入局部最优，准确率只有 76.6%；KNN 算法的准确率较低，仅有 77.8%，主要因为其对多维数据合异常值的敏感性高，并且对特征量级差异反应过强；RF 在随机性场景下的性能较差，准确率较低为 79.4%。相比之下，SVM 凭借其较强的处理线性及非线性问题能力，准确率为 87.2%；由于对时间序列数据具有适应性，HMM 同样表现良好，准确率达到 88%；GM-HMM 以 91.2%的准确率领先，表现出在处理时序数据时的显著优势，特别是在捕捉车辆行为的动态变化方面。综上所述，在车辆行为识别领域，本文提出的 GM-HMM 展现出较高的精度和鲁棒性。

表 3.5 不同算法下的车辆行为识别准确率

算法	BP	K-NN	RF	SVM	HMM	GM-HMM
准确率	76.6%	77.8%	79.4%	87.2%	88%	91.2%

3.6 本章小结

本章提出了一种 GM-HMM 的城市道路前车行为识别方法，首先阐述了换道场景，在 Prescan 平台上模拟城市三车道道路交通场景，并通过 Simulink 获取车辆运动状态数据，以捕捉目标车辆的行为。随后，通过精选特征参数并使用 Baum-Welch 算法训练模型参数，结合前后向算法，成功实现了对城市道路前车行为的准确识别。此外，还探讨了不同时间窗口对识别准确率的影响，确定了 2.0 秒的时间窗口大小为最优，该窗口下模型能有效捕捉行为特征。实验结果表明，相对于其他算法，GM-HMM 结合了 HMM 和 GMM 的优势，通过利用 GMM 描述在特定隐状态下的观察数据分布，以及 HMM 处理状态转换的能力，GM-HMM 能够捕捉车辆行为的多样性和随时间的动态变化，从而更准确地识别车辆行为。

## 第四章 基于 GPR 的不同换道风格前车轨迹预测

在智能交通系统中，为确保智能车辆在复杂交通环境中的安全和有效运行，准确预测其他交通参与者的未来行驶轨迹至关重要。本章基于前一章节对前车行为的分析和识别结果，进一步探讨如何预测前车的行驶轨迹。现有方法在复杂多变的交通环境中表现不佳，难以应对不同驾驶风格等不确定因素的影响，导致预测精度和可靠性不足。针对上述问题，本文提出了一种基于高斯过程回归（GPR）的不同换道风格前车轨迹预测方法。首先，考虑到前车在换道过程中可能表现出的不同驾驶风格，本文收集并分析了大量车辆的历史行驶数据以识别和分类不同的换道风格，然后结合 GMM 聚类出相同换道风格下的轨迹，最后对每类换道风格轨迹进行平均化处理得到原型轨迹，通过 GPR 分析方法完成前车行驶轨迹的预测。

### 4.1 车辆行驶轨迹数据采集

在自动驾驶技术的发展过程中，对前车行驶轨迹的精确采集与分析是确保智能车辆在城市复杂交通环境中安全有效运行的关键一环。为此，本文利用 PreScan 仿真平台构建了一个模拟真实城市三车道单向道路环境，并收集车辆的行驶轨迹数据，如上一章节的图 3.1 所示，中间车道两侧分布有周围车辆（车辆 1、车辆 2、车辆 3、车辆 4），目标车辆和主车行驶在同一车道上。道路的详细参数根据实际城市道路的标准设定，车道宽度 4m，采样周期 10Hz，确保仿真环境的真实性。

本文的数据采集重点放在车辆换道的驾驶行为上，换道轨迹样本的筛选基于模拟环境中的特定行为进行。换道行为通常分为判断（AB 段）、启动换道（BC 段）、完成换道（CD 段）和调整至目标位置（DE 段）四个阶段，如图 4.1 所示。选取 C 点作为换道轨迹的关键点，向前后各扩展一定时长，通常选取 6 秒，以充分覆盖换道过程。




图 4.1 车辆典型换道轨迹示意图

采集的数据内容包括车辆的位置坐标( $X(t)$ ,  $Y(t)$ )、速度  $V(t)$ 、加速度  $a(t)$ 、航向角  $\theta(t)$ 等, 每个样本都包含了以上信息。为确保样本的质量, 本文剔除了存在显著波动或连续换道行为的样本。同时对所有筛选出的样本都进行了统一位置变换, 设定每个样本和车道线交点处的坐标为(100,2), 以消除特定道路位置的影响, 实现轨迹数据的标准化。

通过以上步骤, 经过精细的筛选和坐标转换, 最终得到的换道轨迹样本为标准化数据<sup>[54]</sup>, 筛选后的换道经典轨迹如图 4.2 所示。




图 4.2 左换道经典轨迹（左图）和右换道经典轨迹（右图）

## 4.2 换道轨迹风格聚类特征选择

在识别前车行为的基础上, 本文从仿真的城市三车道道路环境中采集车辆行驶数据, 着重分析换道风格与换道轨迹之间的关系以进行有效的聚类分析。

在进行聚类分析前, 关键在于选择能够反映换道风格特征的数据。基于以往研究和实验场景初步观察, 本文确定了以下几个关键特征:

(1) 横向加速度  $a_y$ : 横向加速度是分析换道动作中最直接的物理量, 它能够反映驾驶员在换道过程中的操作强度和风格倾向。

(2) 航向角  $\theta$ : 航向角的变化提供了车辆方向改变的直接证据, 是理解车辆行驶轨迹变化的重要参数。航向角的细微变化可以揭示驾驶员的驾驶习惯, 如平滑或急转的操作。

(3) 车速  $V$ : 不同的换道风格在车速的高低和变化也有所差异。

由此可知横向加速度、航向角、车速是衡量换道风格的重要特征, 换道风格越激进, 这三个参数越大。本文假设车辆纵向速度基本不变, 故车速  $V$  也可以通过横向加速度体现, 因此, 选择  $a_y$ 、 $\theta$  作为聚类特征。

将单向换道轨迹样本集合记为：

$$LC_{l,n} = \{lc_{l,n}, lc_{l,n}, \dots, lc_{l,n}; lc_{r,n}, lc_{r,n}, \dots, lc_{r,n}\} \quad (4.1)$$

式中,  $l$  代表左换道,  $r$  代表右换道。每个样本由一个  $7 \times 60$  矩阵表示。每个样本的相关信息包括以下内容：

$$lc = \{X(t), Y(t), V_x(t), V_y(t), a_x(t), a_y(t), \theta(t)\} \quad (4.2)$$

通过这种细分, 有助于探究在不同行驶速度下, 驾驶者换道风格的变化及其一致性, 可以更好地模拟和预测驾驶者在特定速度和情境下的换道轨迹, 进而为自动驾驶系统的决策提供科学依据。在聚类分析中, 每个类别的左右换道轨迹被单独处理, 以确保风格分类的准确性。总结来说, 本文通过将横向加速度、航向角、车速结合起来, 形成了一个综合考量驾驶行为与车辆动态的聚类分析方法。这种方法不仅增强了换道轨迹预测的准确性, 也为理解和建模复杂换道风格提供了有效的技术途径。

### 4.3 不同换道风格下的车辆轨迹聚类

本文基于横向加速度  $a_y$  和航向角  $\theta$  构造 GMM, 若存在  $K$  类代表不同换道风格轨迹高斯分布。那么, 该 GMM 的概率密度函数可以表示为:

$$P(a_y, \theta) = \sum_{k=1}^K P(k) p(a_y, \theta | k) = \sum_{k=1}^K \varphi_k \mathcal{N}(a_y, \theta | \mu_k, \Sigma_k) \quad (4.3)$$

上式表示高斯分布的线性加权组合, 其中  $1 \leq k \leq K$ ,  $\mathcal{N}(a_y, \theta | \mu_k, \Sigma_k)$  为多维高斯分布函数, GMM 分布由参数第  $k$  类高斯分布的混合权重系数  $\varphi_k$ 、均值  $\mu_k$  和协方差  $\Sigma_k$  决定, 共同表征了  $a_y$  和  $\theta$  之间的相关性。

假设所有数据样本点都满足相互独立和分布相同的要求, GMM 参数可通过对数最大似然函数估计。给定  $N$  组训练数据, 则对数似然函数的最大值可按如下方法求得:

$$\arg \max_{\varphi, \mu, \Sigma} \sum_{n=1}^N \ln \sum_{k=1}^K \varphi_k \mathcal{N}(a_{yn}, \theta_n | \mu_k, \Sigma_k) \quad (4.4)$$

由于  $\sum_{k=1}^K \varphi_k = 1$ , 故结合拉格朗日乘数法, 对数似然函数变成:

$$L(\varphi_k, \mu_k, \Sigma_k) = \sum_{n=1}^N \ln \sum_{k=1}^K \varphi_k \mathcal{N}(a_{yn}, \theta_n | \mu_k, \Sigma_k) + \lambda \left( \sum_{k=1}^K \varphi_k - 1 \right) \quad (4.5)$$

求偏导, 得到下列式子。

$$\sum_{n=1}^N \frac{\mathcal{N}(a_{yn}, \theta_n | \mu_k, \Sigma_k)}{\sum_j \varphi_j \mathcal{N}(a_{yj}, \theta_j | \mu_j, \Sigma_j)} + \lambda = 0 \quad (4.6)$$

$$\sum_{n=1}^N \frac{\varphi_k \mathcal{N}(a_{yn}, \theta_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \varphi_j \mathcal{N}(a_{yj}, \theta_j | \mu_j, \Sigma_j)} \Sigma_k^{-1} ((a_{yn}, \theta_n) - \mu_k) = 0 \quad (4.7)$$

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \frac{\varphi_k \mathcal{N}(a_{yn}, \theta_n | \mu_k, \Sigma_k)}{\sum_{j=1}^K \varphi_j \mathcal{N}(a_{yj}, \theta_j | \mu_j, \Sigma_j)} ((a_{yn}, \theta_n) - \mu_k) ((a_{yn}, \theta_n) - \mu_k)^T \quad (4.8)$$

由于模型参数的求解依赖于参数本身，导致无法通过对数似然函数的直接求导获得解析解。为此本文采用了迭代的 EM 算法来优化数值，E 步—用初始参数值估计对数似然函数的期望；M 步—利用最大化似然函数来更新参数。循环执行这两个主要步骤，直至对数似然函数值的变化低于预设的阈值。然而，EM 算法的初始参数选择对结果影响较大，为减少迭代次数、降低计算负担和避免陷入局部最优，本文首先使用 K-means 算法对换道轨迹进行聚类来确定 GMM 的初始参数，然后将聚类结果用作 GMM 参数的初始值，通过 EM 迭代求解直至对数似然函数的增量小于预设阈值，以增加聚类结果的准确性<sup>[55]</sup>。具体步骤如下：

(1) 初始化 GMM 的参数：采用 K-means 算法对换道轨迹集合聚类，计算每个类型下的混

合权重系数  $\varphi_k$ 、均值  $\mu_k$  和协方差  $\Sigma_k$ ，其中  $N_k = \sum_{n=1}^N \varphi_i(k)$ 。

$$\varphi_k = \frac{N_k}{N} \quad (4.9)$$

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^{N_k} (a_{yn}, \theta_n) \quad (4.10)$$

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^{N_k} ((a_{yn}, \theta_n) - \mu_k) ((a_{yn}, \theta_n) - \mu_k)^T \quad (4.11)$$

(2) E 步（期望步骤）：基于当前参数，对于每个样本，其属于类型  $k$  的概率如下：

$$\varphi_n(k) = \frac{\varphi_k \mathcal{N}(a_{yn} | \mu_k, \Sigma_k)}{\sum_{i=1}^K \varphi_i \mathcal{N}(a_{yn} | \mu_i, \Sigma_i)}, k=1, \dots, K \quad n=1, \dots, N_k \quad (4.12)$$

(3) M 步（最大化步骤）：使用 E 步的后验概率更新各聚类的参数以最大化数据的似然函数，从而更精确地反映数据的统计特性。参数更新公式如下：

$$\varphi_k = \frac{N_k}{N} \quad (4.13)$$

$$\mu_k = \frac{1}{N_k} \sum_{n=1}^N \varphi_k(a_{yn}, \theta_n) \quad (4.14)$$

$$\Sigma_k = \frac{1}{N_k} \sum_{n=1}^N \varphi_k((a_{yn}, \theta_n) - \mu_k)((a_{yn}, \theta_n) - \mu_k)^T \quad (4.15)$$

(4) 计算对数似然函数：迭代优化，重复 E 步和 M 步，直到收敛。

$$\sum_{n=1}^N \ln \sum_{k=1}^K \varphi_k N(a_{yn}, \theta_n | \mu_k, \Sigma_k) \quad (4.16)$$


参数求解后，通过计算换道轨迹中每个类别的相应概率，对每个样本通过似然函数进行分类，如公式 (4.17) 所示。最后，将概率最高的类别分配给样本。

$$L_k(a_{yi}, \theta_i) = \frac{1}{\sqrt{(2\pi)^n |\Sigma_k|}} \exp \left\{ -\frac{1}{2} ((a_{yi}, \theta_i) - \mu_k)^T \Sigma_k^{-1} ((a_{yi}, \theta_i) - \mu_k) \right\} \quad (4.17)$$

分类后得到  $K$  类轨迹，每类轨迹集合中的样本数符合：

$$N_1 + \dots + N_K = N \quad (4.18)$$

通常以三种换道风格为宜<sup>[56]</sup>，故本文采用 GMM 对左换道和右换道样本轨迹各 100 条进行分类，将其分为三个类别：平缓型 (K1)、普通型 (K2) 和激进型 (K3)，结果如图 4.3 所示。





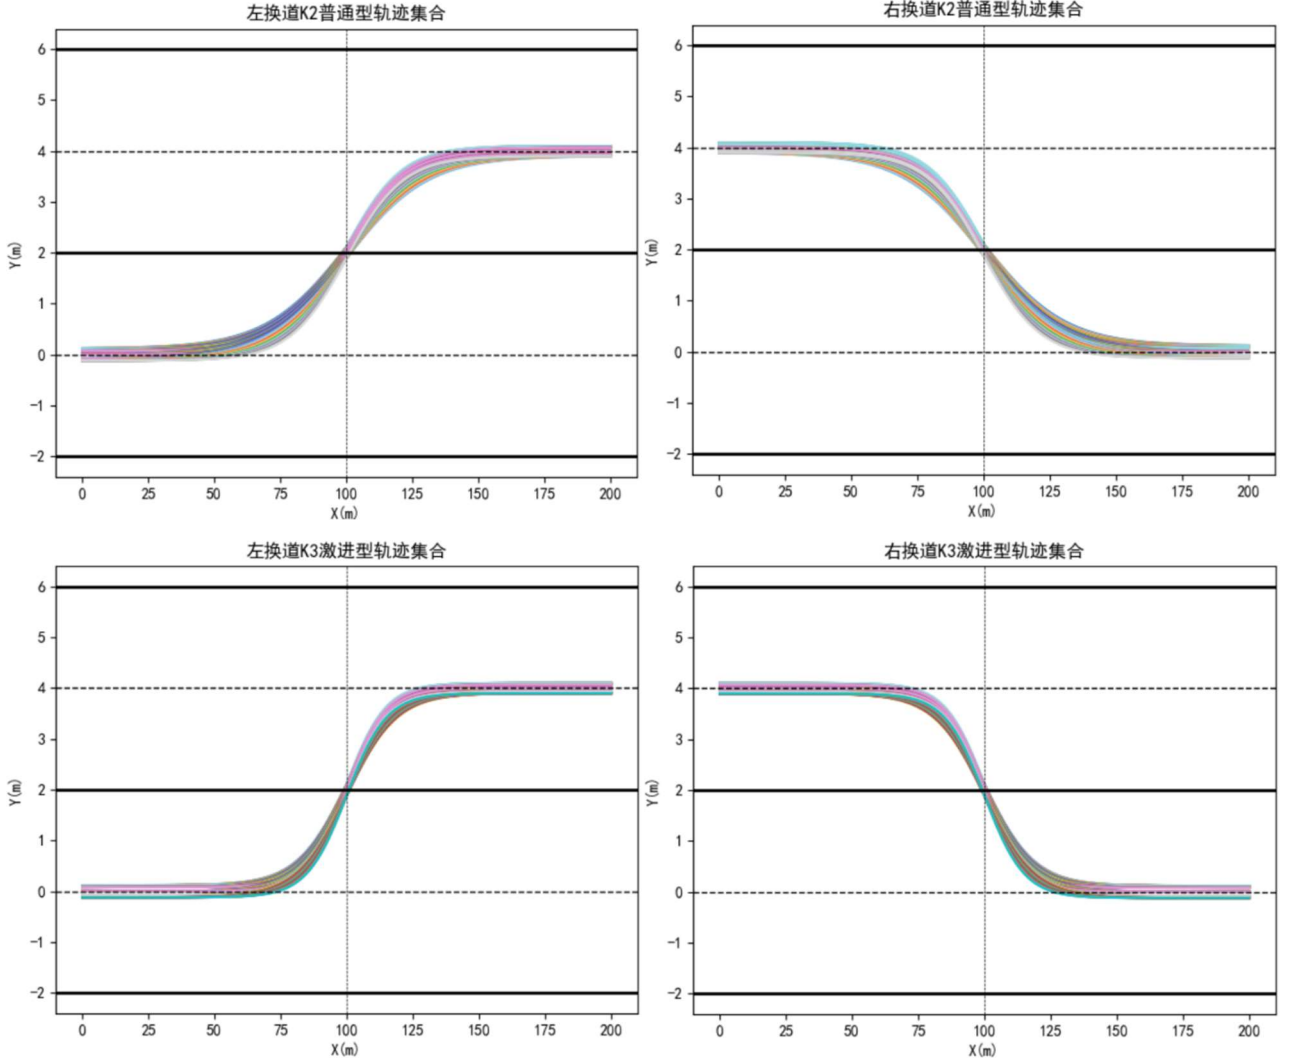


图 4.3 左右不同换道风格聚类轨迹集合

为了简化后面高斯过程模型计算，本文对每类换道风格下轨迹数据按照公式（4.19）实现平均化处理，形成一个标准化的、可以代表多种类似情况的原型轨迹，如图 4.4 和图 4.5 所示。

$$\begin{aligned}
 X_1 &= \frac{1}{N_1} \sum_{i=1}^{N_1} X_{1i} & Y_1 &= \frac{1}{N_1} \sum_{i=1}^{N_1} Y_{1i} & a_{y1} &= \frac{1}{N_1} \sum_{i=1}^{N_1} a_{y1i} & \theta_1 &= \frac{1}{N_1} \sum_{i=1}^{N_1} \theta_{1i} \\
 X_K &= \frac{1}{N_K} \sum_{i=1}^{N_K} X_{Ki} & Y_K &= \frac{1}{N_K} \sum_{i=1}^{N_K} Y_{Ki} & a_{yK} &= \frac{1}{N_K} \sum_{i=1}^{N_K} a_{yKi} & \theta_K &= \frac{1}{N_K} \sum_{i=1}^{N_K} \theta_{Ki} \quad (4.19)
 \end{aligned}$$




图 4.4 左换道原型轨迹




图 4.5 右换道原型轨迹

## 4.4 基于高斯过程回归的轨迹预测

在自动驾驶领域中，准确预测车辆换道轨迹对于确保行车安全至关重要。车辆换道可以视为一个时间序列问题，虽然同一个换道风格下每条轨迹大体遵循某些共同的运动模式，但具体每次换道时都会有细微的差别。这些差别反映了在模拟和预测换道行为时存在的不确定性，表明未来的车辆状态并非唯一确定。为了有效地模拟这种复杂性和不确定性，传统的参数化模型虽然能提供一定的解决方案，但其依赖于准确的参数定义，这在实际应用中往往难以捕捉复杂的运动模式并需要大量数据支持。相比之下，非参数模型如高斯过程模型提供了一个更为灵活和鲁棒的方法。高斯过程（Gaussian Process, GP）作为一种非参数统计模型，能够在相对较少的训练数据情况下有效地进行泛化，尤其适合处理那些具有连续路径特征的时间序列数据<sup>[57]</sup>。

在建模换道轨迹时，尤其是在结构化的城市三车道环境中，假定驾驶行为会遵守交通规

则，并在一定的运动模式下进行。通过从历史数据中提取的原型轨迹，建立一个高斯过程回归模型（Gaussian Process Regression, GPR），利用原型轨迹作为训练基础，结合时间作为输入变量，从而预测车辆的未来横向和纵向运动轨迹。此外，由于高斯过程模型在数学上具有从数据生成概率描述的能力，它可以量化预测的不确定性，这对于自动驾驶系统的决策制定是极其重要的<sup>[58]</sup>。例如，在车辆换道时，GPR 能够提供关于车辆横向位置的预测区间，这些区间反映了潜在的位置变化范围，帮助自动驾驶系统更好地评估风险并做出相应的驾驶决策。

#### 4.4.1 模型设计

本文结合高斯过程在车辆轨迹预测方面良好的通用性和预测精度，基于不同换道风格构建了一个高斯过程回归模型预测目标车辆的未来行驶轨迹，以提高预测目标实时轨迹的准确度。该模型假设车辆行驶轨迹并非完全随机，而可通过典型函数模型描述<sup>[59]</sup>。

若模型输入  $h$ ，输出  $H$ ，训练样本  $Tra=\{h,H\}$ ，则通过高斯过程可以构建如下的回归函数模型来表征输入与输出之间的统计关系：

$$f(h) \sim GP(M(h), R(h_1, h_2)) \quad (4.20)$$

$$H = f(h) + \varsigma \quad (4.21)$$

其中噪声分布  $\varsigma \sim N(0, \sigma^2)$ ， $\sigma$  为标准差， $M(h)$  为均值函数：

$$M(h) = E(f(h)) \quad (4.22)$$

$R(h_1, h_2)$  为协方差函数：

$$R(h_1, h_2) = E\left[(f(h_1) - M(h_1))(f(h_2) - M(h_2))^T\right] \quad (4.23)$$

若存在模型中心点均值函数  $\mu(h)$ ，则  $H$  也一定服从高斯分布：

$$H \sim N(\mu(h), R(h_1, h_2) + \sigma^2) \quad (4.24)$$

若  $h$  满足  $D$  维高斯分布  $N(\mu, \Sigma)$ ， $\mu$  表示均值， $\Sigma$  表示方差，则  $h$  能划分成  $D_1$  维的  $h_a$  和  $(D-D_1)$  维的  $h_b$ ：

$$h = \begin{bmatrix} h_a \\ h_b \end{bmatrix} \quad (4.25)$$

$$\mu = \begin{bmatrix} \mu_a \\ \mu_b \end{bmatrix} \quad (4.26)$$

$$\Sigma = \begin{bmatrix} \Sigma_{aa} & \Sigma_{ab} \\ \Sigma_{ba} & \Sigma_{bb} \end{bmatrix} \quad (4.27)$$

则有条件概率分布  $p(h_b | h_a)$  一定满足高斯分布  $N(\mu_{b|a}, \Sigma_{b|a})$ ，并且该高斯分布中的参数表达式为：

$$p(h_b | h_a) \sim N(\mu_{b|a}, \Sigma_{b|a}) \quad (4.28)$$

$$\mu_{b|a} = \Sigma_{ba} \Sigma_{aa}^{-1} (h_a - \mu_a) + \mu_b \quad (4.29)$$

$$\Sigma_{b|a} = \Sigma_{bb} - \Sigma_{ba} \Sigma_{aa}^{-1} \Sigma_{ab} \quad (4.30)$$

根据公式 (4.21)，若模型测试样本输入  $h^*$ ，则输出  $H^*$ ：

$$H^* = f(h^*) + \varsigma \quad (4.31)$$

则  $H^*$  与  $H$  的联合概率函数为：

$$p(H^*, H) = \sum_{i=1}^N \alpha_i GP(H^*, H | \mu_i, \Sigma_i) = \sum_{i=1}^N \alpha_i GP(H^* | H, f_i^{\wedge}(H), \sigma_i^2) \quad (4.32)$$

$$\text{其中 } \mu_i = [\mu_{iH^*}, \mu_{iH}]^T, \quad \Sigma_i = \begin{bmatrix} \Sigma_{iHH} & \Sigma_{iHH^*} \\ \Sigma_{iH^*H} & \Sigma_{iH^*H^*} \end{bmatrix}, \quad \sum_{i=1}^N \alpha_i = 1, \quad f_i^{\wedge}(H) = E(H^* | H) = \mu_{H^*|H},$$

$$\sigma_i^2 = R(H^* | H) = \Sigma_{H^*|H}.$$

根据多维高斯分布性质，那么  $H^*$  与  $H$  的条件概率函数为：

$$p(H^* | H) = \sum_{i=1}^N \Phi_i(H) GP(H, \mu_{H^*|H}, \Sigma_{H^*|H}) \quad (4.33)$$

其中，混合权重：

$$\Phi_i(H) = \frac{\alpha_i GP(H, \mu_{iH}, \Sigma_{iH})}{\sum_{i=1}^N \alpha_i(H, \mu_{iH}, \Sigma_{iH})} \quad (4.34)$$

均值：

$$\mu_{H^*|H} = \sum_{iH^*H} \sum_{iHH}^{-1} (H - \mu_{iH}) + \mu_{iH^*} \quad (4.35)$$

协方差：

$$\Sigma_{H^*|H} = \Sigma_{iH^*} - \Sigma_{iH^*H} \Sigma_{iHH}^{-1} \Sigma_{iHH^*} \quad (4.36)$$

因此，已知训练样本  $Tra = \{h, H\}$ ，测试样本  $Tes = \{h^*, H^*\}$ ，根据上述  $H$  与  $H^*$  的联合概率和条件概率来预测  $H^*$ ，则最终的回归估计函数为：

$$H_{\text{pre}}^* = \sum_{i=1}^N \Phi_i(H) f_i^*(H) = \sum_{i=1}^N \Phi_i(H) E(H^* | H) = \sum_{i=1}^N \Phi_i(H) \mu_{H^*|H} \quad (4.37)$$

#### 4.4.2 轨迹预测

为了构建高效的预测模型，选择车辆实时横坐标  $x$ 、纵坐标  $y$  和航向角  $\theta$  作为关键输入特征。因此，定义模型的训练样本集： $Tra = \{x, y, \theta\}$ ，其中  $Tra^x = \{(x_i)\}_{i=1}^N$ ， $Tra^y = \{(y_i)\}_{i=1}^N$  和  $Tra^\theta = \{(\theta_i)\}_{i=1}^N$ ， $N$  是样本数量，每个  $i$  对应一个具体的采样时刻。然后分别建立基于  $x$ 、 $y$  和  $\theta$  的回归预测模型来对目标车辆轨迹进行描述。

由于五次多项式能充分描述车辆位置随时间复杂变化的动态特性，同时在计算路径时能够提供足够的灵活性，以适应各种路况和驾驶策略<sup>[60]</sup>，故将  $x$  和  $y$  的均值函数写成：

$$M(t)_x = a_0 + a_1 t + a_2 t^2 + a_3 t^3 + a_4 t^4 + a_5 t^5 \quad (4.38)$$

$$M(t)_y = b_0 + b_1 t + b_2 t^2 + b_3 t^3 + b_4 t^4 + b_5 t^5 \quad (4.39)$$

由于二次函数能精确捕获  $\theta$  与时间的非线性动态关系，同时保持计算效率，适应系统的实时性需求，故将其均值写成：

$$M(t)_\theta = c_0 + c_1 t + c_2 t^2 \quad (4.40)$$

为减少均值参数对协方差的干扰，引入指数核函数<sup>[61]</sup>作为 GPR 的协方差函数：

$$R(t_1, t_2)_x = \exp\left(-\frac{\|t_1 - t_2\|}{2\sigma_x^2}\right) \quad (4.41)$$

$$R(t_1, t_2)_y = \exp\left(-\frac{\|t_1 - t_2\|}{2\sigma_y^2}\right) \quad (4.42)$$

$$R(t_1, t_2)_\theta = \exp\left(-\frac{\|t_1 - t_2\|}{2\sigma_\theta^2}\right) \quad (4.43)$$

以普通型样本为例，模型训练后的换道轨迹相关参数如表 4.1、表 4.2 所示。

表 4.1 左换道轨迹参数

	均值函数参数	协方差函数参数
横坐标 $x$	$M(t)_x : (a_0, a_1, a_2, a_3, a_4, a_5)$ (0.325, 9.721, 0.742, -0.738, 0.239, -0.025)	$R_x = 0.075$
纵坐标 $y$	$M(t)_y : (b_0, b_1, b_2, b_3, b_4, b_5)$ (0.271, 1.311, -3.695, 3.837, -1.302, 0.137)	$R_y = 0.178$
航向角 $\theta$	$M(t)_\theta : (c_0, c_1, c_2)$ (-6.412, 18.625, -4.873)	$R_\theta = 0.091$

表 4.2 右换道轨迹参数

	均值函数参数	协方差函数参数
横坐标 $x$	$M(t)_x : (a_0, a_1, a_2, a_3, a_4, a_5)$ (0.240, 9.688, 0.701, -0.695, 0.234, -0.025)	$R_x = 0.083$
纵坐标 $y$	$M(t)_y : (b_0, b_1, b_2, b_3, b_4, b_5)$ (0.085, -1.181, 3.634, -3.710, 1.270, -0.139)	$R_y = 0.180$
航向角 $\theta$	$M(t)_\theta : (c_0, c_1, c_2)$ (-6.387, 18.245, -4.716)	$R_\theta = 0.092$

若在  $t \in (0, k)$  内, 车辆横坐标  $X = \{x_1, x_2, \dots, x_k\}$ , 相邻横坐标间的增量  $\Delta x_k = \{x_{k+1} - x_k\}_{k=1}^{N-1}$ ,

则下一时刻横坐标  $x_{k+1} = x_k + \Delta x_k$ 。

故预测问题可转化成对位置增量  $\Delta x_k$  的预测计算, 根据公式 (4.37) 能够得出  $\Delta x_k$  的回归估计函数为:

$$\Delta x_k^* = \sum_{i=1}^N \Phi_i(x) f_i^{\wedge}(\Delta x) \quad (4.44)$$

所以, 在  $t=k+1$  时, 车辆横坐标预测值  $x_{k+1}^* = x_k + \Delta x_k^*$ 。同理,  $y_{k+1}^* = y_k + \Delta y_k^*$ ,  $\theta_{k+1}^* = \theta_k + \Delta \theta_k^*$ 。

假设给定在  $t=k+1$  时, 车辆轨迹信息  $TR_{k+1} = \{x_{k+1}, y_{k+1}, \theta_{k+1}\}$ , 可得轨迹预测的误差为:


$$\Delta TR_{k+1} = \sqrt{(x_{k+1}^* - x_{k+1})^2 + (y_{k+1}^* - y_{k+1})^2} = \sqrt{((x_k + \Delta x_k^*) - x_{k+1})^2 + ((y_k + \Delta y_k^*) - y_{k+1})^2} \quad (4.45)$$

航向角的预测误差为:


$$\Delta \theta_{k+1} = |\theta_{k+1}^* - \theta_{k+1}| = |(\theta_k + \Delta \theta_k^*) - \theta_{k+1}| \quad (4.46)$$

## 4.5 实验结果分析


本文以普通型左换道和右换道轨迹为例, 使用不同历史时长 (1s、2s、3s 和 4s) 和横向位置对轨迹预测结果进行分析, 如图 4.6 和图 4.7 中的(a)~(h)所示, 每幅图中包括了历史轨迹、原型轨迹、实际轨迹、预测期望轨迹及其置信区间。分析可知, 虽然初始阶段原型轨迹和实际轨迹有一定的偏差, 但是随着历史轨迹时长 (也是该时长内的实际轨迹) 的扩大, 原型轨迹与历史轨迹的吻合度提高, 预测期望轨迹也越来越接近实际轨迹, 表明了预测准确性的提升。图中预测期望轨迹的置信区间反映了未来轨迹出现于此范围内的可能性较大, 基本覆盖了实际轨迹, 展现出 GPR 在概率性轨迹预测上的良好效果。




(a)



(b)




(c)




(d)

图 4.6 左换道横向位置轨迹预测结果



(e)



(f)

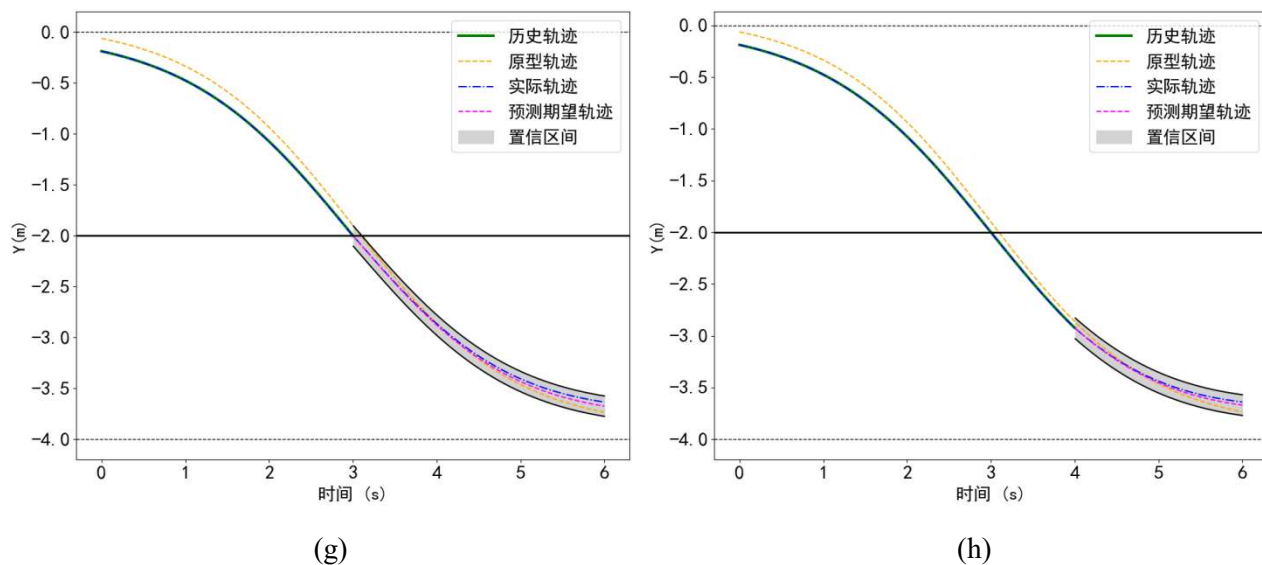


图 4.7 右换道横向位置轨迹预测结果

同时，本文采用轨迹预测领域常用的卡尔曼滤波算法和近年来较新的 LSTM 算法作为基准对比算法，与 GPR 预测结果进行了对比分析。通过比较图 4.8 和 4.9 中的预测结果发现，在处理具有明显非线性特征的换道轨迹时，GPR 在整个范围内更贴合实际轨迹，展现了其出色的适应性和稳定性，提供了更准确的轨迹预测。相较之下，卡尔曼滤波在非线性较强的情况下预测精度明显下降，尤其是在位置变化较大时。此外，尽管 LSTM 在处理时间序列数据时具有潜力，但在本文场景下，受数据集规模和模型易过拟合的限制，导致其在快速变化的交通场景中未能高效捕捉到关键特征，从而使得预测精度较 GPR 稍显不足。




图 4.8 左换道轨迹预测算法对比结果






图 4.9 右换道轨迹预测算法对比结果

另外，本文为说明 GPR 算法预测轨迹的准确性，对左换道和右换道下的不同轨迹预测算法误差进行对比，见表 4.3。分析可得，在轨迹预测方面，GPR 的误差范围更窄，误差均值也明显低于卡尔曼滤波算法和 LSTM 算法。

表 4.3 不同车辆行为下轨迹预测算法误差对比				
车辆行为		卡尔曼滤波算法	LSTM 算法	GPR 算法
左换道	误差波动范围	0.004~0.258	0.002~0.181	0.002~0.165
	误差均值	0.131	0.091	0.083
右换道	误差波动范围	0.004~0.250	0.002~0.168	0.002~0.153
	误差均值	0.127	0.085	0.077

综合实验结果表明，GPR 能够有效利用历史数据中的非线性模式进行轨迹的精确预测，并通过置信区间提供预测的不确定性估计，显示出其在复杂城市道路交通环境中车辆轨迹预测的优越性和可靠性。

4.6 本章小结

在自动驾驶技术领域，为确保智能车辆在复杂交通环境中的安全与高效运行，对前车的轨迹进行准确预测至关重要。鉴于此，本文在前一章识别前车行为算法基础上，进一步深入探讨了如何基于这些行为特征，预测前车短期内的行驶轨迹。

首先，本章详细介绍了数据采集过程，包括通过 PreScan 仿真平台构建的模拟城市道路

环境，以及在此环境中的数据采集策略，所有数据都经过了严格的筛选和标准化处理。

接下来，重点讨论了换道轨迹的聚类特征选择，重要特征包括横向加速度、航向角和车速。这些特征不仅反映了驾驶员的操作强度，还揭示了驾驶风格的倾向。基于这些特征，采用 **K-means** 算法进行了初步聚类，随后通过 EM 算法优化 GMM 参数，并通过平均化处理得到三类换道风格下的原型轨迹，从而提高了换道风格聚类的准确性和预测模型的可靠性。

最后，通过构建高斯过程回归模型来建模预测前车换道轨迹。**GPR** 的建模过程体现了其非线性和概率性特质，能够精确捕捉和模拟复杂的驾驶行为。实验结果表明，随着历史数据长度的增加，预测的精确性显著提高，模型生成的置信区间有效覆盖了实际轨迹，且误差明显低于卡尔曼滤波算法和 **LSTM**，进一步验证了其在动态交通环境中轨迹预测的实用价值。

## 第五章 车辆安全换道模型及其最优轨迹规划

在智能交通系统中，轨迹规划是保证智能车辆安全和效率的核心组成部分。基于前两章中成功识别的前车行为及其轨迹预测，本章进一步探讨如何规划出智能车辆安全高效的最优轨迹。尽管现有方法在特定场景下表现优异，但往往难以兼顾环境的动态性，另外大部分研究集中在高速公路上，缺乏对城市道路或其他类型道路的适用性。为了解决以上问题，本文利用五次多项式的多目标优化方法，结合前车的行为轨迹，提出一种动态环境下基于圆形安全距离模型的城市道路主车最优轨迹规划方法，旨在避免与周围相邻车道车辆碰撞以提高换道过程中的安全性，并通过分析前车行为和预测轨迹，设计出合适的路线策略，以适应复杂多变的行驶环境。本章将重点讨论圆形安全距离模型的建立以及换道轨迹规划在五次多项式中的应用，并通过建立综合评价指标函数来筛选出最优轨迹。

### 5.1 车辆换道安全特性分析

车辆在多车道环境中进行换道时，必须仔细观察周围车辆状态以确保安全。鉴于连续多次换道可视作双车道换道行为的重复，故本文主要聚焦于双车道间的换道，并为避免来自对面车道和非机动车的干扰，建立一个简单的全封闭的城市单向三车道直行路段换道场景如图 5.1 所示，设  $M$  为换道主车，在中间车道行驶， $M2$  和  $M1$  分别是同车道前车和后车， $L2$  是左车道前车， $L1$  是左车道后车， $R2$  是右车道前车， $R1$  是右车道后车。




图 5.1 城市三车道换道场景

在跟驰模型中<sup>[62]</sup>，主车的轨迹规划主要受到前车及周围环境的影响。由于后车  $M1$  只处于跟驰状态，通常只需调整其速度和距离即可适应主车  $M$  的变动，故在本章场景模型中不用考虑  $M1$  对主车  $M$  轨迹规划的影响。另外，本文旨在探究主车在前车行为不确定的情况下如何规划出主车最优轨迹，故  $M2$  对主车  $M$  轨迹规划的影响也先暂不考虑，以便在后续工况中

讨论。本文通过最小纵向安全换道距离研究 L1、L2、R1、R2 的位置状态对 M 车换道的安全影响<sup>[63]</sup>，只有当 M 与目标车道的前后车满足安全距离要求时，才可换道。设定周围车道车辆保持匀速运动，M 车以恒定加速度换道；L 为车长，通常取 4m；W 为车宽，通常取 1.8m；不同方向上速度变化互不影响，即换道所形成纵向夹角较小。

若换道过程中，M 车与周围车辆的最小纵向距离未达到安全标准，则可能出现如下情况：

- ①M 车左换道后，与 L1 侧向刮擦或追尾；②M 车左换道时加速太快，与 L2 斜向或追尾碰撞；
- ③M 车右换道后，与 R1 侧向刮擦或追尾；④M 车右换道时加速过快，与 R2 斜向或追尾碰撞。

为确保安全，车辆在加速换道完成后应调整速度以匹配目标车道的流速。通过这种速度调整，若 M 在换道后未与目标车道前车或后车发生碰撞，则其后续行驶中也不会碰撞。图 5.2 展示了换道过程中车辆 M 与 A 的位置关系。以两车右前 endpoint 作为参考点，记初始时刻  $t_0$  时 M 车与 A 车距离为  $S_0$ ， $\theta$  为 M 车换道时与水平线形成的夹角。




图 5.2 换道位置关系

结合跟驰最小安全距离公式，为避免发生侧碰，则在时刻  $t$  两车最小安全距离  $S(t)$  满足<sup>[64]</sup>：

$$S(t) = S_0 + \int_0^t \int_0^\tau (a_A - a_M) dt d\tau + (V_A - V_M) dt - L - W \sin \theta > 0 \quad (5.1)$$

式中，W 为车宽；L 为车长； $a$  为加速度； $V$  为速度。

为避免发生追尾，应满足：

$$S(t) = S_0 + \int_0^t \int_0^\tau (a_A - a_M) dt d\tau + (V_A - V_M) dt - L > 0 \quad (5.2)$$

分析表明，若最小安全距离  $S(t)$  符合公式 (5.1) 要求，则一定也符合公式 (5.2) 要求，故初始时刻距离  $S_0$  满足：

$$S_0 \geq \int_0^t \int_0^\tau (a_M - a_A) dt d\tau + (V_M - V_A) dt + L + W \sin \theta \quad (5.3)$$

$$\text{即 } S_0 \geq S_M - S_A + L + W \sin \theta \quad (5.4)$$

故为避免碰撞，设定  $S_0$  最小值为：

$$\min S_0 = \max \left[ \int_0^t \int_0^\tau (a_M - a_A) dt d\tau + (V_M - V_A) dt + L + W \sin \theta \right] \quad (5.5)$$

其中  $\tan \theta = \frac{V_x(t)}{V_y(t)}$ ,  $V_x(t)$  和  $V_y(t)$  分别为车辆横向、纵向位移速度。

### 5.1.1 M 车与 L1/R1 车之间的最小纵向安全距离

如图 5.3 所示, 左换道时 M 车可能与 L1 发生斜向或追尾碰撞。为避免两车碰撞, 设  $t_a$  为主车 M 完成加速的时间, 则需满足:

$$S_0 \geq S_{L1} - S_M + L + W \sin \theta \quad (5.6)$$

式中,  $S_M$ 、 $S_{L1}$  分别为  $t_a$  时段内两车所行驶的纵向位移。




图 5.3 M 车与 L1 车发生碰撞位置关系图

假设  $a_M$  为 M 车换道加速度, 故  $t_a = (V_M - V_{L1}) / a_M$ , 则 M 车在加速时间内的纵向位移为:

$$S_M = \frac{V_M^2 - V_{L1}^2}{2a_M} = \frac{V_M + V_{L1}}{2} \frac{V_M - V_{L1}}{a_M} = \frac{V_{L1} + V_M}{2} t_a \quad (5.7)$$

根据车辆换道安全特性分析设定, 周围车道车辆均保持匀速, 故 L1 在  $t_a$  时段内的纵向位移为:  $S_{L1} = v_{L1} t_a$ 。所以主车 M 与 L1 的最小纵向安全距离表示为:

$$S_{MSDL1}(0) = V_{L1} t_a - \frac{V_{L1} + V_M}{2} t_a + L + W \sin \theta = \frac{(V_{L1} - V_M)^2}{2a_M} + L + W \sin \theta \quad (5.8)$$

同理, M 车与 R1 最小纵向安全距离:

$$S_{MSDR1}(0) = V_{R1} t_a - \frac{V_{R1} + V_M}{2} t_a + L + W \sin \theta = \frac{(V_{R1} - V_M)^2}{2a_M} + L + W \sin \theta \quad (5.9)$$

### 5.1.2 M 车与 L2/R2 车之间的最小纵向安全距离

如图 5.4 所示, 左换道时 M 车可能与 L2 发生斜向或追尾碰撞。为避免两车碰撞, 设  $t_a$

为主车 M 完成加速的时间，则需满足：

$$S_0 \geq S_M - S_{L2} + L + W \sin \theta \quad (5.10)$$

式中： $S_{L2}$  为加速时间段内 L2 车所行驶的纵向位移。




图 5.4 M 车与 L2 车发生碰撞位置关系图

若  $a_M$  是主车换道加速度，则  $t_a = (V_{L2} - V_M) / a_M$ 。M 车在加速时间内的纵向位移为：

$$S_M = \frac{V_{L2}^2 - V_M^2}{2} = \frac{V_{L2} + V_M}{2} \frac{V_{L2} - V_M}{a_M} = \frac{V_{L2} + V_M}{2} t_a \quad (5.11)$$

L2 保持匀速，故在  $t_a$  时段内，其纵向位移为： $S_{L2} = v_{L2} t_a$ 。则 M 车与 L2 的最小纵向安全距离为：

$$S_{MSDL2}(0) = \frac{V_{L2} + V_M}{2} t_a - V_{L2} t_a + L + W \sin \theta = \frac{(V_{L2} - V_M)^2}{2a_M} + L + W \sin \theta \quad (5.12)$$

同理，M 车与 R2 的最小纵向安全距离为：

$$S_{MSDR2}(0) = \frac{V_{R2} + V_M}{2} t_a - V_{R2} t_a + L + W \sin \theta = \frac{(V_{R2} - V_M)^2}{2a_M} + L + W \sin \theta \quad (5.13)$$

## 5.2 圆形安全距离模型的建立

本章借鉴无人机领域中的第一距离与第二距离的概念<sup>[65]</sup>，结合上文介绍的最小纵向安全距离，提出一个圆形安全距离模型，用以判定车辆的安全区域。在无人机领域里，第一距离表示无人机在悬停过程中通过雷达探测到的初始障碍物与无人机之间的距离，是在预设时间前获得的信息。第二距离表示无人机预设时间后再次通过雷达探测到的障碍物与无人机之间的距离信息，通过第一距离和第二距离来判断是否为移动障碍物以进行避障。将这一思路应用于圆形安全距离模型中，对无人机领域中的“第一距离”和“第二距离”的概念进行了重新定义和调整，以适应智能车辆在城市道路场景中的安全需求。在此模型中，车辆的第一距

离定义为车辆当前时刻与附近车辆障碍物的距离，相应地，第二距离是在第一次测量后一段时间后，重新测量到的与同一障碍物的距离。定义一个圆形的安全区域，将第一距离、第二距离和圆形半径比较，当周围车辆位于这个圆外安全区域内时，可直接换道；否则需通过调整车速以满足最小安全距离要求后，方可执行换道。这一模型的设计旨在增强自动驾驶系统的实时判断和反应能力，提高道路安全性。

记  $S_{MSD} = \max\{S_{MSDL1}(0), S_{MSDL2}(0), S_{MSDR1}(0), S_{MSDR2}(0)\}$ ，在给定的车辆换道环境中，确定以 M 车为圆心，半径  $r = S_{MSD}$  的圆，根据车辆第一距离、第二距离变化进行动态调整，M 车根据圆形安全距离换道场景如图 5.5 所示，考虑以下步骤：




图 5.5 M 车根据圆形安全距离换道场景图

步骤 1：获取车辆信息。使用传感器（如雷达、摄像头等）获取初始时刻 M 车、L2 车、L1 车、R1 车、R2 车的位置、速度、加速度等信息。

步骤 2：计算第一距离。根据 M 车的位置和方向，以及其他车辆的位置信息，计算初始时刻出（两车中心相距距离）M 车到 L2 车、M 车到 L1 车的距离为第一左换道距离，M 车到 R1 车、M 车到 R2 车的距离为第一右换道距离，并记录下来。为提高换道时间效率，将圆形安全距离模型分为左换道半圆和右换道半圆，如图 5.6 和图 5.7 所示。




图 5.6 M 车根据圆形安全距离左换道场景图




图 5.7 M 车根据圆形安全距离右换道场景图

步骤 3：根据圆形安全距离判定安全车辆。

判断周围车辆是否位于 M 车的圆外，根据第一距离信息，通过圆形安全距离范围半径判断哪些车辆被认为是在圆形范围外的安全车辆，可以排除掉不需要考虑的车辆。将第一左换道距离与左换道半圆形范围半径  $r_L$  比较，第一右换道距离与右换道半圆形范围半径  $r_R$  比较。判断比较过程如下：

①若所有第一左换道距离  $> r_L$ ，所有第一右换道距离  $> r_R$ ，则周围车辆都位于 M 车的圆外安全区域，M 车可以任意换道。以左换道（即 M 车当前车道和左边车道）为例，综合换道效率，若  $r_L < r_R$ ，则表示左换道的半圆范围半径小，则需要换道的位移小，换道时间则短，此时 M 车就选择左换道。右换道同理。

②若所有第一左换道距离  $> r_L$ ，并非所有第一右换道距离  $> r_R$ ，则左换道半圆车辆都位于 M 车的圆外安全区域，M 车可以进行左换道。

③若并非所有第一左换道距离  $> r_L$ ，所有第一右换道距离  $> r_R$ ，则右换道半圆车辆都位于 M 车的圆外安全区域，M 车可以进行右换道。

④若并非所有第一左换道距离  $> r_L$ ，并非所有第一右换道距离  $> r_R$ ，则无论左换道还是右换道，都存在周围车辆位于 M 车的圆内危险区域，则标记该车为危险车辆，视为不安全换道，M 车继续行直行，间隔  $t_i$  时间后继续记录标记过的危险车辆位置并计算其与 M 车的距离记为第二距离，转至步骤 4 并进行判断。

步骤 4：比较第一距离和第二距离的值。若该车的第一距离与第二距离的差值大于圆半径，则认为该车对 M 车换道没有影响即为安全车辆，M 车可以安全换道。否则，则 M 车继续行直行，返回之前步骤 2，重新以该时刻为新的起点，计算当前情况下车辆与 M 车距离为新的第一距离并执行后续判断比较过程直至可以安全换道。

车辆安全换道流程如图 5.8 所示。



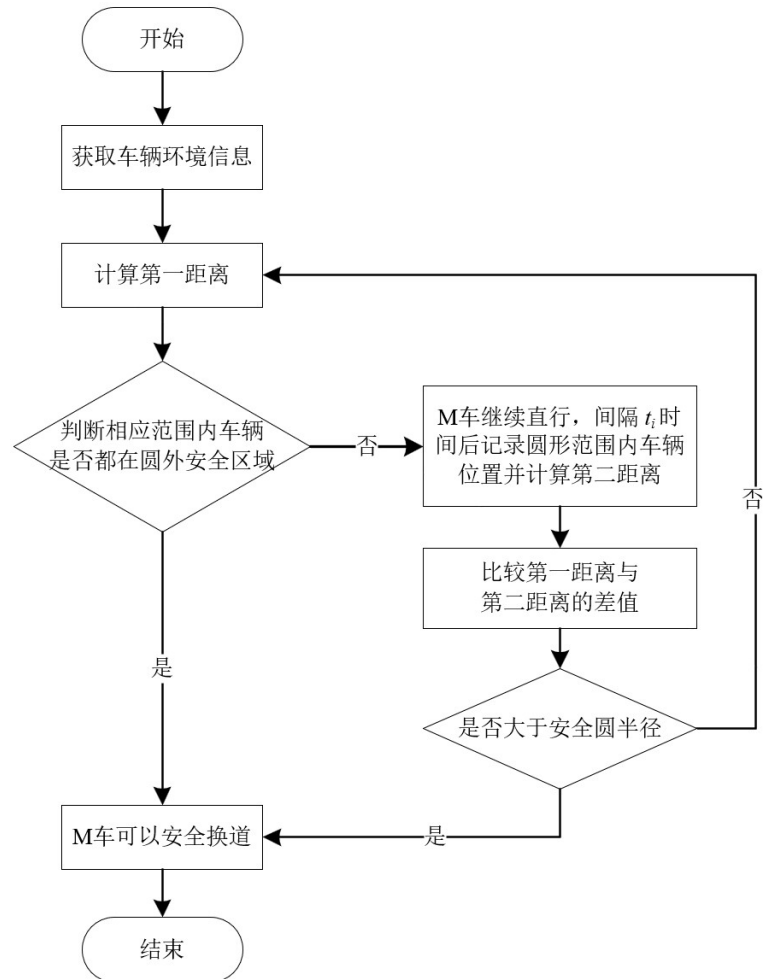


图 5.8 车辆安全换道流程图

由此可见，圆形安全距离模型的引入可以改进动态交通环境适应性。该模型通过定义车辆间的第一距离和第二距离，使得换道决策可以根据实时交通状况动态调整，从而提高响应速度并优化安全距离管理。具体地，通过在不同时间点测量与附近车辆的距离，此模型能够判断其他车辆的运动趋势和速度变化，进而动态确定换道行为的安全性。此外，将安全距离模型分为左换道和右换道的半圆，进一步增强了决策的灵活性和精确性，允许系统根据具体的道路情况和周围车辆的位置做出更加精确的换道决策。这种方法不仅减少了计算量，提高了换道操作的效率，也确保了在高速且复杂的交通流中自动驾驶系统的安全性和可靠性。因此，圆形安全距离模型为智能车辆提供了一种更加动态和高效的方式来应对城市道路的实时交通挑战。

5.3 基于安全距离模型和前车行为轨迹的主车路径簇生成

主车轨迹首先依赖于前车的行为分析。根据前车是否换道和圆形安全距离模型，主车的行驶路线分为以下两种基本情况：

情况 1：如果前车 M2 进行换道，主车 M 将继续直行，保持安全距离，避免不必要的换

道行为，从而减少交通干扰和潜在碰撞风险。

情况 2：如果前车 M2 保持当前车道不变，主车 M 将根据当前的交通情况和预设的安全距离模型决定其换道行为。

由于情况 1 主车轨迹为简单的直行路线，故本文重点研究情况 2 即主车的换道路径簇生成。五次多项式因其能够提供连续一阶和二阶导数（即速度和加速度），非常适合用于生成平滑的车辆运动轨迹以避免车辆在换道时产生急剧加速或减速<sup>[66]</sup>，从而提高乘坐舒适性并减少事故风险。此外，五次多项式还具备曲率连续性和高度的场景适应性，使其能够灵活应对各种道路条件并轻松集成各种状态约束<sup>[67]</sup>。这些特性确保了所生成的路径不仅符合物理行驶要求，而且在换道轨迹规划中得到了广泛应用。为有效地模拟真实驾驶情况下基于前车行为分析结果的车辆轨迹，本文采用基于五次多项式的主车换道路径簇生成方式。具体步骤如下：

（1）定义轨迹边界条件：在轨迹规划中，车辆的起始位置和结束位置是已知的。同样，起始和结束时的速度和加速度也需要被明确定义。通常，换道开始和结束时车辆的速度应接近或等于交通流的速度，而加速度应接近零，以避免产生急剧的速度变化。

（2）起点和终点设定：起点由当前车辆的位置和速度确定，结合驾驶员的换道意图和周围车辆的行为，多个潜在终点则根据主车当前位置和预计的换道完成时间设定。这些终点沿目标车道的中心线布置，考虑侧向和纵向的位移。根据驾驶模型，设定换道时长为 4s，以此确定目标终点。通过对终点进行横纵向偏置变换，从而形成一个终点簇。

（3）路径采样：在主车起点和设定的潜在终点之间，根据车辆的动态性能和所需的换道时间采样生成多个换道路径。每个路径都有特定的侧向和纵向位移，这些位移间隔根据主车的速度和操作反应时间精确计算<sup>[68]</sup>。

采用五次多项式来表达换道路径，设定横坐标为  $x$ ，纵坐标为  $y$ ，起点与终点横坐标  $x_0$ 、 $x_1$ ，路径的参数为  $z_0$ 、 $z_1$ 、 $z_2$ 、 $z_3$ 、 $z_4$ 、 $z_5$ ，其数学形式如下所示：

$$y(x) = z_0 + z_1(x - x_0) + z_2(x - x_0)^2 + z_3(x - x_0)^3 + \cdots + z_4(x - x_0)^4 + z_5(x - x_0)^5 \quad (x_0 \leq x \leq x_1) \quad (5.14)$$

#### （4）条件约束

换道路径生成过程中，主要考虑约束包含起点与终点的侧向位移、速度方向和曲率，确保在实际驾驶中的可行性和安全性。设定  $y_0$  和  $y_1$  为路径起点与终点的纵坐标，则路径的约束为：

$$\begin{cases} y|_{x=x_0} = y_0, y'|_{x=x_0} = y'_0, y''|_{x=x_0} = y''_0 \\ y|_{x=x_1} = y_1, y'|_{x=x_1} = y'_1, y''|_{x=x_1} = y''_1 \end{cases} \quad (5.15)$$

## (5) 参数求解

利用已知的边界条件，可以通过求解线性方程组来确定这些系数。把约束条件代入公式 (5.14) 可得:

$$\begin{cases} y_0 = z_0 \\ y'_0 = z_1 \\ y''_0 = 2z_2 \\ y_1 = z_0 + z_1(x_1 - x_0) + z_2(x_1 - x_0)^2 + z_3(x_1 - x_0)^3 + z_4(x_1 - x_0)^4 + z_5(x_1 - x_0)^5 \\ y'_1 = a_1 + 2a_2(x_1 - x_0) + 3a_3(x_1 - x_0)^2 + 4a_4(x_1 - x_0)^3 + 5a_5(x_1 - x_0)^4 \\ y''_1 = 2a_2 + 6a_3(x_1 - x_0) + 12a_4(x_1 - x_0)^2 + 20a_5(x_1 - x_0)^3 \end{cases} \quad (5.16)$$

通过求解上述方程组，则具体的路径参数为:

$$\begin{cases} z_0 = y_0 \\ z_1 = y'_0 \\ z_2 = \frac{y''_0}{2} \\ z_3 = \frac{20y_1 - 20y_0 - 3y''_0x_1^2 - 12y'_0x}{2(x_1 - x_0)^3} \\ z_4 = \frac{30y_1 - 30y_0 - 3y''_0x_1^2 - 16y'_0x}{2(x_1 - x_0)^4} \\ z_5 = \frac{12y_1 - 12y_0 - y''_0x_1^2 - 6y'_0x_1}{2(x_1 - x_0)^5} \end{cases} \quad (5.17)$$

每个换道终点根据一组参数可生成相应路径。通过这些参数，从采样得到的终点簇中规划出多条可能的换道路径。图 5.9 和图 5.10 分别显示了生成的主车左换道和右换道备选路径簇，这些不同的路径对应于不同的行驶速度或者换道风格，以满足不同的驾驶安全和舒适性需求。从图中可以观察到，随着换道进行，生成主车的不同备选轨迹从一个车道到另一个车道的平滑地过渡，显示出了五次多项式曲线的连续性和平滑性。这些曲线的终点清晰地落在目标中心车道线范围附近，确保了换道过程的安全性和准确性。此外，所有曲线均在规定的位移范围内，表明了路径规划的高效性和执行的可控性。综上所述，本章采用的五次多项式能够对主车进行有效的轨迹规划。




图 5.9 主车左换道备选路径簇




图 5.10 主车右换道备选路径簇

## 5.4 最优轨迹规划

在智能车辆的轨迹规划中,采用五次多项式方法虽然可以确保路径的平滑性和连续性,但其在路径与速度的耦合处理上存在局限,难以保证路径的最优性和实时适应性<sup>[69]</sup>。这一局限性导致了在动态复杂的交通环境中,该方法可能无法实现最佳的导航效果。为弥补这一缺陷,从备选路径簇中选出最优轨迹,引入多目标综合评价指标函数成为了一种有效的策略<sup>[70]</sup>。

为选出最适合当前道路环境的最优轨迹，综合考虑以下指标函数组成要素：

(1) 安全性：本文采用圆形安全距离模型中的车辆的实时动态位置以及前车对碰撞的风险，来评估路径的安全性指标  $J_s$ ，量化了在换道过程中可能出现的碰撞风险，以避免碰撞提高安全性。

定义一个动态距离函数  $f_r$  来评析圆形安全距离模型中的车辆的实时动态位置对安全的影响。

$$f_r = \sum_{q=1}^Q \frac{1}{r - d_{clo}} \quad (5.18)$$

式中， $r$  是圆形安全距离模型的半径，考虑横向和纵向距离， $d_{clo}$  是车辆  $M$  在行驶过程中与当前最近的障碍车辆的中心直线距离， $Q$  为障碍车辆的数量。

对于前车  $M2$  对主车  $M$  碰撞的风险，本文定义一个特定的碰撞风险指数函数  $f_{clo}$ <sup>[71]</sup>：

$$f_{col} = \exp \left( - \frac{(d_{M,M2} - D_{safe})^2}{2 \times D_{safe}^2} \right) \quad (5.19)$$

$$D_{safe} = v_M \times T_r + \frac{v_M^2 - v_{M2}^2}{2 \times a_{max}} \quad (5.20)$$

其中  $D_{safe}$  是根据主车和前车的速度以及预期反应时间计算的安全距离， $v_M$  是主车  $M$  的当前速度， $v_{M2}$  是前车  $M2$  的当前速度， $d_{M,M2}$  是主车  $M$  与前车  $M2$  之间的当前距离， $a_{max}$  是主车的最大安全减速度， $T_r$  是反应时间。

选择该碰撞风险指数函数理由如下：首先，指数函数由于其高灵敏度，能够在车辆距离接近临界安全距离时迅速响应，即当主车  $M$  与前车  $M2$  之间的实际距离  $d_{M,M2}$  接近安全距离  $D_{safe}$ ，碰撞风险  $f_{clo}$  快速增加，从而提供一个强烈的风险警告，增强了模型对距离变化的捕捉能力，提升了安全性；其次，该函数的非线性特性能有效放大接近安全边界的危险，而在安全距离范围内则表现出较低的风险响应，利用其对靠近距离提供强烈的惩罚性，当距离超出阈值安全距离时即  $d_{M,M2} > D_{safe}$ ，函数值会指数级逼近 0，这意味着风险大幅降低，以确保在近距离情况下安全考虑占主导，这有助于系统在实际驾驶中做出更加平滑和连贯的决策；此外，指数函数在计算上高效且易于集成到实时系统中，适合自动驾驶系统的实时性需求<sup>[72]</sup>。

将动态距离函数  $f_r$  和碰撞风险指数函数  $f_{clo}$  结合，我们得到最终的安全性指标  $J_s$ ：

$$J_s = f_r + f_{col} = \sum_{q=1}^Q \frac{1}{r - d_{clo}} + \exp \left( - \frac{(d_{M,M2} - D_{safe})^2}{2 \times D_{safe}^2} \right) \quad (5.21)$$

(2) 舒适性：在智能车辆的轨迹规划中，平滑的速度变化是最大限度减少乘客不适感的关键因素，故本文计算轨迹的平均速度变化的平滑度来量化舒适性指标  $J_c$ ，车辆的平均速度变化越小，其舒适性越好。

$$J_c = \frac{1}{t_a} \int_0^{t_a} (v_M - v_0)^2 dt \quad (5.22)$$

式中， $t_a$  为主车换道过程的加速时间， $v_M$  为主车 M 当前速度， $v_0$  为主车换道初始速度。

(3) 效率：本文通过计算规划路径的行驶时间来评估效率指标  $J_e$ 。

$$J_e = \frac{D_{ch}}{v_M} \quad (5.23)$$

式中， $D_{ch}$  为 M 车完成最优轨迹规划时间内总位移， $\overline{v_M}$  为 M 车平均速度。该指标强调在保证安全和舒适的前提下，通过优化行驶轨迹和车速分配来最小化行驶时间，从而提高效率，增强系统的适应能力和实用性。

基于上述要素，可以构建一个综合的评价函数：

$$J_{be} = w_1 J_s + w_2 J_e + w_3 J_c \quad (5.24)$$

其中， $J_{be}$  是综合评价函数， $J_s$ 、 $J_c$ 、 $J_e$  分别代表安全性、舒适性、效率评价指标， $w_1$  到  $w_3$  是相应的权重系数，可以根据实际情况和需求进行调整。最终，根据这个综合评价函数来选择最优路径。

## 5.5 实验结果分析

本文通过 PreScan 与 MATLAB 进行联合仿真实验来搭建不同工况下的仿真场景，根据综合评价函数对主车的最优轨迹规划进行模拟，分析其有效性。设定限制条件：所有车辆初始速度均为 15m/s，除主车 M 和前车 M2 外其余车辆均匀速行驶，速度限制为 0 到 20 m/s，加速度限制为 -5 到 5m/s<sup>2</sup>，场景周期为 6 秒。

(1) 工况 1：设定前车 M2 执行换道操作，主车 M1 则保持直行，目标是验证主车在前车换道时能否保持安全距离并避免不必要的换道行为，实验设置见表 5.1。

表 5.1 工况 1 相关参数设置

车辆 ID	M	M2	M1	L1	L2	R1	R2
起始 $x$ 位置/m	0	25	-15	-10	15	-10	20
起始 $y$ 位置/m	0	0	0	4	4	-4	-4
起始航向角 $\theta$ /rad	0	10	0	0	0	0	0
起始速度 $v$ /(m/s)	15	15	15	15	15	15	15
运动状态	变化	变化	匀速	匀速	匀速	匀速	匀速

基于工况 1 中对安全性、舒适性和效率的均衡考虑，实验的综合评价函数权重如下：安全性权重  $\omega_1$ : 0.55，舒适性权重  $\omega_2$ : 0.25，效率性权重  $\omega_3$ : 0.2。在工况 1 中，前车执行换道操作可能会引起潜在的碰撞风险，因此安全性是首要考虑因素。较高的安全性权重可以确保主车在前车换道时保持足够的安全距离。舒适性次之，因为在确保安全的前提下，保证车辆运行的平稳性对乘客体验也很重要。效率在此场景中优先级最低，因为即使牺牲少许效率也需优先保证安全和舒适。前车换道情况下主车最优轨迹规划结果如图 5.11 和图 5.12 所示。




图 5.11 前车左换道情况下主车最优轨迹规划




图 5.12 前车右换道情况下主车最优轨迹规划

图中红色虚线显示了主车 M（绿色车辆）的最优轨迹，仿真结果表明，M 的轨迹平滑稳定，没有出现明显的偏移或不必要的加速度变化，这表明本文五次多项式轨迹规划算法在面对前车换道时，能够及时做出反应并保持稳定舒适的行驶状态。在整个过程中，主车 M 与周围车辆保持了安全距离，避免了潜在的碰撞风险，这验证了本文所提出的圆形安全距离模型在实际应用中的有效性。主车 M 成功避免了不必要的换道行为，展现了良好的效率性能。

（2）工况 2：前车 M2 保持当前车道不变且对主车无碰撞风险，但相邻车道前后车对主车有碰撞风险，主车 M1 则保持跟驰前车直行为最优轨迹。实验设置见表 5.2。

表 5.2 工况 2 相关参数设置

车辆 ID	M	M2	M1	L1	L2	R1	R2
起始 $x$ 位置/m	0	25	-15	-10	5	-10	5
起始 $y$ 位置/m	0	0	0	4	4	-4	-4
起始航向角 $\theta/\text{rad}$	0	10	0	0	0	0	0
起始速度 $v/(\text{m/s})$	15	15	15	15	15	15	15
运动状态	变化	匀速	匀速	匀速	匀速	匀速	匀速

基于工况 2 中对安全性、舒适性和效率的均衡考虑，实验的综合评价函数权重如下：安

全性权重  $\omega_1$ : 0.65, 舒适性权重  $\omega_2$ : 0.25, 效率性权重  $\omega_3$ : 0.1。此权重反映了安全性的至关重要性, 特别是在考虑到相邻车道的潜在碰撞风险时, 主车需要高度警觉并优先考虑避免碰撞。同时, 舒适性权重确保在避免潜在碰撞的同时, 主车的行驶轨迹尽量平稳, 以增强乘客体验。效率虽然重要, 但在这种情况下其优先级相对较低。工况 2 下仿真结果如图 5.13 所示, 图中红色虚线显示了主车 M (绿色车辆) 的最优轨迹, 仿真结果表明, 该工况综合评价函数下主车规划的最优轨迹成功有效地避免了与相邻车道的碰撞风险, 并跟驰前车直行。




图 5.13 工况 2 下主车最优轨迹规划

(3) 工况 3: 前车 M2 保持当前车道不变且对主车 M 有碰撞风险, 相邻右侧车道的前后车辆对 M 无碰撞风险, M 车执行右换道操作。为验证该工况下最优轨迹规划有效性, 实验设置见表 5.3。

表 5.3 工况 3 相关参数设置

车辆 ID	M	M2	M1	L1	L2	R1	R2
起始 $x$ 位置/m	0	20	-15	-10	15	-10	30
起始 $y$ 位置/m	0	0	0	4	4	-4	-4
起始航向角 $\theta/\text{rad}$	0	0	0	0	0	0	0
起始速度/(m/s)	15	15	15	15	15	15	15
运动状态	变化	变化	匀速	匀速	匀速	匀速	匀速

工况 3 的场景示意图如图 5.14 所示。




图 5.14 工况 3 场景示意图

在工况 3 中, 主车进行右换道操作。为了兼顾安全性和舒适性, 同时保证行驶效率, 权



重设置更为均衡，实验的综合评价函数权重如下：安全性权重  $\omega_1$ : 0.45，舒适性权重  $\omega_2$ : 0.3，效率性权重  $\omega_3$ : 0.25。安全性依然是首要考虑因素，但舒适性和效率的权重被提升，以确保车辆能够平稳且迅速地完成任务。工况 3 前车直行且有碰撞风险情况下主车右换道最优轨迹规划仿真结果如图 5.15 所示。




图 5.15 工况 3 下主车最优轨迹规划

图中红色虚线为规划出的主车最优轨迹，仿真结果表明，在右换道过程中，主车 M 的轨迹均展现出平滑性，未出现剧烈的速度或方向变化，证明了采用的五次多项式轨迹规划算法能够生成连续且平滑的路径，确保车辆行驶的舒适性。主车 M 为规避与前车碰撞风险提前变道，在换道过程中，主车 M 成功避开了前车 M2，并且与周围车辆保持了足够安全距离，展示了圆形安全距离模型的有效性和可靠性。根据综合评价函数，把所规划出的相对靠中间轨迹作为最优轨迹，从而减小换道总位移，体现了良好的行驶效率。

（4）工况 4：前车 M2 保持当前车道不变且对主车 M 有碰撞风险，主车 M 执行左换道操作，但换道时发现相邻车道后车 L1 与主车相距过近也存在碰撞风险。为验证该工况下最优轨迹规划有效性，实验设置见表 5.4。

表 5.4 工况 4 相关参数设置

车辆 ID	M	M2	M1	L1	L2	R1	R2
起始 $x$ 位置/m	0	20	-15	-5	30	-10	15
起始 $y$ 位置/m	0	0	0	4	4	-4	-4
起始航向角 $\theta$ /rad	0	0	0	0	0	0	0
起始速度/(m/s)	15	15	15	15	15	15	15
运动状态	变化	变化	匀速	匀速	匀速	匀速	匀速

工况 4 的场景示意图如图 5.16 所示。




图 5.16 工况 4 场景示意图

在工况 4 中，实验的综合评价函数权重如下：安全性权重  $\omega_1$ : 0.7，舒适性权重  $\omega_2$ : 0.2，效率性权重  $\omega_3$ : 0.1。安全性是智能车辆的首要考虑因素。在该场景中，主车 M 需要变道以避免前方的 M2 车辆，但同时也要避免与左侧车道的 L1 车辆发生碰撞。高安全性权重确保在规划过程中，避免碰撞的优先级最高。虽然舒适性重要，但在该工况的安全性面前，其优先级较低。因此，舒适性的权重相对较小，确保乘客体验不被完全忽视，同时不会妨碍紧急避险动作的执行。在避障情况下，效率性通常是次要考虑。在该场景中，主车 M 需要牺牲一些效率，如减速让行，以确保安全和舒适。工况 4 下主车左换道最优轨迹规划仿真结果如图 5.17 所示。




图 5.17 工况 4 下主车最优轨迹规划

图中红色标记曲线为规划出的主车最优轨迹，仿真结果表明，该工况综合评价函数下主车规划的最优轨迹成功有效地避免了前车与相邻车道后车的碰撞风险。主车 M 在识别到前方 M2 的碰撞风险后，尝试向左变道。但在换道过程中，主车 M 发现如果按照原计划的速度和

轨迹行驶，将会与左侧车道的后车有较高碰撞风险。故根据交通法规，主车 M 做出调整，其速度调整如图 5.18 所示，从图中可以看出，当发现 L1 的碰撞风险后，主车很快执行从 20m/s 到 5m/s 的减速以避免碰撞确保了安全性。主车在避障减速后，通过逐步平稳加速回到 15m/s，避免了乘客经历急转和震动，并通过平滑的轨迹调整保障了舒适性。同时根据综合评价函数，规划出的最优轨迹为相对靠前和中间的轨迹，减少了换道总路程，从而较快地完成换道过程，保证了整个行驶过程的效率。




图 5.18 工况 4 下主车速度调整

通过分析以上四个工况的实验结果可得，不同工况下，根据对安全性、舒适性和效率的不同需求，根据综合评价函数，调整相应评价指标的权重，可以有效规划出主车的最优轨迹。

## 5.6 本章小结

在本章中，详细介绍了基于圆形安全换道模型的车辆换道安全性评估方法及最优轨迹规划。结合最小纵向安全距离和无人机的距离避障，引入了一个的圆形安全距离模型来避免与目标车道车辆发生碰撞，并根据前车的行为轨迹情况分类讨论设计合适的换道策略，通过五次多项式生成主车换道备选路径簇，建立了考虑安全性、舒适性、效率的多目标综合评价指标函数来确定主车最优轨迹。实验结果表明，本文设计的综合评价函数在不同工况下的应用，能够高效地规划出最优轨迹，验证了其在轨迹规划中的实用性和有效性。未来研究可以在实际交通环境中进一步验证该方法，并考虑更加复杂的交通场景，以提升智能车辆的实际应用表现。

## 第六章 总结与展望

### 6.1 全文工作总结

随着智能车辆应用的不断发展,车辆行为识别、轨迹预测及轨迹规划被广泛研究和应用,有望满足复杂多变的各种交通场景要求。在此背景下,本文研究了城市道路智能车辆行为识别与安全轨迹问题,以满足智能交通系统需求,文章主要工作如下:

(1) 针对传统车辆行为识别方法特征选择繁琐、难以处理时序数据和多维数据的问题,提出一种 GM-HMM 来识别城市道路上目标车辆的行为。首先通过在 Prescan 平台上模拟城市三车道道路交通场景,并通过 Simulink 获取车辆运动状态数据。随后,通过精选特征参数并使用 Baum-Welch 算法训练模型参数,结合前后向算法,成功实现了对城市道路前车行为的准确识别。此外,还探讨了不同时间窗口大小对识别准确率的影响,确定了 2.0 秒的时间窗口为最优,该窗口下模型能有效捕捉车辆行为特征。最后实验结果表明,相对于其他算法,GM-HMM 结合了 HMM 和 GMM 的优势,通过利用 GMM 描述在特定隐状态下的观察数据分布,以及 HMM 处理状态转换的能力,GM-HMM 能够捕捉车辆行为的多样性和随时间的动态变化,从而更准确地识别车辆行为。

(2) 针对车辆轨迹预测中难以应对不同驾驶风格等不确定因素影响,导致预测精度和可靠性不足问题。在已知前车行为的情况下,考虑到驾驶风格这一不确定因素影响,进一步研究前车不同换道风格下的轨迹预测精度和可靠性,为规划主车最优安全轨迹奠定基础。从仿真数据集中筛选前车的经典换道轨迹,以横向加速度、航向角为聚类特征,使用高斯混合模型聚类出不同换道风格的原型轨迹,并根据 GPR 来获得预测轨迹,以指导主车进行安全换道。最后仿真实验验证该方法可以精确有效地预测出目标车辆轨迹,提高了预测精度和可靠性。

(3) 针对现有车辆轨迹规划研究集中在高速公路上,缺乏对城市道路或其他类型道路的适用性,且难以兼顾环境的实时动态性问题,提出一种动态环境下基于圆形安全距离模型的城市道路主车最优轨迹规划方法,首先建立圆形安全距离模型,再结合前车的行为轨迹,设计出合适的路线策略,利用五次多项式生成备选路径簇,最后通过构造综合评价指标函数来筛选智能车辆的最优轨迹,旨在避免与周围车辆碰撞以提高行驶过程中的安全性,规划出智能车辆安全高效的最优轨迹。最后仿真实验验证该方法能够兼顾场景的实时动态性,并成功规划出了主车安全高效的最优轨迹。

综上所述,本文针对城市道路智能车辆行为识别与安全轨迹研究的关键问题,提出了一

系列创新方法和策略,具有如下实际贡献:首先,在 Prescan 平台上模拟的城市道路交通场景中,相对于 BP、K-NN、RF、SVM、HMM 算法,本文的 GM-HMM 展现出更高的行为识别准确率。其次,在考虑不同驾驶风格的情况下,利用 GPR 对车辆轨迹进行预测,随着历史数据长度的增加,预测的精确性显著提高,模型生成的置信区间有效覆盖了实际轨迹,且误差明显低于卡尔曼滤波算法和 LSTM,进一步验证了其在动态交通环境中轨迹预测的实用价值。最后,提出的基于圆形安全距离模型和综合评价函数的主车轨迹规划方法表明,在不同工况下的实验分析中,该方法能够有效地规划出智能车辆最优轨迹。

## 6.2 未来展望

展望未来,随着智能车辆技术的不断进步和普及,城市道路的安全性、效率、舒适性将得到显著提升。本文研究工作还存在不足和改善之处,未来研究可以在以下几个方向进一步深入:

(1)本文提出的 GM-HMM 已经在城市道路车辆行为识别中表现出良好的效果,未来的研究可以探索更高效的算法和模型,如深度学习方法,以优化提高行为识别算法准确性。同时,可考虑引入更多类型的传感器数据,以增强模型对复杂交通环境的适应能力和鲁棒性。

(2)本文的轨迹预测模型已能够处理不同驾驶风格不确定性的影响,但仍需考虑更多轨迹预测的个性化和实时性需求。后续研究应聚焦于实时数据处理和在线学习机制的开发,针对不同天气条件和突发交通事件等更多不确定因素进行优化,以实现动态调整预测模型,从而更精确地应对快速变化的道路情况。

(3)本文研究了基于圆形安全距离模型的轨迹规划方法,有效提升了实时性和行驶安全性。未来可以进一步探讨其他多目标优化策略,如考虑能源效率、行驶时间、乘客舒适度等因素,实现更全面的轨迹优化。此外,增加机器学习元素,如强化学习,可能有助于在未知或变化环境中自适应地优化轨迹。

(4)随着城市智能化水平的提升,未来研究可考虑车辆行为与智能交通系统之间的更深层次整合。例如,通过车联网技术,实现车与车、车与路基础设施之间的实时通信和数据共享,以协同优化整个交通系统的运行效率和安全性。

(5)本文研究了城市三车道道路交通场景,后续可进一步研究多交叉路口、信号灯、其他道路场景等复杂情况。

## 参考文献

- [1] 国家统计局. 中国统计年鉴 2022[M]. 北京: 中国统计出版社, 2022.
- [2] 詹骄, 郭迟, 雷婷婷, 等. 自动驾驶地图的数据标准比较研究[J]. 中国图象图形学报, 2021, 26(1): 36-48.
- [3] 曹立波, 陈峥, 颜凌波, 等. 基于RFID, 视觉和UWB 的车辆定位系统[J]. 汽车工程, 2017, 39(2): 225-231.
- [4] 郭凯红, 李博昊, 宗晓瑞, 等. 基于改进人工势场的避障路径规划策略研究[J]. 舰船科学技术, 2021, 43(7): 54-57.
- [5] 王润民, 胡锦涛, 任亮, 等. 基于多传感器的智能车辆姿态解算方法[J]. 测控技术, 2016, 35(9): 6-11.
- [6] Li Y, Xue F, Feng L, et al. A driving behavior detection system based on a smartphone's built - in sensor[J]. International Journal of Communication Systems, 2017, 30(8): 1-13.
- [7] 袁伟, 张亚岐, 王畅. 支持向量机在换道行为识别中的应用研究[J]. 计算机工程与设计, 2013, 34(2): 643-648.
- [8] 王相海, 丛志环, 方玲玲, 等. 基于HMM的车辆行驶状态实时判别方法研究[J]. 自动化学报, 2013, 39(12): 2131-2142.
- [9] Xing Z. Driver's intention recognition algorithm based on recessive Markoff model[J]. Journal of Intelligent & Fuzzy Systems, 2020, 38(2): 1603-1614.
- [10] 熊晓夏, 陈龙, 梁军, 等. 危险换道驾驶行为预测方法研究[J]. 汽车工程, 2017, 39(9): 1040-1046.
- [11] Sun Q, Wang C, Fu R, et al. Lane change strategy analysis and recognition for intelligent driving systems based on random forest[J]. Expert Systems with Application, 2021, 186(12): 1-14.
- [12] Lee J H, Lim S, Ahn C W. Automotive ecu data-based driver's propensity learning using evolutionary random Forest[J]. IEEE Access, 2019, 1(1): 51899-51906.
- [13] Gao J, Yi J, Murphey Y L. Multi-scale space-time transformer for driving behavior detection[J]. Multimedia tools and Applications, 2023, 82(16): 24289-24308.
- [14] Guo H, Keyvan-Ekbatani M, Xie K. Lane change detection and prediction using real-world connected vehicle data[J]. Transportation research part C: emerging technologies, 2022, 142(9): 142-163.
- [15] Zhang Y, He Y, Zhang L. Recognition method of abnormal driving behavior using the bidirectional gated recurrent unit and convolutional neural network[J]. Physica A: Statistical Mechanics and its Applications, 2023, 3(5): 609-627.
- [16] Zhang Y, Zou Y, Tang J, et al. Long-term prediction for high-resolution lane-changing data using temporal convolution network[J]. Transportmetrica B: Transport Dynamics, 2022, 10(1): 849-863.
- [17] Liu Z Q, Peng M C, Sun Y C. Estimation of driver lane change intention based on the LSTM and Dempster-Shafer evidence theory[J]. Journal of advanced transportation, 2021, 9(1): 1-11.
- [18] Komol M M R, Elhenawy M, Masoud M, et al. Deep RNN based prediction of driver's intended movements at intersection using cooperative awareness messages[J]. IEEE Transactions on Intelligent Transportation Systems, 2023, 24(7): 6902-6921.
- [19] 王艳阳, 王珂, 廖凯凯, 等. 驾驶人行为不确定性对车辆轨迹预测的影响分析[J]. 安全与环境学报, 2023, 23(9): 3243-3250.
- [20] 张一鸣, 周兵, 吴晓建, 等. 基于前车轨迹预测的高速智能车运动规划[J]. 汽车工程, 2020, 42(5): 574-580.
- [21] Tomar R S, Verma S, Tomar G S. SVM based trajectory predictions of lane changing vehicles[C]. 2011 International Conference on Computational Intelligence and Communication Networks. IEEE, 2011: 716-721.

- [22] 宋秀兰, 董兆航, 单杭冠, 等. 基于时空融合的多头注意力车辆轨迹预测[J]. 浙江大学学报: 工学版, 2023, 57(8): 1636-1643.
- [23] 王雪阳, 刘茜. 融合变道意图识别的车辆轨迹预测GAN模型[J]. 计算机系统应用, 2023, 32(4): 354-360.
- [24] Altche F, Fortelle A D L. An LSTM network for highway trajectory prediction[J]. IEEE, 2017, 4(2): 353-359.
- [25] Ye N, Zhang Y, Wang R. Vehicle trajectory prediction based on Hidden Markov Model[J]. KSII Transactions on Internet and Information Systems(TIIS), 2016, 10(7): 3150-3170.
- [26] Sheng Z, Xu Y, Xue S, et al. Graph-based spatial-temporal convolutional network for vehicle trajectory prediction in autonomous driving[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(10): 17654-17665.
- [27] Chen X, Zhang H, Zhao F, et al. Intention-aware vehicle trajectory prediction based on spatial-temporal dynamic attention network for internet of vehicles[J]. IEEE Transactions on Intelligent Transportation Systems, 2022, 23(10): 19471-19483.
- [28] Shi K, Wu Y, Shi H, et al. An integrated car-following and lane changing vehicle trajectory prediction algorithm based on a deep neural network[J]. Physica A: Statistical Mechanics and its Applications, 2022, 59(9): 127-133.
- [29] Li H, Liao Z, Rui Y, et al. A physical law constrained deep learning model for vehicle trajectory prediction[J]. IEEE Internet of Things Journal, 2023, 10(24): 22775 - 22790.
- [30] 陈浩, 喻厚宇. 基于势场搜索的无人车动态避障路径规划算法研究[J]. 北京汽车, 2019, 1(4): 1-5.
- [31] 黄子超, 吴青, 马育林. 基于模型预测控制与环境势场建模的车队协同驾驶方法研究[C]. 中国智能交通年会大会. 2016: 255-266.
- [32] Li A, Jiang H, Zhou J, et al. Learning human-like trajectory planning on urban two-lane curved roads from experienced drivers[J]. IEEE Access, 2019, 7(4): 65828-65838.
- [33] Yang D, Zheng S, Wen C, et al. A dynamic lane-changing trajectory planning model for automated vehicles[J]. Transportation Research Part C: Emerging Technologies, 2018, 9(5): 228- 247.
- [34] Xiao J. Trajectory planning of quadrotor using sliding mode control with extended state observer[J]. SAGE Publications Sage UK: London, England, 2020, 53(7): 1300-1308.
- [35] 李航. 统计学习方法[M]. 北京: 清华大学出版社, 2012: 194-195.
- [36] 胡少伟. 基于驾驶意图识别的主动换道系统研究[D]. 清华大学, 2019.
- [37] 周志华. 机器学习[M]. 北京: 清华大学出版社, 2016: 321-322.
- [38] 叶硕, 杜珍珍, 彭春堂, 等. 基于HMM的混响环境下语音识别研究[J]. 计算机技术与发展, 2019, 29(8): 5-8.
- [39] 张强, 闫斌, 杨蔚, 等. 基于预测的混和自动重传请求算法[J]. 通信技术, 2016, 49(5): 544-548.
- [40] 熊慧, 唐宏亮, 丁永. 基于改进HMM的食品安全风险评估方法[J]. 食品与机械, 2021, 37(11): 72-76.
- [41] 高冰涛. 基于文本挖掘的生物命名实体识别算法研究[D]. 西北农林科技大学, 2018.
- [42] 张提. 基于MPE藏语拉萨话区分度声学模型研究[D]. 西北民族大学, 2017.
- [43] 刘鹏, 贾寒冰, 张雷, 等. 结构化道路下智能汽车自主换道轨迹规划研究[J]. 机械工程学报, 2023, 59(24): 271-281.
- [44] 吴晓建, 燕冬, 王爱春, 等. 融合前车轨迹预测的改进人工势场轨迹规划研究[J]. 汽车工程, 2021, 43(12): 11-17.
- [45] Wang J, Wang J, Wang R, et al. A framework of vehicle trajectory replanning in lane exchanging with considerations of driver characteristics[J]. IEEE Transactions on Vehicular Technology, 2017, 66(5): 3583-3596.
- [46] 李莉, 奚雪峰, 盛胜利, 等. 深度学习中文命名实体识别研究进展[J]. 计算机工程与应用, 计算机工程与应用, 2023, 59(24): 46-69.
- [47] 周波波. 基于深度学习的自动驾驶汽车主动换道决策与轨迹规划研究[D]. 重庆大学, 2021.

- [48] Li X, Wang W, Zhang Z, et al. Effects of feature selection on lane-change maneuver recognition: An analysis of naturalistic driving data[J]. *Journal of intelligent and connected vehicles*, 2018, 1(3): 85-98.
- [49] Li X, Wang W, Roetting M. Estimating driver's lane-change intent considering driving style and contextual traffic[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2018, 20(9): 3258-3271.
- [50] Rezazadeh N, Zarrabi H. Using adaptive approach to enhance the accuracy of forward and backward algorithms in solving the evaluation problems of non stationary environments[J]. *International Journal of Computer Science and Information Security*, 2017, 15(1): 80-89.
- [51] Zhao L, Rilett L, Haque M S. Hidden Markov model of lane-changing-based car-following behavior on freeways using naturalistic driving data[J]. *Transportation research record*, 2021, 26(8): 550-561.
- [52] Park S, Lim W, Sunwoo M. Robust lane-change recognition based on an adaptive hidden markov model using measurement uncertainty[J]. *International Journal of Automotive Technology*, 2019, 20(2): 255-263.
- [53] Beglerovic H, Schloemicher T, Metzner S, et al. Deep learning applied to scenario classification for lane-keep-assist systems[J]. *Applied Sciences*, 2018, 8(12): 259-270.
- [54] 徐杰, 裴晓飞, 杨波, 等. 融合车辆轨迹预测的学习型自动驾驶决策[J]. *汽车安全与节能学报*, 2022, 13(2): 317-324.
- [55] Ramasamy M, Ramapackiam S. Edge preserving image segmentation using spatially constrained EM algorithm[J]. *International Arab Journal of Information Technology*, 2018, 15(5): 927-933.
- [56] Chen G, Gao Z, Hua M, et al. Lane change trajectory prediction considering driving style uncertainty for autonomous vehicles[J]. *Mechanical Systems and Signal Processing*, 2024, 20(6): 110854-11884.
- [57] Barbosa B H G, Xu N, Askari H, et al. Lateral force prediction using Gaussian process regression for intelligent tire systems[J]. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2021, 52(8): 5332-5343.
- [58] Lim J, Ha S, Choi J. Prediction of reward functions for deep reinforcement learning via Gaussian process regression[J]. *IEEE/ASME Transactions on Mechatronics*, 2020, 25(4): 1739-1746.
- [59] 刘鹏, 贾寒冰, 张雷, 等. 结构化道路下智能汽车自主换道轨迹规划研究[J]. *机械工程学报*, 2023, 59(24): 271-281.
- [60] Xu J, Ren C, Chang X. Robot time-optimal trajectory planning based on quintic polynomial interpolation and improved Harris Hawks algorithm[J]. *Axioms*, 2023, 12(3): 245-253.
- [61] 夏其坤. 考虑交通车辆换道行为的轨迹预测方法研究[D]. 吉林大学, 2021.
- [62] Shang M, Rosenblad B, Stern R. A novel asymmetric car following model for driver-assist enabled vehicle dynamics[J]. *IEEE Transactions on Intelligent Transportation Systems*, 2022, 23(9): 15696-15706.
- [63] 许伦辉, 倪艳明, 罗强, 等. 基于最小安全距离的车辆换道模型研究[J]. *广西师范大学学报: 自然科学版*, 2011, 29(4): 6-12.
- [64] 杨龙海, 张春, 仇晓赞, 等. 车辆跟驰模型研究进展[J]. *交通运输工程学报*, 2019, 19(5): 125-138.
- [65] 陶醉, 曹洪涛, 高海亮, 等. 一种无人机避障方法[P]. 中国, CN202210639454.8, 2022, 09.
- [66] Analooee A, Kazemi R, Azadi S. A novel trajectory planning method based on explicit quintic polynomial curves[J]. *Proceedings of the Institution of Mechanical Engineers*, 2020, 234(4): 650-674.
- [67] Yue M, Wu X, Guo L, et al. Quintic polynomial-based obstacle avoidance trajectory planning and tracking control framework for tractor-trailer system[J]. *International Journal of Control, Automation and Systems*, 2019, 17(10): 2634-2646.
- [68] Tan Z, Wei J, Dai N. Real-time dynamic trajectory planning for intelligent vehicles based on quintic polynomial[C]//2022 IEEE 21st International Conference on Ubiquitous Computing and Communications. IEEE, 2022: 51-56.
- [69] Liu Y, Wang Y, Wang X, et al. A model for safe lane changing of connected vehicles based on quintic polynomial Trajectory planning[C]//2022 7th International Conference on Intelligent Informatics and Biomedical Science. IEEE, 2022: 51-55.



- [70] Huang J, Hu P, Wu K, et al. Optimal time-jerk trajectory planning for industrial robots[J]. Mechanism and Machine Theory, 2018, 12(1): 530-544.
- [71] Tao L, Watanabe Y, Li Y, et al. Collision risk assessment service for connected vehicles: Leveraging vehicular state and motion uncertainties[J]. IEEE Internet of Things Journal, 2021, 8(14): 11548-11560.
- [72] Althoff M, Dolan J M. Online verification of automated road vehicles using reachability analysis[J]. IEEE Transactions on Robotics, 2017, 30(4): 903-918.

## 附录 1 攻读硕士学位期间撰写的论文

[1]陆金辉,鲍楠,胡晗,等.城市道路车辆行为识别方法研究[J].移动通信, 2023, 47(10):38-43.已发表.

## 附录 2 攻读硕士学位期间申请的专利

[1] 鲍楠, 陆金辉, 孙希霞, 师晓晔, 潘甦. 一种基于 GM-HMM 的道路安全驾驶行为识别方法, CN202310939571.0, 2023.07.28. 已公开.

### 附录 3 攻读硕士学位期间参加的科研项目

- (1) 国家自然科学基金，基于空间资源压缩概念和方法的物联网资源优化分配(62071244)；
- (2) 国家自然科学基金，基于多域信息联合利用的空地融合频谱共享研究(62071250)；
- (3) 中国博士后科学基金，面向 6G 的高能效 RIS-NOMA 技术研究(2021M693699)。

## 致谢

漫漫求学二十载，行文至此，不由感慨万千。鲜衣怒马少年时，不负韶华行且知。在此，我衷心感谢所有在学术探索和生活中给予我帮助和支持的人。

首先非常感谢研究生阶段鲍楠老师对我的悉心指导与无微不至的关照，很幸运能遇到这么一位宇宙超级无敌好的老师！在研途中，您以严谨的学术态度和无私的精神，对我的研究工作提出了宝贵的指导和建议。您的深刻见解和批判性思维激发了我对科学研究的热情，教会了我如何面对科研中的困难与挑战。每当我遇到疑难问题时，您总是耐心地指导我，帮助我找到解决问题的方法，在生活上也关心有加。您的敦敦教诲是我学术旅程中最宝贵的财富，您的言传身教将是我职业生涯中永远的灯塔。人生得此良师，实乃吾之三生有幸哉！

其次特别感谢我的父母和家人。感谢我的父亲，是您起早贪黑，顶着风吹日晒辛苦地赚钱养家；感谢我的母亲，是您任劳任怨，对家庭的无微不至让我感受到小家的温馨，你们的养育之恩我会永远铭记在心。感谢我的外公钱承淦，是您从小到大的启蒙和教导，让我成长。感谢我的爷爷奶奶，外公外婆，叔伯，姑娘，舅舅，兄弟姐妹等亲人，家人们，感谢你们在人生路上一直地支持和陪伴，在我遇到困难和挫折时，是你们的信任和鼓励让我找到了继续前进的动力，你们的理解和爱是我一往无前的坚强后盾。

我还要感谢我的好同门好室友陈嘉旭；感谢我的室友，练元洪、俞文军；感谢我的朋友们，王强、谢兆广、刘强、姚子健、管东、周晓威等；感谢我的同门师兄姐妹；感谢教研室的小伙伴们，感谢你们在我需要时给予的帮助和陪伴。在学习和生活中，你们的陪伴和鼓励让我感到温暖和力量，你们的支持是我在学术旅程中不可或缺的部分。

最后，感谢我的母校，南京邮电大学，给了我一个成长的平台和难忘的三年。

今朝告别，是为更好的重逢。再次拜谢，三载光阴，必永记于心。路漫漫其修远兮，吾将上下而求索。愿将所学，投身社会，不负韶华，不负卿卿。

何其荣幸，生于华夏盛世，感念天地之宽容，人间之暖意。文毕，祝诸君阖家平安喜乐，身体健康，万事顺遂。