

引用格式:林志坤,吴小竹.考虑驾驶员驾驶风格的车辆跟驰模型[J].地球信息科学学报,2023,25(9):1798-1812. [Lin Z K, Wu X Z. Car-following model considering driver's driving style[J]. Journal of Geo-information Science, 2023,25(9):1798-1812.] DOI:10.12082/dqxxkx.2023.230121

考虑驾驶员驾驶风格的车辆跟驰模型

林志坤^{1,2}, 吴小竹^{1,2*}

1. 福州大学数字中国研究院(福建), 福州 350003; 2. 空间数据挖掘与信息共享教育部重点实验室, 福州 350003

Car-Following Model Considering Driver's Driving Style

LIN Zhikun^{1,2}, WU Xiaozhu^{1,2*}

1. Academy of Digital China (Fujian), Fuzhou University, Fuzhou 350003, China; 2. Key Laboratory of Spatial Data Mining and Information Sharing, Ministry of Education, Fuzhou 350003, China

Abstract: The research on car-following behavior aims to explore the impact of the leading vehicle's movement on the following vehicle's driving state on a one-way road. By establishing corresponding car-following models for simulation studies, it can reveal the underlying mechanism of traffic congestion, traffic flow oscillation, and other traffic phenomena, which is helpful for evaluating the stability, road capacity, and operational efficiency of traffic flow. Due to differences in driving experience, personality, and other characteristics, drivers may exhibit different car-following characteristics. Moreover, under the same conditions, the car-following behavior of different drivers may differ, and the car-following behavior of the same driver may also vary at different times. However, traditional car-following models often assume that drivers' driving behavior is homogeneous and rarely consider differences in driving styles among passing vehicles, which is inconsistent with actual situations. Therefore, this paper first extracts four driving behaviors of passing vehicles on the road (lane changing, starting, braking, and smooth driving), develops a Weight-based Adaptive Data Stream Gravity Clustering (WASstream) algorithm based on weights, and conducts clustering analysis on the time-series data of different driving behavior characteristics. Then, according to the driving style scoring model, the aggressiveness of different driving behaviors of drivers is quantified, the effective classification of driving styles of passing vehicles is achieved, and the overall driving behavior characteristics of different style driver groups are obtained. Next, by analyzing the car-following data of drivers with different styles, a speed expectation function for different style vehicles is constructed. Furthermore, the proposed car-following model considers the impact of speed and acceleration differences between the leading vehicle and multiple front vehicles in the driver's field of vision, which considers the driver's driving style. Finally, based on the NGSIM vehicle trajectory data, the key parameters of the car-following model considering the driver's driving style are calibrated using genetic algorithms, and the model's validation and numerical simulation analysis are achieved. The experimental results show that compared with the

收稿日期 2023-03-11; 修回日期: 2023-05-17.

作者简介 林志坤(1997—), 男, 福建漳州人, 硕士生, 主要从事地理信息服务与时空数据挖掘研究。

E-mail: 205520015@fzu.edu.cn

*通讯作者: 吴小竹(1979—), 男, 福建漳州人, 博士, 副教授, 主要研究方向为智能交通、空间数据挖掘和地理知识网络等。

E-mail: wxz@fzu.edu.cn

classical FVD model, the proposed car-following model can better fit the car-following data, and the MAE, MAPE, and RMSE are reduced by 1.511 m/s², 6.122%, and 1.064 m/s², respectively. At the same time, the model can effectively reduce the delay of vehicles in car-following behavior, construct traffic flow scenarios closer to reality, and improve the stability of traffic flow. The car-following model proposed in this study can provide effective decision-making information for transportation planning and management departments and provide model references for micro-traffic simulation studies.

Key words: car-following model; microscopic traffic simulation; driving style; driving behavior; parameter calibration; data stream clustering; trajectory extraction; data mining

***Corresponding author:** WU Xiaozhu, E-mail: wxz@fzu.edu.cn

摘要 跟驰行为研究旨在探究单行道上前车运动状态的变化对后车行驶状态的影响,通过建立相应的跟驰模型进行仿真研究,可以揭示交通拥堵、交通流震荡等交通现象的内在机理,有助于研究交通流的稳定性、道路通行能力和运行效率。由于驾驶经验、性格等特征的差异,驾驶员会表现出不同的跟车特征。然而,传统的跟驰模型往往假设驾驶员的驾驶行为是同质的,较少考虑通行车辆驾驶风格的差异,这与实际情况不符。为此,本文首先提取了路面通行车辆的4种驾驶行为特征(变道、起步、制动、平稳行驶),开发了基于权重的自适应数据流引力聚类(Weight-based Adaptive Data Stream Gravity Clustering, WASStream)算法,分别对不同驾驶行为特征时序数据进行聚类分析,进而根据驾驶风格评分模型量化了驾驶员不同驾驶行为的激进程度,实现了通行车辆驾驶风格的有效分类;接着通过分析不同风格驾驶员的跟驰数据,构建不同风格车辆的速度期望函数,并充分考虑主车与驾驶视野中多辆前车的速度差、加速度差等影响,提出了一种考虑驾驶员驾驶风格的车辆跟驰模型;最后基于NGSIM车辆轨迹数据,利用遗传算法标定考虑驾驶员驾驶风格的车辆跟驰模型的关键参数,实现模型的验证和数值仿真分析。实验结果表明:与经典的FVD模型相比,所提出的跟驰模型能够更好地拟合车辆跟驰数据,其MAE、MAPE、RMSE分别减小了1.511 m/s²、6.122%、1.064 m/s²;同时,该模型能够有效降低车辆在跟驰行为中的延迟性,构建更逼近真实情况的交通流场景,提高了交通流的稳定性。本研究提出的跟驰模型能够为交通运输规划和管理部门提供有效的决策信息,为微观交通仿真研究提供模型参考。

关键词 车辆跟驰模型;微观交通仿真;驾驶风格;驾驶行为;参数标定;数据流聚类;轨迹提取;数据挖掘

1 引言

随着我国城市化的不断推进,人们对交通需求的进一步加深,城市交通路网车流量急剧增加,导致交通拥堵,进而严重影响城市居民日常出行规划和通行质量,已然成为各大城市亟待解决的问题^[1]。交通拥堵问题在交通理论中,也被称为交通失稳问题,为了探究其成因和演化规律,许多学者基于车辆跟驰行为特征构建了相应数学模型来模拟交通流的演变情况^[2-4]。这些模型通常从微观交通流的角度,考虑了车辆之间的相互作用,以及车辆与道路环境之间的相互作用,从而可以比较准确地反映实际交通流的运行情况。

在跟驰模型的早期研究中,大多学者应用了不同的建模思想描述驾驶人的跟驰行为。在20世纪50年代早期,Reuschelp等^[5]首先发展了刺激-反应模型,即假定跟驰车的驾驶员不断调整车辆的速度,使其与前面车辆的速度保持一致;Kometti等^[6]提出了一个安全距离模型,其使得车辆在不能完全

预测先行车的运动时,也能够避免碰撞的发生;Kikuchi等^[7]使用模糊逻辑理论,建立了一个人工智能跟车模型;Newell^[8]通过假设车速与车头时距之间存在关联性,进而将速度函数引入跟车模型。理论上,这些模型假定跟驰车辆在某一时间点的运动是由加速或减速来控制的,以此作为对周围车辆运动的响应,特别是目标车辆的当前先行车的运动,这符合大多数驾驶员的实际驾驶策略。随后,Bando等^[9]提出了一个通用的最优速度(Optimal Velocity, OV)模型,其中跟驰车的加速度与其车头距相关的最佳速度和实际速度之间的速度差成正比,OV模型可以描述实际交通流的许多性质,如现实道路中车辆停停走走的现象、交通不稳定性及交通堵塞等。同时,由于OV模型方程的简单性(只有车头时距和跟驰车的速度2个输入),该模型也存在一些缺陷。Helbing等^[10]发现,OV模型在一些常见的交通情况下,甚至会产生过高的加速度和不切实际的减速。他们认为这种不足是由于没有考虑先行车和跟驰车之间速度差的影响,并提出了一种基于

OV模型的广义力(Generalized Force, GF)模型。GF模型继承了OV模型的思想,并考虑了负速度差的影响(即跟驰车的速度大于先导车的速度的情况),减少了不切实际的加速或减速。紧接着,为了解决OV模型和GF模型在预测车辆运动延迟时间和堵塞时车辆运动波速方面性能较差的问题,Jiang等^[11]通过对GF模型进行了进一步的改进,提出了一个全速度差(Full Velocity Difference, FVD)模型。与GF模型相比,FVD模型不仅考虑了速度的负差,而且还考虑了速度正差(即跟驰车的速度小于其先行车的速度)对跟驰车加速度的影响。

近年来,随着车联网技术的成熟,王涛等^[12]基于车辆通信技术获取超视距下车辆的信息,提出考虑多辆前车速度差的多速差(Multiple Velocity Difference, MVD)车辆跟驰模型。孙棣华等^[13]提出了向后观测速度差(Backward Looking and Velocity Difference, BLVD)模型,其是在FVD模型的基础上加入了后视效应的影响,通过考虑车辆跟随行驶时的后视信息,从而更加准确地描述了车辆之间的相互作用。基于经典的FVD模型,申勇等^[14]提出了考虑速度对反应强度影响的车辆跟驰模型,该模型能够表现驾驶员加减速过程的非对称性。Zhang等^[15]通过对车头时距的变化进行预测,使得模型的稳定性显著提高。Jiang等^[16]考虑了驾驶员视角中相邻车道前车的影响,提出了一种双车道车辆跟驰模型。潘义勇等^[17]基于分位数回归方法对速度函数进行改进,建立了随机优化速度跟驰模型,描述了驾驶员异质性对交通流状况的影响。

另外随着数据采集技术的不断进步,海量车辆轨迹数据能够被便捷的获得,其中美国的NGSIM车辆轨迹数据集^[18]在车辆跟驰模型研究领域被广泛使用。如,Zhang等^[19]基于NGSIM数据集记录的城市交通信号灯路口处的车辆轨迹数据,分析了不同交通信号灯对车辆跟驰行为的影响,建立一种跟驰模型。Zhao等^[20]通过分析前车变道行为对后车的影响,提出了考虑前车变道过程的跟驰模型,并利用NGSIM数据集对模型进行分析和验证。然而,上述研究较少从驾驶员的角度考虑多种前后车辆的关系,并且不同风格车辆驾驶员受到前后车辆的影响也各不相同。综上所述,本文首先基于城市交通流场景,提出了一种驾驶风格分类方法;其次,本文在FVD模型的基础上,考虑驾驶员视野中多辆前车的影响,构建了一种考虑驾驶员驾驶风格的车

辆跟驰模型;最终,利用数值仿真验证模型的有效性,并与FVD模型进行对比。

2 研究方法

本文技术框架如图1所示。首先,将原始NGSIM车辆轨迹数据集进行清洗,利用阈值检测方法,提取得到4类驾驶行为事件特征数据(变道、起步、制动和平稳行驶);其次,可开发基于权重的自适应数据流引力聚类算法,实现通行车辆驾驶风格的分类,并对分类结果进行验证分析,拟合不同驾驶风格的期望速度函数;最后,通过考虑跟驰车的驾驶风格和视野中多辆前车的影响,构建了考虑驾驶员驾驶风格的车辆跟驰模型,并将其与经典的FVD模型进行对比验证和仿真分析。

2.1 基于数据流聚类算法的驾驶风格分类

2.1.1 驾驶行为特征数据提取

为了有效分类车辆的驾驶风格,本研究将车辆轨迹数据根据其行为划分为变道、起步、制动和平稳行驶,并采用阈值检测方法提取各驾驶行为事件轨迹数据:

(1)提取变道驾驶行为事件轨迹数据。首先进行车道变化检测,提取车辆变道前后3秒的轨迹数据。然后,持续检测车辆的横向偏移情况,判断车辆的变道行为是否开始或结束,并提取有效的变道驾驶行为轨迹数据。

(2)提取起步和制动驾驶行为事件轨迹数据。将从长时间处于静止开始不断增加速度,且在一段时间后车辆加速度首次不为正值的车辆行驶轨迹作为车辆起步事件轨迹数据集,将从加速度最后一次不为正值开始到完全静止的车辆行驶轨迹作为车辆制动驾驶行为事件轨迹数据。

(3)提取平稳行驶驾驶行为事件轨迹数据。去除目标车辆轨迹数据中的变道、起步和制动行为事件的轨迹数据,得到车辆平稳驾驶行为事件轨迹数据。

(4)计算驾驶行为事件特征数据。使用驾驶行为发生时的平均速度、平均加速度、平均车头间距和平均车头时距等数据作为驾驶行为风格的重要表征数据。

提取得到的新数据集记录了车辆变道、制动、起步和平稳行驶行为特征,其中每条数据记录目标

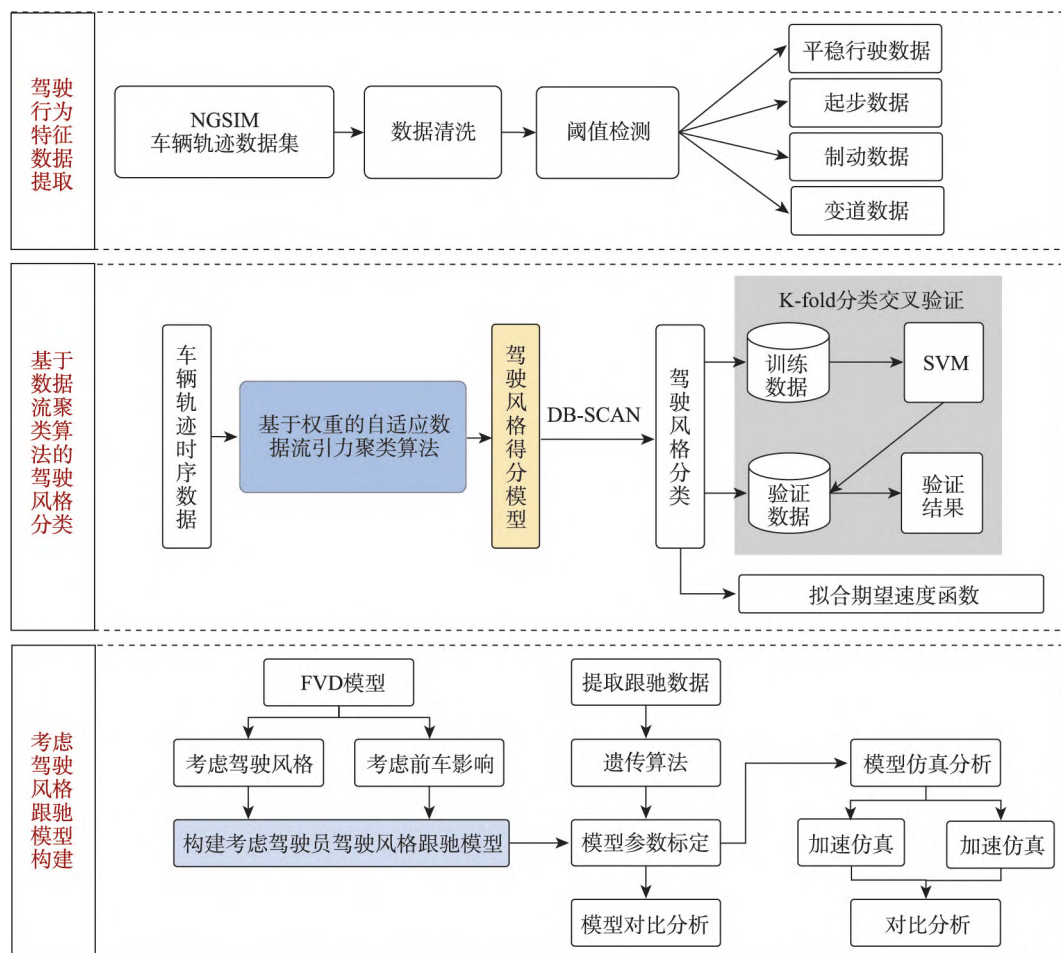


图1 考虑驾驶员驾驶风格的车辆跟驰模型研究的技术框架

Fig. 1 The technical framework for the study of vehicle following models considering driver's driving style

车辆的识别号、平均速度、平均加速度、平均车头间距、平均车头时距和驾驶行为事件时间信息,如表1所示。

表1 车辆轨迹重构数据集

Tab. 1 Vehicle trajectory reconstruction dataset

数据	描述	单位
Vehicle_Id	车辆识别号	-
Time	驾驶行为事件记录的时间	-
Ave_Vel	车辆平均速度	m/s
Ave_Acc	车辆的平均加速度	m
Ave_Space_Headway	平均车头间距	m
Ave_Time_Headway	平均车头时距	s

2.1.2 基于权重的自适应数据流引力聚类算法

车辆轨迹数据作为时序数据的一种,使用数据流聚类方法挖掘潜在的交通信息,进行有效分析有着巨大的优势^[21]。因此,为了实现车辆驾驶行为特征时序数据的最优聚类,进而基于驾驶风格评分模

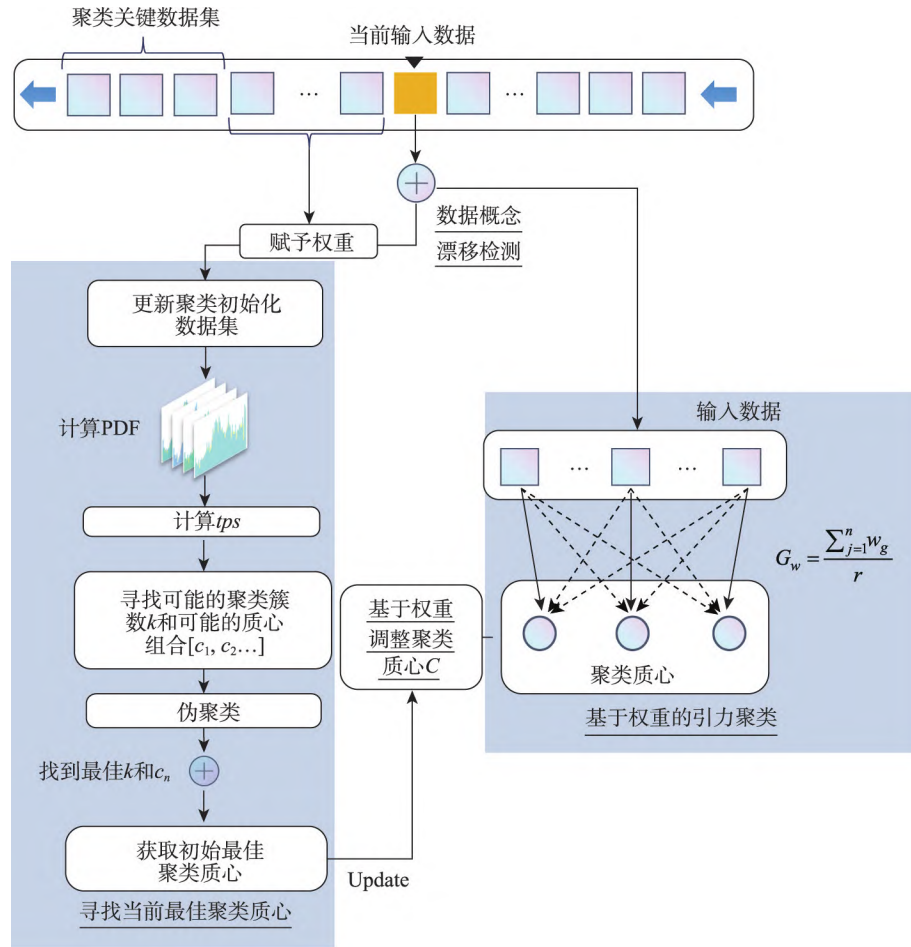
型量化车辆的驾驶行为风格,本节提出了一种基于权重的自适应数据流引力聚类(Weight-based Adaptive Data Stream Gravity Clustering, WASstream)算法,如图2所示。

基于权重的自适应数据流引力聚类算法包含:①数据概念漂移检测;②寻找当前最佳聚类质心;③基于权重调整聚类质心;④基于权重的引力聚类4个主要部分,当发现数据流发生较大的数据概念漂移情况时,才进行对聚类质心的更新,否则只进行基于权重的引力聚类。

步骤(1)数据概念漂移检测。基于 Kullback-Leibler (KL) Divergence 理论,通过计算数据流特征流前后各特征的 KL 散度数值来量化数据流中的数据漂移情况,KL 散度的计算公式如下:

$$D_{KL}(p // q) = \sum_{i=1}^N p(x_i) \cdot \log \frac{p(x_i)}{q(x_i)} \quad (1)$$

式中: D_{KL} 为概率分布 $p(x_i)$ 和 $q(x_i)$ 的散度值;



注: PDF为驾驶行为数据特征的概率密度函数, tps 为PDF函数曲线的拐点; G_w 为聚类质心对输入数据的引力大小; w_g 为驾驶行为特征数据的全局权重。

图2 基于权重的自适应数据流引力聚类算法流程

Fig. 2 Flow chart of weight-based adaptive data stream gravity clustering algorithm

N 为驾驶行为特征数据的总数; $p(x_i)$, $q(x_i)$ 分别为驾驶行为特征(如平均速度、平均加速度等) x_i 的前后数据情况的概率分布函数, 当其散度产生较大值时, 即视为数据发生概念漂移, 将会触发方法中质心的更新。

步骤(2)寻找当前最佳聚类质心。分析未知数据流的关键问题之一就是如何确定不同时段数据流场景中的最佳聚类簇的数量。首先, 本文基于核密度估计方法(Kernel Density Estimation, KDE), 计算得到数据的概率密度函数(Probability Density Function, PDF), 并根据PDF的拐点 tps 确定最佳的聚类簇数量, 并将其作为潜在的 k 值, 将PDF拆分成相应数量的等概率区域, 最后将各区域特征值的平均值作为初始的聚类质心 c 。其次, 由于各数据流特征值的PDF曲线包含不同 tps , 即对应不同的

聚类数目 k 并且提供了不同的初始聚类质心 c 。本研究基于上述获取初始聚类质心组合的方法, 利用K-Mean模型对可能的 k 值($k \in [tps_{min}, tps_{max}]$)进行伪聚类。最后, 采用轮廓系数(Silhouette Coefficient, SC)和戴维森堡丁指数(Davies Bouldin, DB)对算法的聚类效果进行比较, 进而找到最佳的 k 及对应的聚类质心组合 C 。

步骤(3)基于权重调整聚类质心。该算法首先基于衰减函数, 定义了数据的全局时间权重 w_g , 表征数据的重要性:

$$w_g = 1 - e^{-\alpha(t-t_0)} \quad (2)$$

式中: w_g 为驾驶行为特征数据的全局权重; α 为权重衰减参数, 其依据数据的变化情况给定; t 是指驾驶行为事件发生的时间; t_0 是指因数据概念漂移检测更新关键数据集的时间。每个具有全局权重的

数据被定义 $\{\overline{CF}_1, \overline{CF}_2, \overline{CF}_3, \overline{CF}_4, w_g\}$, \overline{CF}_i 表示各驾驶行为特征的值。其次, 进一步定义数据的簇内权重:

$$w = \frac{w_g}{\sum_{j=1}^n w_g} \quad (3)$$

式中: w 表示每个数据点在该聚类簇内的权重大小; n 表示该聚类簇内数据点的数量; $\sum_{j=1}^n w_g$ 表示该聚类簇内数据点的权重总和。基于步骤(2)中的最佳质心的聚类结果, 计算其聚类簇中各数据的簇内权重, 进而通过得到最终的聚类质心组合 c 。

$$c = \sum [\overline{CF}_1 \cdot w, \overline{CF}_2 \cdot w, \overline{CF}_3 \cdot w, \overline{CF}_4 \cdot w] \quad (4)$$

步骤(4)基于权重的引力聚类。本文基于牛顿万有引力定律, 提出了基于权重引力的大小进行聚类, 将聚类质心的权重 $\sum_{j=1}^n w_g$ 视为聚类质心的质量。由于每次流入数据点的权重和引力系数对整体的影响是一样的, 进而对二者进行忽略。得到的公式如下所示:

$$G_w = \frac{\sum_{j=1}^n w_g}{r} \quad (5)$$

式中: n 为该聚类簇内数据点的数量; r 为数据点到质心的欧式距离; G_w 为聚类质心对输入数据的引力大小, 进而将数据点聚类到对其引力最大的聚类质心。

2.1.3 驾驶风格评分模型

在以往许多类型的驾驶行为风格研究^[22-24]中, 其大都是基于驾驶行为数据相关特征的聚类结果直接对驾驶风格进行分析。因此, 根据驾驶行为事件特征数据流的聚类结果, 我们使用不同的特征作为主要评价指标来量化各聚类簇的驾驶风格, 如表2所示。

表2 各驾驶行为关键评价指标

Tab. 2 Key evaluation indicators of each driving behavior

驾驶行为	变道	起步	制动	平稳行驶
关键评价指标	速度(m/s)	加速度(m/s ²)	加速度(m/s ²)	速度(m/s)


如图3(a)所示, 通过将驾驶员驾驶行为特征数据流的聚类中心投影到其主要特征指标对应的坐标轴上, 进而得到每个聚类簇内部驾驶行为事件的最终得分, 其得分计算公式如下:

$$score_i = \frac{d_i}{\max\{d_1, d_2, \dots, d_n\}} \quad (6)$$


式中: $score_i$ 是聚类簇 C_i 的驾驶风格得分; d_i 表示 C_i 聚类中心投影点到坐标原点的距离。

2.1.4 驾驶风格分类

首先基于上述所提出的WAStream算法对车辆起步、制动、变道和平稳行驶驾驶行为特征数据流分别进行聚类, 并根据驾驶风格评分模型得到各车



(a) 不同聚类的质心在速度轴上投影



(b) 计算不同聚类簇的得分情况

注: d_i 为聚类中心投影点到坐标原点的距离, $\max\{d_1, d_2, \dots, d_n\}$ 表示到坐标原点距离的最大值。

图3 驾驶风格评分模型示意

Fig. 3 Diagram of driving style scoring model

辆驾驶行为事件的得分。其次,将各类驾驶行为事件的平均得分作为驾驶员各类驾驶行为风格的最终得分,对于缺失某些驾驶行为得分的驾驶员,利用该类驾驶行为事件得分的平均值予以插补,得到的得分数据如表3所示。最后,根据已有的DBSCAN参数寻优研究^[25],本文基于SC聚类评价指标,计算得到DBSCAN中最优的邻域(Eps)和最少样本的数量($Min_samples$),进而实现驾驶员的驾驶风格的最优分类,并对验证分类结果和分析不同交通流状况驾驶员的驾驶风格特征。

表3 驾驶风格得分数据示例

Tab. 3 Example of driving style score data

车辆ID	制动风格得分	起步风格得分	变道风格得分	平稳行驶风格得分
#1	0.072	1.000	0.450	1.000
#2	0.794	0.721	0.587	1.000
#3	0.443	0.063	0.862	1.000
#4	0.579	0.535	0.449	0.709
...
#2442	0.540	0.512	0.445	0.635

2.2 考虑驾驶员驾驶风格的车辆跟驰模型构建

2.2.1 跟驰模型构建

车辆跟驰模型是一种微观交通流模型,描述了单车道上行驶车队中前后车辆之间的相互作用。为了更直观描述车辆在跟驰过程中所受到的影响,本研究设定车辆行驶过程中某一时刻的跟驰场景如图4所示,其包含了一辆主车和驾驶视野内的两辆前车的位置、速度等信息。

FVD模型是描述先行车对跟驰车驾驶行为影响的主流模型,FVD模型的加速度公式为:

$$\frac{dv_n(t)}{dt} = \alpha [V(\Delta x_n) - v_n(t)] + \lambda \Delta v_n \quad (7)$$

式中: $v_n(t)$ 表示车辆 n 在 t 时刻的行驶速度;表示 α

和 λ 是灵敏度系数; $V(\cdot)$ 为最佳速度函数,是根据与前车的车距 Δx_n 定义的最佳预期速度; Δv_n 是与前车的速度差。FVD只针对目标车辆与其前车的位置关系 Δx_n 和速度差 Δv_n 设计相应的跟驰策略,未能对多辆前车的影响以及不同驾驶风格驾驶员的期望速度进行考虑,比如与多辆前车的速度差、加速度差等,进而实现不同风格驾驶员的跟驰策略。为此,本文基于2.1节的驾驶风格分类结果,获取不同风格驾驶员的期望速度函数。

$$V_{\exp} = f(\Delta t) \quad (8)$$


式中: V_{\exp} 表示不同驾驶风格车辆在不同车头时距 Δt 下的期望速度,并充分考虑了多辆前车对当前车驾驶行为决策的影响,进而对原有FVD跟驰模型进行改进,开发了一种新颖的车辆跟驰模型,其加速度公式如下所示:

$$a_n(t) = \alpha \{ \beta V(\Delta x_n) + (1 - \beta) V(\Delta t_n) + \lambda V(\Delta x_{n+1}) + (1 - \lambda) V(\Delta t_{n+1}) - v_n(t) \} + \sigma \Delta v_n(t) - \mu_1 \Delta a_{n+1} - \mu_2 \Delta a_{n+2} \quad (9)$$

式中: $a_n(t)$ 表示目标车辆 n 在 t 时刻的加速度; α 为驾驶员反应灵敏度系数; $v_n(t)$ 表示车辆 n 在 t 时刻的行驶速度; Δx_n 表示目标车辆 n 与前车的车头间距; Δt_n 表示目标车辆 n 与前车的车头时距; $\beta, \lambda, \sigma, \mu_1, \mu_2$ 表示不同驾驶员对车辆期望速度和前后车辆状态的反应灵敏程度; $V(\cdot)$ 为根据上一章节中的驾驶风格分类结果,拟合不同风格驾驶员平稳行驶状态下的行驶速度与车头时距 Δt_n 、车头间距 Δx_n 的关系函数。

2.2.2 跟驰模型参数标定方法

车辆跟驰模型的校准主要是基于所获取的车辆跟驰行为特征数据集,设定相应的目标函数衡量校准结果,通过相应的优化算法对所建立模型的各个参数进行标定,求解得到模型的最优参数集合



注: x_n, x_{n+1}, x_{n+2} 和 v_n, v_{n+1}, v_{n+2} 分别表示车辆 $n, n+1, n+2$ 在某一时刻的速度和位置情况。

图4 车辆跟驰状态示意

Fig. 4 Diagram of vehicle following state

(即最小化目标函数)。在对车辆跟驰模型进行标定前,需要明确模型输出结果如何表征模拟车辆与真实车辆之间的差别,研究如何最小化跟驰模型与实际跟驰行为特征之间的误差。为此,需要建立相应的目标函数 F_{obj} ,用来衡量不同参数跟驰模型的性能,即:

$$F_{\text{obj}} = \frac{1}{N} \sum_{i=1}^N |a_i^* - a_i| \quad (10)$$

式中: N 表示车辆加速度数据的总量; a_i^* 表示跟驰模型生成的加速度; a_i 为车辆的实际加速度; i 为数据集的索引号。由目标函数的定义可知,当目标函数的值越小,对应车辆跟驰模型越接近实际的交通情况。

目前,遗传算法^[26](Genetic Algorithm, GA)已被广泛应用在优化微观交通跟驰模型参数的研究中。遗传算法最早是由 John Holland 在进行生物操作实验的时候所提出,它是一种并行且高效的全局搜索算法,通过模仿自然选择和变异繁殖的过程,进而找到给定问题的最优解。因此,本研究通过提取相同风格车辆的跟驰数据,进而利用遗传算法对上述模型中表征车辆反应灵敏程度的参数 β , λ , σ , μ_1 , μ_2 进行标定,以构建逼近车辆真实跟驰行为的不同驾驶风格的车辆模型。

3 实验与结果

本节采用的NGSIM车辆轨迹数据进行驾驶风格分类研究和跟驰模型对比分析,NGSIM车辆轨迹数据集来源于美国联邦公路管理局Next Generation Simulation项目,记录了美国加利福尼亚州洛杉矶Lankershim Boulevard道路南部2 442辆车的行驶轨迹,共计1 607 319条车辆轨迹数据,每条数据记录目标车辆每0.1 s的位置、瞬时速度、瞬时加

速度、车头间距、车头时距和车辆出入口等信息。如表4所示,为实现跟驰模型的对比分析,本节采用阈值检测的方法,提取得到研究跟驰模型所需的车辆跟驰状态信息包括 $v_n(t)$ 、 $\Delta v_n(t)$ 、 Δx_n 、 Δx_{n+1} 、 Δt_n 、 Δa_{n+1} 和 Δa_{n+2} 。本研究实验平台配置为 Intel (R) Core(TM) i5- 10505 CPU @3.20GHz, 4GB RAM, Windows11 64 bit 操作系统, Python 编程实现,参考标定流程如图5所示。

3.1 驾驶风格分类及验证

基于参数寻优的结果,本文将DBSCAN的参数进行如下设置: $Eps=0.23$, $Min_samples=200$, 实现驾驶风格的分类,结果如图6所示。此外,根据驾驶风格评分模型可知,驾驶风格得分越高的驾驶员所采取的驾驶行为策略越激进,结合聚类结果的整体得分情况,本文将数据集中车辆的驾驶风格分为3类,即激进型(542名)、正常型(558名)和谨慎型(1 342名)。由图6可知,激进型驾驶员的驾驶风格平均得分几乎都在0.8以上,明显高于其他两种驾驶风格,表明该类驾驶员在行驶过程中对于高速度和大加速度的偏好。同时,谨慎型驾驶风格的驾驶员的各类驾驶风格平均得分均为最低,表明该类驾驶员更偏向于平稳行驶。同时,上述图表中不同驾驶风格之间存在一定的差异,说明了本文所提出的方法能够对不同车辆的驾驶风格进行量化表征,进而实现对路面车辆驾驶风格的有效分类。

由表5可知,激进型驾驶员群体的平均最大速度、平均最大加速度均为最高,且其平均最小车头时距也为最小,表明激进型驾驶员在行驶中更倾向于加快速度,而另外2类驾驶员更加谨慎,更注重保持安全距离。

为有效验证所提出的驾驶风格分类方法的性能,本节基于上述驾驶风格分类实验得到的驾驶风格标签,通过将其划分为训练数据和测试数据进行

表4 车辆跟驰数据示例
Tab. 4 Example of car following data

$\Delta v_n(t)$ /(m/s)	$\Delta a_{n+1}(t)$ /(m/s ²)	$v_n(t)$ /(m/s)	$a(t)$ /(m/s ²)	Δx_n /m	$v_{n+1}(t)$ /(m/s)	$a_{n+1}(t)$ /(m/s ²)	Δx_{n+1} /m
-0.213	0.003	12.398	-1.024	11.214	12.185	-1.203	15.849
-0.358	0.091	12.431	0.338	11.219	12.074	-1.112	15.838
-0.469	0.298	12.461	0.292	11.184	11.993	-0.814	15.870
...
-0.523	0.518	12.485	0.246	11.105	11.963	-0.295	15.948

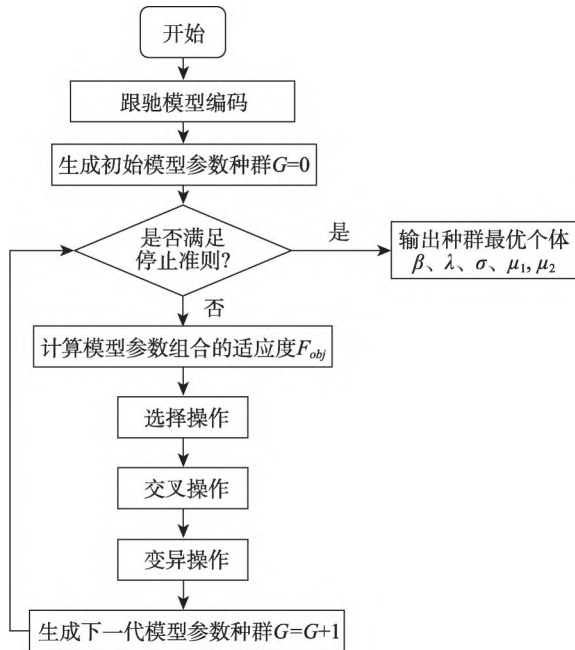


图5 基于遗传算法的参数标定流程

Fig. 5 Flow chart of parameter calibration based on genetic algorithm




图6 不同风格驾驶员的驾驶行为得分情况

Fig. 6 Driving behavior scores of drivers with different styles

表5 不同风格驾驶员的驾驶行为特征

Tab. 5 Driving behavior characteristics of drivers with different driving styles

驾驶特征	激进型	正常型	谨慎型
平均最大速度/(m/s)	14.51	10.43	9.04
平均最大加速度/(m/s ²)	5.77	4.80	4.51
平均最小车头时距/s	1.22	2.04	2.77

交叉验证,实现对分类有效评价(图7)。为了验证本文所提出的分类方法,并且避免模型的欠拟合和过拟合,本节采用了 K-fold 交叉验证的方法。首先将车辆得分数据取出 $1/k$ 作为测试集,其余的 $k-1/k$ 作为训练集,其中 k 为整数。其次,通过对训练数据集进行聚类,并利用 SVM 对训练集的数据进行训练,进而给定测试集中每条得分数据的类别。最后,将测试数据集的分类结果与整个数据集的聚类结果进行比较,得到相应的分类准确率。为了进一步评估驾驶风格分类识别的有效性采用了 Precision(精确率)、Recall(召回率)以及引入 F1 对模型进行评估。假设模型正确分类驾驶风格的数量为 TP,模型错将其他类驾驶风格为正确类别的数量为 FP;模型识别驾驶风格正确数量为 TN,模型错将正确驾驶风格识别成其他类别的数量为 FN。

$$P = \frac{TP}{TP + FP} \quad (11)$$

$$R = \frac{TP}{TP + FN} \quad (12)$$

$$F_1 = \frac{2PR}{P + R} \quad (13)$$

最后,本文根据先前基于支持向量机的驾驶风格分类研究^[27-28],将模型的关键参数如下进行设置:惩罚系数为 10,残差收敛条件为 0.000 1, kernel 设置为“poly”,最大迭代次数 1 000,通过对训练数据集中不同风格驾驶行为得分数据进行学习和训练,进而实现验证数据集的分类检验。另外,为了防止模型过拟合及欠拟合的情况,本文将 k 分别设置为 5 和 7 进行实验。实验结果表明,当 $k=7$ 驾驶风格识别分类的准确率、精确率和召回率均高于 $k=5$ 时的值,且分类准确率能够达到 97%。这表明所提出的驾驶风格分类可以有效地对驾驶风格特征进行量化,并且通过学习不同驾驶风格的得分,实现对路面车辆驾驶风格进行准确识别分类。

3.2 跟驰模型验证

为根据驾驶风格分类结果(表6),拟合不同风格驾驶员平稳行驶状态下的行驶速度与车头时距 Δt_n ,车头间距 Δx_n 的关系函数,作为跟驰模型中 $V(\cdot)$ 速度期望函数。其次,通过 Python 构建 GA 算法,通过车辆跟驰数据其中 100 组数据对车辆跟驰模型参数进行参数标定,并利用另外 100 组车辆跟驰数据对比标定的跟驰模型进行验证。通过参考相关的跟驰模型参数标定研究^[29-30],将 FVD

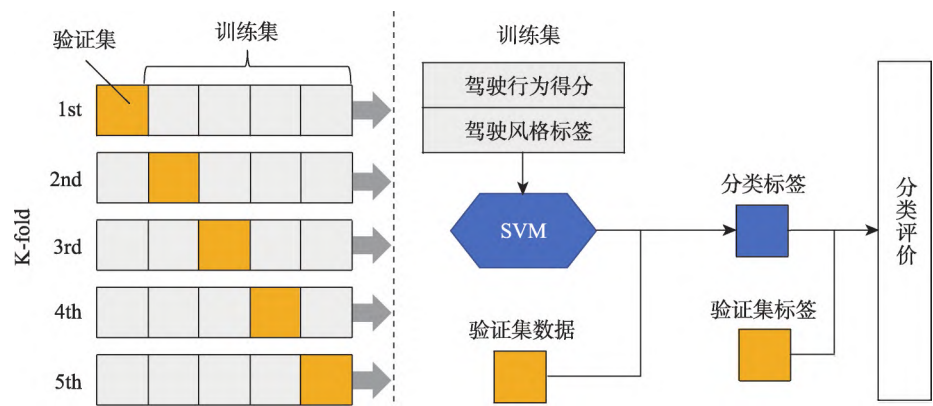


图7 驾驶风格分类验证流程

Fig. 7 Flow chart of driving style classification verification

表6 驾驶风格分类验证结果

Tab. 6 Validation results of driving style classification (%)

K-fold	平均准确率 <i>A</i>	平均精确率 <i>P</i>	平均召回率 <i>R</i>	F1
3-fold	87.297	86.772	87.567	87.144
5-fold	97.461	96.894	97.864	97.346

模型和考虑驾驶员驾驶风格的跟驰模型参数取值范围设定为:

- FVD模型: $a \in [0, 1]$, $\lambda \in [0, 1]$;
- 考虑驾驶员驾驶风格的跟驰模型: $\alpha \in [0, 1]$, $\beta \in [0, 1]$, $\sigma, \mu_1, \mu_2 \in [-2, 2]$;

通过将遗传算法相应的条件设置为:种群大小为100,交叉概率为0.8,变异概率为0.2,迭代600次终止,得到相同数据集的GA标定结果和目标函数值如表7所示。

最后,通过分别将标定后的考虑驾驶员驾驶风

表7 跟驰模型参数标定结果

Tab. 7 Calibration results of the follower model parameters

	FVD模型	考虑驾驶员驾驶风格的跟驰模型
参数标定结果	$a=0.053$ $\lambda=0.493$	$\alpha=0.014, \beta=0.199,$ $\sigma=-0.145,$ $\mu_1=1.765, \mu_2=-1.294$
F_{obj}	2.713	1.892

格的跟驰模型和原有的FVD模型计算的加速度估计值与原始的车辆轨迹加速度进行比较(图8),经过参数标定的改进模型对原始车辆加速度数据具有更好的拟合性。

为了进一步验证标定结果,分别将标定后的考虑驾驶员驾驶风格的跟驰模型和FVD模型对相同驾驶风格的跟驰行为验证数据集进行比较,如图9所示,针对相同驾驶风格的驾驶员,改进的跟驰模




图8 FVD模型与改进模型的加速度仿真对比图(标定组)

Fig. 8 Comparison of simulated accelerations with FVD model and improved model (calibration group)




图9 FVD模型与改进模型的加速度仿真对比图(验证组)

Fig. 9 Comparison of simulated accelerations with FVD model and improved model (verification group)

型能够更好地模拟真实车辆的加速度情况,进而能够对其跟驰行为进行有效地模拟仿真。综上所述,在局部和整体效果上,改进模型($F_{obj}=2.013$)相比FVD($F_{obj}=3.524$),其对车辆加速度变化的捕捉更为敏感,能够展现出更细节的变化趋势,达到更好的仿真效果。另外,由于在车辆跟驰仿真实验中通常假设车辆只会受到前后车辆的影响,但在实际驾驶过程中还会受到其他如行人、路面障碍物等突发事件的影响,这也会使得车辆跟驰模型有时会出现与原始数据幅度变化相反的情况。

为了对跟驰模型参数的标定效果进一步说明,本文采用平均绝对误差(Mean Absolute Error, MAE)、平均绝对百分比误差(Mean Absolute Percentage Error, MAPE)和均方根误差(Root Mean Square Error, RMSE)作为评价指标,从统计学的角度对模型进行评价:

$$MAE = \frac{1}{N} \sum_{i=1}^N |a_i^* - a_i| \quad (14)$$

$$MAPE = \frac{1}{N} \sum_{i=1}^N \left| \frac{a_i^* - a_i}{a_i} \right| \quad (15)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (a_i^* - a_i)^2} \quad (16)$$

式中: N 表示车辆加速度数据的总数; a_i^* 表示跟驰模型生成的加速度; a_i 为车辆的实际速度; i 为数据集的索引号。

从表8中可以知道,考虑驾驶员驾驶风格的跟驰模型的各项指标数值均小于FVD模型,即本文所改进跟驰模型在对车辆跟驰行为的仿真模拟方面要比FVD模型更符合车辆的实际策略。

表8 FVD模型与改进模型的加速度仿真评价

Tab. 8 Evaluation of simulated accelerations between FVD model and improved model


评价指标	FVD模型	考虑驾驶员驾驶风格的跟驰模型
MAE/(m/s ²)	3.524	2.013
MAPE/%	11.794	5.672
RMSE/(m/s ²)	3.613	2.549

4 模型仿真分析

4.1 加速过程仿真对比分析

本研究构建了车辆起步加速的交通流仿真场景:沿着直线车道(即X轴)等距水平放置20辆驾驶风格相同的车辆,仿真开始前,车辆完全处于静止状态,车辆的车头间距均为10 m,进而研究分析交通信号灯由红灯转变为绿灯时不同跟驰模型车辆的运动状态(车辆的速度、加速度和车辆的位置)。如图10所示为考虑驾驶员驾驶风格模型和FVD模型仿真的车辆跟驰加速度对比图,从图10中可以很明显看出,在考虑驾驶风格的车辆跟驰模型仿真结果中,随着车辆驶出的次序增加,车辆的初始加速度呈现先减小后缓慢增大的趋势。这种结果与实际城市道路中的车辆通行情况更相符,其可以通过跟驰理论来解释,即当前车通过后,后车会有更多的空间可以加速,并且不会受到前车的限制,因此后车的加速度可以更高。


另外,采用改进模型的起步加速度仿真曲线相较FVD模型紧凑(图11),这也代表改进模型对前车的行为有着更快的反应,这主要得益于改进模型通过对视野中的车辆的加速度进行考虑,能够更快



注: 不同颜色的曲线代表不同仿真车辆的加速度变化情况。

图 10 不同模型的车辆起步加速度仿真对比

Fig. 10 Comparison of simulated vehicle starting accelerations with different models



注: 不同颜色的曲线代表不同仿真车辆的速度变化情况。

图 11 不同模型的车辆起步速度仿真对比

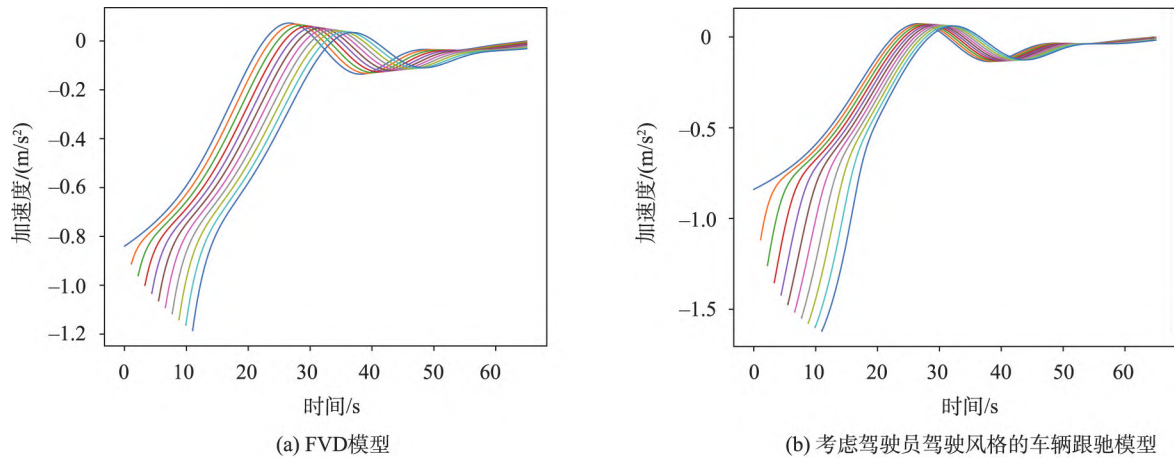
Fig. 11 Comparison of simulated vehicle starting speeds with different models

地对交通流的运行状态进行捕捉,进而更早采取相应的驾驶策略。如图 11 起步速度仿真对比图可知,改进模型的车辆速度在仿真时间第 37 s 时就达到稳定状态,而此时 FVD 模型还尚未趋于稳定。同时,改进模型通过对多辆前车进行考虑,因此能够反映跟驰车丰富跟驰策略及其差异,而构建异质交通流,而在 FVD 模型仿真实验中,各车辆的跟驰行为则表现得相对一致。综上所述,由于改进模型通过考虑视野中车辆的行驶情况,从而能够减少车辆在跟驰行为中的延迟性,进而能够在起步中以相对平稳的加速度更快地达到稳定状态。

4.2 减速过程仿真对比分析

通过对起步加速的交通流场景进行仿真,说明了本文提出的考虑驾驶员驾驶风格的跟驰模型能够更贴近实际的车辆行驶情况。为了进一步说明改进的车辆跟驰模型在有速度的车辆跟驰的情况下,该模型也能够促进跟驰系统的稳定性,本文又设置了车辆制动减速仿真对比实验:基于上述的仿真场景,设置道路中所有车辆的行驶速度为 25 m/s,研究当首车进行减速后,但尚未完全制动的过程,观察各车辆特征的变化情况,并将两种模型进行对比分析。

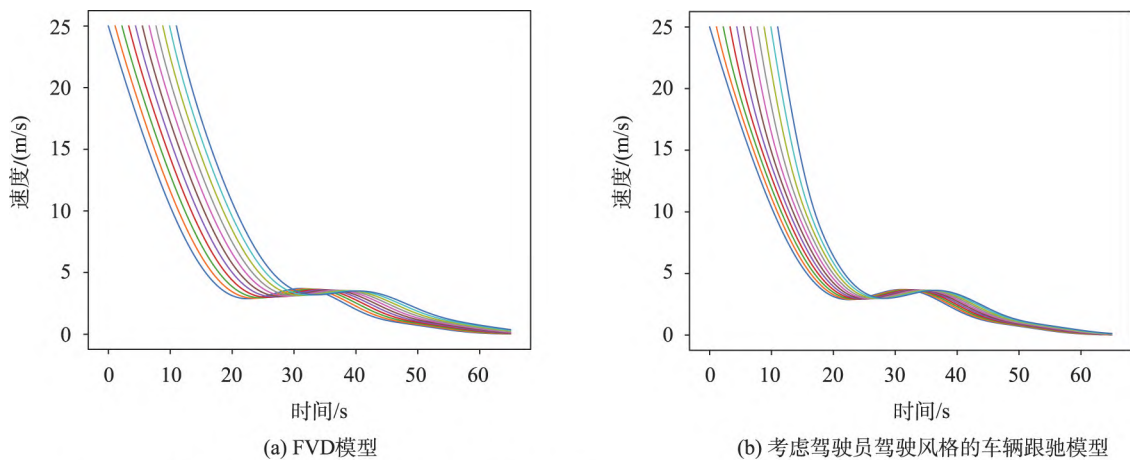
由图 12 和图 13 所示的车辆减速制动的加速度



注：不同颜色的曲线代表不同仿真车辆的速度变化情况。

图 12 不同模型的车辆减速加速度仿真对比

Fig. 12 Comparison of simulated vehicle deceleration accelerations with different models



注：不同颜色的曲线代表着不同仿真车辆的速度变化情况。

图 13 不同模型的车辆减速速度仿真对比

Fig. 13 Comparison of simulated vehicle deceleration speeds with different models

和速度对比图可知,考虑驾驶员驾驶风格的跟驰模型在头车采取减速行为的第 50 s 时,路面所有车辆的行驶速度保持相对一致,即交通流达到稳定状态。而反观 FVD 模型则是在第 60 s 时才达到稳定状态,相较改进模型有着 10 s 的时间延迟。同时,通过对各个车辆制动加速度进行分析,采用改进跟驰模型的仿真实验中后续车辆的加速度明显比头车采用的制动加速度要大,并且随车跟驰车的次序越靠后车辆的制动加速度的也明显加大,这符合实际城市道路的驾驶行为,即后面的跟驰车辆由于对先行车的制动行为有一定的反应时间,因此在后续采取的制动策略要比先行车更为激进。此外,相比

FVD 模型,改进模型通过对视野中多辆先行车进行观察,因此能够更快采取制动措施,其制动加速度曲线则显得更为紧凑。

5 结论与讨论

本文首先基于 NGSIM 车辆自然驾驶轨迹数据集,提出了一种基于数据流聚类算法的驾驶风格分类方法,实现了驾驶风格的有效分类。然后,基于经典的 FVD 跟驰模型,综合考虑驾驶员驾驶风格和驾驶员视野中多辆前车的影响,提出了一种考虑驾驶员驾驶风格的车辆跟驰模型,并对模型的仿真性

能进行对比分析。主要结论如下:

(1) 基于 WStream 算法的驾驶风格分类方法能够量化驾驶员不同驾驶行为(起步、制动、变道和平稳驾驶)的激进程度,进而实现车辆驾驶风格的有效分类,分类准确率能够达到 97%,为考虑驾驶员驾驶风格的车辆跟驰模型的构建奠定了基础;

(2) 考虑驾驶员驾驶风格的车辆跟驰模型综合考虑驾驶员驾驶风格和驾驶视野中多辆前车的速度差等信息,能够更真实的反映实际跟驰过程中当前车所受到的影响。模型验证结果表明,相比经典的 FVD 模型,本文所提出的模型能够更好预测车辆的实际加速度,其 MAE 、 $MAPE$ 、 $RMSE$ 分别减小了 1.511 m/s^2 、 6.122% 、 1.064 m/s^2 ;

(3) 本文所提出的车辆跟驰模型在车辆起步和制动的交通流仿真实验中,相较 FVD 模型能够对先行车的突发驾驶行为进行快速反应,有效地减少车辆在跟驰行为中的延迟性,有着更良好的仿真性能。综上所述,本文基于城市道路车辆轨迹数据,构建了一种行之有效的车辆跟驰模型,为城市微观交通流的高效仿真模拟提供了模型参考,并有利于研究异质交通流的变化规律。

本研究所构建的车辆跟驰模型虽然能够有效模拟实际交通流场景下的车辆跟驰行为,但尚未考虑相邻车道前车变道行为等对主车的影响,在未来的研究工作中,我们将进一步探究车辆跟驰策略的潜在影响因素,提高跟驰模型对实际交通流的仿真能力。

参考文献(References):

- [1] Tsuboi T. Traffic flow analysis and management[M]//Design of Cities and Buildings-Sustainability and Resilience in the Built Environment. IntechOpen, 2021. DOI: 10.5772/intechopen.95087
- [2] Hossain M A, Tanimoto J. A microscopic traffic flow model for sharing information from a vehicle to vehicle by considering system time delay effect[J]. Physica A: Statistical Mechanics and Its Applications, 2022,585: 126437. DOI:10.1016/j.physa.2021.126437
- [3] Zhang Y, Xiang W, Dong J, et al. An improved car-following model considering forecast speed difference with delay time[J]. Modern Physics Letters B, 2019,33(33): 1950414. DOI:10.1142/s0217984919504141
- [4] Ma G Y, Li K P, Sun H N. Modeling and simulation of traffic flow based on memory effect and driver characteristics[J]. Chinese Journal of Physics, 2023,81:144-154. DOI:10.1016/j.cjph.2022.11.008
- [5] Pipes L A. An operational analysis of traffic dynamics[J]. Journal of Applied Physics, 1953,24(3):274-281. DOI: 10.1063/1.1721265
- [6] Kometani E, Sasaki T. On the stability of traffic flow (report-I)[J]. Journal of the Operations Research Society of Japan, 1958,2(1):11-26.
- [7] Sarker A, Shen H Y, Rahman M, et al. A review of sensing and communication, human factors, and controller aspects for information-aware connected and automated vehicles[J]. IEEE Transactions on Intelligent Transportation Systems, 2020,21(1):7-29. DOI:10.1109/TITS.2019.2892399
- [8] Newell G F. Nonlinear effects in the dynamics of car following[J]. Operations Research, 1961,9(2):209-229. DOI: 10.1287/opre.9.2.209
- [9] Bando M, Hasebe K, Nakayama A, et al. Dynamical model of traffic congestion and numerical simulation[J]. Physical Review E, 1995,51(2):1035-1042. DOI:10.1103/physreve.51.1035
- [10] Helbing D, Tilch B. Generalized force model of traffic dynamics[J]. Physical Review E, 1998,58(1):133-138. DOI: 10.1103/physreve.58.133
- [11] Jiang R, Wu Q S, Zhu Z J. Full velocity difference model for a car-following theory[J]. Physical Review E, 2001, 64:017101. DOI:10.1103/physreve.64.017101
- [12] 王涛,高自友,赵小梅.多速度差模型及稳定性分析[J].物理学报,2006,55(2):634-640. [Wang T, Gao Z Y, Zhao X M. Multiple velocity difference model and its stability analysis[J]. Acta Physica Sinica, 2006,55(2):634-640.] DOI:10.3321/j.issn: 1000-3290.2006.02.028
- [13] 孙隽华,张建厂,赵敏,等.考虑后视效应和速度差信息的跟驰模型[J].四川大学学报(自然科学版),2012,49(1): 115-120. [Sun D H, Zhang J C, Zhao M, et al. Effect of backward looking and velocity difference in an extended car following model[J]. Journal of Sichuan University (Natural Science Edition), 2012,49(1):115-120.] DOI: 10.3969/j.issn.0490-6756.2012.01.019
- [14] 申勇,马天奕,李祥尘.考虑速度对反应强度影响的车辆跟驰模型[J].交通运输工程与信息学报,2019,17(2):153-159. [Shen Y, Ma T Y, Li X C. Improved car-following model considering the influence of velocity on driver response[J]. Journal of Transportation Engineering and Information, 2019,17(2):153-159.] DOI:10.3969/j.issn.1672-4747.2019.02.020
- [15] Zhang J, Wang B, Li S B, et al. Modeling and application analysis of car-following model with predictive headway variation[J]. Physica A: Statistical Mechanics and Its Applica-

- tions, 2020,540:123171. DOI:10.1016/j.physa.2019.123171
- [16] Jiang N, Yu B, Cao F, et al. An extended visual angle car-following model considering the vehicle types in the adjacent lane[J]. *Physica A: Statistical Mechanics and Its Applications*, 2021,566:125665. DOI:10.1016/j.physa.2020.125665
- [17] 潘义勇,管星宇.基于分位数回归的随机优化速度跟驰模型[J]. *浙江大学学报(工学版)*,2022,56(8):1553-1559. [Pan Y Y, Guan X Y. Stochastic optimal velocity car-following model based on quantile regression[J]. *Journal of Zhejiang University (Engineering Science)*, 2022,56(8):1553-1559.] DOI:10.3785/j.issn.1008-973X.2022.08.009
- [18] U.S. Department of Transportation Federal Highway Administration. (2016). Next Generation Simulation (NGSIM) Vehicle Trajectories and Supporting Data. [Dataset]. Provided by ITS DataHub through Data.transportation.gov. Accessed 2022-10-10 from <http://doi.org/10.21949/1504477>.
- [19] Zhang J, Tang T Q, Wang T. Some features of car-following behaviour in the vicinity of signalised intersection and how to model them[J]. *IET Intelligent Transport Systems*, 2019,13(11):1686-1693. DOI:10.1049/iet-its.2018.5510
- [20] Zhao M, Wang S H, Sun D H, et al. A car-following model considering preceding vehicle's lane-changing process [J]. *IEEE Access*, 2019,7:89913-89923. DOI:10.1109/ACCESS.2019.2924659
- [21] Puschmann D, Barnaghi P, Tafazolli R. Adaptive clustering for dynamic IoT data streams[J]. *IEEE Internet of Things Journal*, 2017,4(1):64-74. DOI:10.1109/JIOT.2016.2618909
- [22] Nikulin V. Driving style identification with unsupervised learning[C]//International Conference on Machine Learning and Data Mining in Pattern Recognition. Cham: Springer, 2016:155-169. DOI:10.1007/978-3-319-41920-6_12
- [23] Ren G Q, Zhang Y, Liu H, et al. A new lane-changing model with consideration of driving style[J]. *International Journal of Intelligent Transportation Systems Research*, 2019,17(3):181-189. DOI:10.1007/s13177-019-00180-7
- [24] Deng Z J, Chu D F, Wu C Z, et al. A probabilistic model for driving-style-recognition-enabled driver steering behaviors[J]. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2022,52(3):1838-1851. DOI:10.1109/TSMC.2020.3037229
- [25] 王光,林国宇.改进的自适应参数DBSCAN聚类算法[J]. *计算机工程与应用*,2020,56(14):45-51. [Wang G, Lin G Y. Improved adaptive parameter DBSCAN clustering algorithm[J]. *Computer Engineering and Applications*, 2020,56(14):45-51.] DOI:10.3778/j.issn.1002-8331.1908-0501
- [26] Lambora A, Gupta K, Chopra K. Genetic algorithm- A literature review[C]//2019 International Conference on Machine Learning, Big Data, Cloud and Parallel Computing (COMITCon). IEEE, 2019:380-384. DOI:10.1109/COMITCon.2019.8862255
- [27] Vaitkus V, Lengvenis P, Žylius G. Driving style classification using long-term accelerometer information[C]//2014 19th International Conference on Methods and Models in Automation and Robotics (MMAR). IEEE, 2014:641-644. DOI:10.1109/MMAR.2014.6957429
- [28] Wang W S, Xi J Q. A rapid pattern-recognition method for driving styles using clustering-based support vector machines[C]//2016 American Control Conference (ACC). IEEE, 2016:5270-5275. DOI:10.1109/ACC.2016.7526495
- [29] Peng Y, Liu S, Dennis Z Y. An improved car-following model with consideration of multiple preceding and following vehicles in a driver's view[J]. *Physica A: Statistical Mechanics and Its Applications*, 2020,538:122967. DOI:10.1016/j.physa.2019.122967
- [30] Zhu M X, Wang X S, Tarko A, et al. Modeling car-following behavior on urban expressways in Shanghai: A naturalistic driving study[J]. *Transportation Research Part C: Emerging Technologies*, 2018,93:425-445. DOI:10.1016/j.trc.2018.06.009